

Uso de IA

De acuerdo a desarrollar el sistema más preciso y completo posible, estudiamos la implementación de distintas arquitecturas.

Recuperación de la información correspondiente mediante RAGs multi-hop Agénticos.

Para poder aprovechar la mayor cantidad posible de documentación e incorporar de forma continua nuevos procedimientos, resoluciones y fuentes jurídicas, los modelos LLM de *ReJust* estarán acompañados por una arquitectura RAG agéntica y *multi-hop*. Su función será recuperar dinámicamente la información necesaria para cada caso antes de elaborar cualquier razonamiento o propuesta de resolución.

Como referencia de las capacidades que esperamos alcanzar (*“Conversación estado del arte de algoritmos RAGs”*) pueden considerarse arquitecturas actuales como Graph-R1 ([2507.21892] *Graph-R1: Towards Agentic GraphRAG Framework via End-to-end Reinforcement Learning*), en las que la recuperación deja de consistir en una única consulta estática. El agente puede analizar en qué estado se encuentra, teniendo en cuenta la pregunta inicial, la información recuperada hasta ese momento y los pasos realizados previamente, y decidir de forma iterativa cuál debe ser su siguiente acción: realizar una nueva consulta, profundizar sobre determinada información, explorar una relación concreta, consultar otra fuente o finalizar la búsqueda cuando considere que dispone de evidencia suficiente.

La recuperación combinaría distintas técnicas complementarias. Por una parte, se utilizarían métodos de recuperación léxica, como *BM25* (Robertson and Zaragoza), especialmente útiles para localizar términos jurídicos exactos, nombres, identificadores, artículos concretos o expresiones específicas. Estos métodos se complementarían con sistemas de recuperación densa y semántica, como *ColBERTv2* ([2112.01488] *ColBERTv2: Effective and Efficient Retrieval via Lightweight Late Interaction*), capaces de localizar documentos conceptualmente relacionados incluso cuando no emplean exactamente las mismas palabras.

Sobre estas técnicas se incorporarían arquitecturas de recuperación basadas en grafos, inspiradas en aproximaciones actuales como Microsoft GraphRAG (Microsoft) , HippoRAG ([2405.14831] *HippoRAG: Neurobiologically Inspired Long-Term Memory for Large Language Models*) o HippoRAG 2 ([2502.14802] *From RAG to Memory: Non-Parametric Continual Learning for Large Language Models*), así como en futuros algoritmos de construcción y exploración de grafos. La finalidad sería representar explícitamente las relaciones existentes entre procedimientos, personas, delitos, artículos legales, jurisprudencia, pruebas, informes periciales y resoluciones judiciales. De este modo, la recuperación no se limitaría a encontrar documentos individualmente similares, sino que permitiría realizar búsquedas multi-hop recorriendo relaciones entre distintas fuentes. Por ejemplo, el sistema podría localizar inicialmente un determinado tipo penal, recuperar las

resoluciones relacionadas con él, identificar qué sentencias son citadas por esas resoluciones y explorar posteriormente casos con hechos o circunstancias similares.

Destacar que los algoritmos mencionados representan únicamente ejemplos del estado actual de la tecnología. Al situar *ReJust* en el año 2030, asumimos la existencia de técnicas de recuperación considerablemente más avanzadas, capaces de alcanzar niveles muy elevados de cobertura de la información relevante para una consulta. El objetivo no sería garantizar matemáticamente la recuperación absoluta de toda la información existente, sino minimizar al máximo la posibilidad de omitir evidencia jurídicamente relevante.

Sobre esta capa de recuperación se situaría una arquitectura agéntica, potencialmente compuesta por distintos agentes o herramientas especializadas. Algunos componentes podrían encargarse de planificar la búsqueda, otros de consultar jurisprudencia, legislación o expedientes, otros de recorrer el grafo de conocimiento y otros de comprobar si la evidencia obtenida resulta suficiente o si es necesario continuar investigando, es decir, actuando como una “mezcla de expertos”. Una de las propuestas de *ReJust* para 2030 sería mejorar progresivamente la estrategia de recuperación mediante un mecanismo inspirado en *Dream-RSI* (“*Dream-RSI: Recursive Self-Improvement through Evolving Worlds*”). Para ello, se conservarían experiencias de búsqueda que incluyeran el estado inicial, las acciones ejecutadas, las fuentes consultadas, los resultados obtenidos y el coste asociado. A partir de estas experiencias se evaluarían distintas políticas para decidir qué fuente consultar, qué línea de investigación ampliar y cuándo finalizar una búsqueda. La evaluación offline quedaría limitada a las acciones y resultados disponibles en el historial. Si una política propusiese una consulta nueva cuyo resultado no estuviese registrado, sería necesario ejecutarla o dejar esa parte de la evaluación pendiente. Por tanto, la memoria de experiencias se ampliaría mediante nuevas exploraciones y se actualizaría cuando cambiasen las fuentes utilizadas. Las políticas se compararían atendiendo a la relevancia y cobertura de la evidencia recuperada, la detección de información contradictoria, la corrección de las referencias y el coste computacional. La evaluación combinaría comprobaciones automáticas con casos revisados por especialistas. Antes de incorporar una política al sistema, se comprobaría su comportamiento sobre casos separados de los utilizados para desarrollarla. El objetivo sería mejorar la eficiencia de la búsqueda manteniendo la calidad y trazabilidad de sus resultados. (“conversación algoritmo RSI de Google”)

Caso de uso:

«Encuentra todas las condenas asociadas a este individuo.»

El agente podría aprender que una búsqueda directa sobre determinadas bases de datos resulta suficiente. Sin embargo, ante una consulta como:

«Encuentra las condenas más similares a este caso, teniendo en cuenta los hechos, la fecha, el tipo penal, los agravantes y las circunstancias del acusado.»

el sistema podría activar automáticamente una estrategia de recuperación mucho más compleja, combinando búsqueda semántica, exploración del grafo, recuperación multi-hop, comparación temporal y consulta de múltiples fuentes.

En nuestro escenario de 2030, estas políticas se habrían desarrollado y evaluado sobre tareas jurídicas heterogéneas, desde consultas directas hasta búsquedas que requiriesen múltiples pasos. Un LLM podría proponer modificaciones en las reglas o el código que dirige la exploración, sin que ello implicase necesariamente modificar sus propios parámetros. Cada nueva versión se sometería a evaluación antes de utilizarse y permanecería identificada para poder reconstruir qué estrategia intervino en cada caso. Así, ReJust buscaría mejorar cómo consulta sus fuentes y distribuye sus recursos a lo largo de todo el proceso de análisis y revisión.



Figura 1: Esquema de la arquitectura propuesta. Imagen generada por ChatGPT.

Visión por computador

Para analizar las pruebas audiovisuales de un procedimiento penal y detectar comportamientos potencialmente relevantes en entornos penitenciarios, ReJust incorporará un módulo de visión por computador aplicado principalmente a cámaras de videovigilancia (CCTV). Este módulo se apoyará en modelos Vision Transformer y Vision-Language Models, arquitecturas que actualmente constituyen una de las principales líneas de investigación para la comprensión semántica de imágenes y vídeo. En el escenario planteado para 2030, suponemos además que estos modelos habrán sido entrenados o adaptados con grandes cantidades de ejemplos representativos de comportamientos, interacciones y situaciones potencialmente violentas o sancionables.

Una arquitectura actual que puede servir como referencia consistiría en combinar estos modelos de visión con técnicas avanzadas de *Video Anomaly Detection* y sistemas RAG. El procesamiento podría dividirse en varias fases.

En primer lugar, se realizaría una segmentación temporal del vídeo, dividiéndolo en fotogramas o pequeños fragmentos temporales. Sobre ellos podrían aplicarse aproximaciones similares a LAVAD (“[2404.01014] Harnessing Large Language Models for Training-free Video Anomaly Detection”), donde un modelo visión-lenguaje genera descripciones textuales de lo que sucede en las imágenes y posteriormente un LLM analiza temporalmente estas descripciones, las refina y estima si los acontecimientos observados pueden considerarse anómalos. LAVAD resulta especialmente interesante porque demuestra que es posible realizar detección de anomalías aprovechando modelos pre entrenados sin tener que entrenar específicamente un nuevo detector para cada escenario.

En sistemas de videovigilancia continua, analizar repetidamente grabaciones completas supondría un coste elevado y podría superar la capacidad de contexto del modelo. Para reducir este problema, *ReJust* incorporaría una memoria estructurada de eventos que recogería qué entidades aparecen, qué acciones se observan, dónde ocurren y durante qué intervalo temporal. Esta memoria actuaría como un índice para localizar información relevante, manteniendo vínculos con los fragmentos audiovisuales originales. Las representaciones compactas no sustituirían a las grabaciones, cuya conservación y acceso se gestionarían conforme a las condiciones aplicables. Un sistema RAG especializado en vídeo recuperaría los eventos y fragmentos necesarios para cada consulta, incluyendo contexto anterior y posterior cuando resultase pertinente. De este modo, sería posible revisar una descripción generada, comprobar interpretaciones alternativas y recuperar detalles que hubieran quedado fuera del resumen inicial.

En lugar de realizar una única recuperación, el sistema podría razonar sobre la información obtenida, detectar que falta contexto y ejecutar nuevas recuperaciones de forma iterativa. Una arquitectura actual que muestra esta dirección es Memory-enhanced Retrieval Augmentation for Long Video Understanding, que propone memorizar información global del vídeo, razonar sobre qué información necesita la consulta, recuperar los momentos relevantes y finalmente concentrar el análisis sobre ellos (“[2503.09149] Memory-enhanced Retrieval Augmentation for Long Video Understanding”). Esta separación entre memoria global y recuperación de momentos concretos permitiría trabajar con grabaciones de muchas horas sin tener que procesarlas íntegramente cada vez que se formula una

consulta. Por ejemplo, ante una investigación sobre una agresión, el sistema podría recuperar primero el instante de la agresión, posteriormente buscar qué interacciones habían ocurrido entre las mismas personas minutos antes y, si fuera necesario, ampliar de nuevo la búsqueda hacia acontecimientos anteriores.

Para el funcionamiento online, donde las imágenes llegan continuamente desde las cámaras, sería necesario mantener además una memoria temporal del contexto reciente. Una referencia especialmente interesante es MoniTor, que procesa vídeo en streaming y utiliza estados anteriores y predicciones recientes para interpretar el fotograma actual. Su mecanismo está inspirado en las redes LSTM, conservando información relevante del pasado y utilizando una memoria dinámica para determinar si la secuencia reciente de acontecimientos puede representar una anomalía (“[2510.21449] MoniTor: Exploiting Large Language Models with Instruction for Online Video Anomaly Detection”). Por tanto, una acción no tendría que considerarse anómala únicamente por lo observado en un fotograma aislado. El sistema podría considerar la secuencia completa de acontecimientos. Por ejemplo, observar a una persona corriendo puede no contener información suficiente por sí solo; sin embargo, si previamente el sistema ha registrado una confrontación y segundos después detecta que una de las personas involucradas huye, el contexto temporal permite construir una interpretación mucho más rica de la situación.

Finalmente, esta memoria podría representarse mediante un grafo dinámico de eventos, conectando personas, objetos, lugares y acontecimientos mediante relaciones como *participa_en*, *interactúa_con*, *ocurre_en* o *precede_a*. Cada evento y relación conservaría un vínculo con el fragmento audiovisual del que procede, su intervalo temporal y la información disponible sobre la fiabilidad de su identificación. De esta manera, la información extraída de miles de fotogramas se organizaría en una estructura semántica consultable y vinculada a sus fuentes originales.

Esta representación distinguiría explícitamente entre observaciones audiovisuales, hipótesis interpretativas y valoraciones jurídicas. Por ejemplo, detectar que una persona corre después de una confrontación permitiría registrar una secuencia de acciones, pero no demostraría por sí solo que está huyendo ni que ha cometido una infracción. Del mismo modo, que un acontecimiento preceda a otro no permitiría afirmar automáticamente que lo ha causado. Las interpretaciones generadas por el sistema se almacenarían como hipótesis revisables, acompañadas de sus evidencias y posibles explicaciones alternativas, para contrastarlas posteriormente con el resto de la información del caso.




Figura 2. Ejemplo conceptual de un grafo de eventos extraídos de videovigilancia. Los eventos representan observaciones e hipótesis que requieren contraste con las grabaciones originales. Imagen generada con ChatGPT.

El RAG podría recuperar tanto fragmentos audiovisuales como subgrafos de acontecimientos relacionados, proporcionando al modelo de razonamiento un contexto compacto y estructurado. Esta representación facilitaría la reconstrucción temporal de una situación y la consulta de relaciones entre entidades, aunque podría omitir detalles presentes en la grabación. Por ello, cualquier conclusión relevante debería poder contrastarse con los fragmentos originales y ampliarse mediante nuevas recuperaciones cuando fuese necesario.

Modelos Juez

A partir de una primera recuperación de información, un sistema de agentes LLM que dominan el razonamiento jurídico analizaría conjuntamente los hechos del procedimiento, las pruebas disponibles, la legislación aplicable y la jurisprudencia recuperada. Después sacaría conclusiones que deberían estar sustentadas por información concreta y verificable del expediente y de las fuentes jurídicas consultadas.

La recuperación y el razonamiento funcionarían de forma iterativa. Si durante el análisis un agente detectase una contradicción, una fuente incompleta o una cuestión que no pudiera resolverse con el contexto disponible, solicitaría información adicional al módulo RAG. Por ejemplo, podría pedir una versión concreta de una norma, ampliar un fragmento audiovisual o buscar resoluciones que cuestionasen una interpretación provisional. Si, tras estas comprobaciones, persistiesen carencias relevantes, el sistema debería identificarlas explícitamente y limitar el alcance de su propuesta, dejando las cuestiones pendientes para revisión humana.

En nuestro escenario de 2030, suponemos modelos específicamente entrenados para el dominio jurídico mediante conjuntos de datos amplios y heterogéneos, sometidos además a procesos destinados a reducir sesgos, inconsistencias y diferencias injustificadas entre casos equivalentes. No asumimos una objetividad absoluta, sino un sistema diseñado para aplicar de forma consistente unos mismos criterios jurídicos ante circunstancias equivalentes.

La arquitectura podría estar formada por diferentes agentes especializados. Por ejemplo, un agente podría analizar los hechos y pruebas, otro estudiar la legislación aplicable, otro contrastar la jurisprudencia y precedentes similares, y otro actuar como agente crítico, buscando contradicciones, información omitida o argumentos que cuestionen la conclusión provisional. Finalmente, un agente de síntesis integraría estas perspectivas para elaborar una resolución estructurada y motivada. Esta incluiría no solamente la decisión propuesta y, cuando proceda, la pena correspondiente, sino también los hechos considerados probados, las normas aplicadas, los precedentes utilizados, los elementos que han influido en la decisión y el grado de incertidumbre existente.

Cada agente produciría una salida estructurada que distinguiese sus conclusiones provisionales, las fuentes utilizadas, las incertidumbres detectadas y las comprobaciones pendientes. El agente de hechos separaría la información respaldada de las afirmaciones discutidas; el de legislación identificaría las normas potencialmente aplicables y su contexto temporal; el de jurisprudencia explicaría las semejanzas y diferencias relevantes entre casos; y el crítico buscaría contradicciones y explicaciones alternativas. El agente de síntesis integraría estas aportaciones conservando los desacuerdos que pudieran afectar a la propuesta. La coincidencia entre agentes no se consideraría una validación suficiente, especialmente cuando compartiesen modelo o fuentes, por lo que las conclusiones deberían contrastarse con evidencia verificable.




Figura 2. Arquitectura conceptual de agentes especializados para el análisis jurídico. Los agentes pueden solicitar información adicional al módulo de recuperación antes de elaborar una propuesta estructurada. Imagen generada con ChatGPT.

Módulo de explicabilidad y trazabilidad

Dado que las decisiones tomadas por *ReJust* podrían tener consecuencias extremadamente importantes sobre las personas afectadas, la explicabilidad y trazabilidad constituirían una parte central de la arquitectura y no únicamente una explicación generada posteriormente por el propio LLM. Cada afirmación relevante de la resolución deberá estar vinculada con la evidencia concreta que la sustenta. Gracias a la arquitectura RAG, el sistema podrá indicar qué fragmentos del expediente, artículos legales, informes periciales o resoluciones jurisprudenciales han sido utilizados para alcanzar cada conclusión. Las citas incluirían además información sobre su procedencia, fecha y versión, permitiendo reconstruir posteriormente el proceso seguido por el sistema.

Junto a esta trazabilidad documental podrían utilizarse técnicas de XAI , como SHAP o LIME, cuando existan componentes predictivos o clasificadores en los que resulte útil determinar qué variables han tenido mayor influencia sobre una determinada predicción. Sin embargo, estas técnicas no serían suficientes para explicar por sí solas el razonamiento completo de un sistema basado en LLM.

Por ello, *ReJust* incorporaría diferentes niveles de explicación:

- **Explicabilidad documental:** mostrar exactamente qué documentos y fragmentos sustentan cada afirmación.
- **Explicabilidad jurídica:** indicar qué normas, artículos y precedentes justifican la interpretación realizada.
- **Explicabilidad del modelo:** analizar, cuando sea técnicamente posible, qué variables o elementos de entrada han influido especialmente en determinadas predicciones.
- **Explicabilidad contrafactual:** permitir analizar cómo cambiaría la decisión si determinados hechos fueran diferentes. Por ejemplo, comprobar si la ausencia de un agravante concreto modificaría la pena propuesta.
- **Trazabilidad del proceso:** registrar qué agentes participaron, qué información recuperaron, qué hipótesis consideraron y qué comprobaciones realizaron antes de alcanzar la conclusión final.

Además, el sistema debería ser capaz de mostrar evidencia favorable y desfavorable a su propia conclusión. Si existe jurisprudencia contradictoria, pruebas con interpretaciones alternativas o incertidumbre sobre algún hecho relevante, dicha información deberá aparecer explícitamente en la explicación en lugar de ser ocultada por la respuesta final. El objetivo es que una resolución de *ReJust* no se limite a proporcionar una decisión, sino que permita reconstruir de manera auditable

- qué información conocía
- qué evidencia utilizó
- qué normas aplicó
- qué alternativas consideró
- por qué descartó otras interpretaciones

- cómo llegó finalmente a la resolución propuesta.

De esta manera, la explicabilidad no dependería únicamente de que el modelo sea capaz de generar una justificación aparentemente convincente, sino de que dicha justificación pueda ser contrastada con evidencias externas, verificables y trazables.

Evaluación y gestión de la incertidumbre

La evaluación de ReJust se realizaría tanto por componentes como sobre el funcionamiento completo del sistema. En recuperación se mediría la capacidad para localizar evidencia relevante, incluyendo información que contradijese la hipótesis inicial. En visión por computador se analizarían las falsas alarmas, los eventos omitidos y los errores al asociar personas o acciones entre fragmentos. En razonamiento se comprobarían las afirmaciones sin respaldo, las contradicciones y el uso de fuentes que no resultasen aplicables al caso. Finalmente, se verificaría que las citas de cada propuesta sustentasen realmente las afirmaciones a las que están asociadas.

Para valorar la aportación de la arquitectura, se compararía su funcionamiento con alternativas más sencillas, como una recuperación sin exploración del grafo o un único agente de razonamiento. También se analizaría qué sucede al retirar componentes concretos, como la memoria de experiencias o el agente crítico. Estas comparaciones permitirían justificar su utilidad y su coste.

La evaluación utilizaría casos separados de los empleados para desarrollar el sistema e incluiría situaciones ambiguas, fuentes incompletas y condiciones audiovisuales diversas. También examinaría posibles diferencias injustificadas de comportamiento entre grupos y contextos. La coincidencia con resoluciones históricas no se consideraría, por sí sola, una garantía de corrección.

ReJust debería identificar cuándo la evidencia disponible resulta insuficiente o presenta contradicciones sin resolver. En estas situaciones, la respuesta esperada sería solicitar información adicional, expresar los límites de la propuesta o remitir la cuestión a revisión humana. Cualquier estimación numérica de confianza requeriría validación; no se interpretaría directamente como una probabilidad de que la conclusión sea correcta.

Trabajos Citados

“[2112.01488] ColBERTv2: Effective and Efficient Retrieval via Lightweight Late Interaction.”

arXiv, <https://arxiv.org/abs/2112.01488>. Accessed 26 September 2026.

“[2404.01014] Harnessing Large Language Models for Training-free Video Anomaly

Detection.” *arXiv*, <https://arxiv.org/abs/2404.01014>. Accessed 27 September 2026.

“[2405.14831] HippoRAG: Neurobiologically Inspired Long-Term Memory for Large

Language Models.” *arXiv*, <https://arxiv.org/abs/2405.14831?> Accessed 27 September 2026.

“[2502.14802] From RAG to Memory: Non-Parametric Continual Learning for Large

Language Models.” *arXiv*, <https://arxiv.org/abs/2502.14802>. Accessed 27 September 2026.

“[2503.09149] Memory-enhanced Retrieval Augmentation for Long Video Understanding.”

arXiv, <https://arxiv.org/abs/2503.09149>. Accessed 27 September 2026.

“[2503.09149] Memory-enhanced Retrieval Augmentation for Long Video Understanding.”

arXiv, <https://arxiv.org/abs/2503.09149>. Accessed 27 September 2026.

“[2507.21892] Graph-R1: Towards Agentic GraphRAG Framework via End-to-end

Reinforcement Learning.” *arXiv*, <https://arxiv.org/abs/2507.21892>. Accessed 26 September 2026.

“[2510.21449] MoniTor: Exploiting Large Language Models with Instruction for Online Video

Anomaly Detection.” *arXiv*, <https://arxiv.org/abs/2510.21449>. Accessed 27 September 2026.

ChatGPT. *Conversación sobre el estado del arte de ViT*,

<https://chatgpt.com/c/6ab902e7-6dfc-83ed-9239-a25a2c08ca43>.

“conversación algoritmo RSI de Google.”

<https://chatgpt.com/c/6ab2144c-d4f8-83eb-a2ba-ecdd4e265471>

“Conversación estado del arte.”

<https://chatgpt.com/c/6ab7f0c6-71d4-83eb-bc99-e0dd3d92091d>.

“Dream-RSI: Recursive Self-Improvement through Evolving Worlds.” *arXiv*,

<https://arxiv.org/html/2609.14858v1>. Accessed 26 September 2026.

Microsoft. *Welcome - GraphRAG*, <https://microsoft.github.io/graphrag/>. Accessed 27 September 2026.

Robertson, Stephen, and Hugo Zaragoza. “The Probabilistic Relevance Framework: BM25 and Beyond Contents.” *City, University of London*,

https://www.staff.city.ac.uk/~sbrp622/papers/foundations_bm25_review.pdf.

Accessed 26 September 2026.