

Uso de IA

De acuerdo a desarrollar el sistema más preciso y completo posible, estudiamos la implementación de distintas arquitecturas.

Recuperación de la información correspondiente mediante *RAGs multi-hop* Agénticos.

Para poder aprovechar la mayor cantidad posible de documentación e incorporar de forma continua nuevos procedimientos, resoluciones y fuentes jurídicas, los modelos LLM de *ReJust* estarán acompañados por una arquitectura *RAG* agéntica y *multi-hop*. Su función será recuperar dinámicamente la información necesaria para cada caso antes de elaborar cualquier razonamiento o propuesta de resolución.

Como referencia de las capacidades que esperamos alcanzar (*“Conversación estado del arte de algoritmos RAGs”*) pueden considerarse arquitecturas actuales como Graph-R1 (*“[2507.21892] Graph-R1: Towards Agentic GraphRAG Framework via End-to-end Reinforcement Learning”*), en las que la recuperación deja de consistir en una única consulta estática. El agente puede analizar en qué estado se encuentra, teniendo en cuenta la pregunta inicial, la información recuperada hasta ese momento y los pasos realizados previamente, y decidir de forma iterativa cuál debe ser su siguiente acción: realizar una nueva consulta, profundizar sobre determinada información, explorar una relación concreta, consultar otra fuente o finalizar la búsqueda cuando considere que dispone de evidencia suficiente.

La recuperación combinaría distintas técnicas complementarias. Por una parte, se utilizarían métodos de recuperación léxica, como *BM25* (Robertson and Zaragoza), especialmente útiles para localizar términos jurídicos exactos, nombres, identificadores, artículos concretos o expresiones específicas. Estos métodos se complementarían con sistemas de recuperación densa y semántica, como *ColBERTv2* (*“[2112.01488] ColBERTv2: Effective and Efficient Retrieval via Lightweight Late Interaction”*), capaces de localizar documentos conceptualmente relacionados incluso cuando no emplean exactamente las mismas palabras.

Sobre estas técnicas se incorporarían arquitecturas de recuperación basadas en grafos, inspiradas en aproximaciones actuales como Microsoft GraphRAG (Microsoft) , HippoRAG (*“[2405.14831] HippoRAG: Neurobiologically Inspired Long-Term Memory for Large Language Models”*) o HippoRAG 2 (*“[2502.14802] From RAG to Memory: Non-Parametric Continual Learning for Large Language Models”*), así como en futuros algoritmos de construcción y exploración de grafos. La finalidad sería representar explícitamente las relaciones existentes entre procedimientos, personas, delitos, artículos legales, jurisprudencia, pruebas, informes periciales y resoluciones judiciales. De este modo, la recuperación no se limitaría a encontrar documentos individualmente similares, sino que permitiría realizar búsquedas multi-hop recorriendo relaciones entre distintas fuentes. Por ejemplo, el sistema podría localizar inicialmente un determinado tipo penal, recuperar las resoluciones relacionadas con él, identificar qué sentencias son citadas por esas resoluciones y explorar posteriormente casos con hechos o circunstancias similares.

Destacar que los algoritmos mencionados representan únicamente ejemplos del estado actual de la tecnología. Al situar *ReJust* en el año 2030, asumimos la existencia de técnicas de recuperación considerablemente más avanzadas, capaces de alcanzar niveles muy elevados de cobertura de la información relevante para una consulta. El objetivo no sería garantizar matemáticamente la recuperación absoluta de toda la información existente, sino minimizar al máximo la posibilidad de omitir evidencia jurídicamente relevante.

Sobre esta capa de recuperación se situaría una arquitectura agéntica, potencialmente compuesta por distintos agentes o herramientas especializadas. Algunos componentes podrían encargarse de planificar la búsqueda, otros de consultar jurisprudencia, legislación o expedientes, otros de recorrer el grafo de conocimiento y otros de comprobar si la evidencia obtenida resulta suficiente o si es necesario continuar investigando. Una de las principales innovaciones de nuestra propuesta para 2030 sería que la propia estrategia de recuperación podría aprender y evolucionar con la experiencia. Para ello planteamos un mecanismo inspirado en Dream-RSI (“Dream-RSI: Recursive Self-Improvement through Evolving Worlds”). La idea sería aprovechar las trayectorias de búsqueda ejecutadas previamente para construir una memoria de experiencias de recuperación (“Conversación algoritmo RSI de Google”). Cada trayectoria almacenaría información sobre el estado inicial, las consultas realizadas, las fuentes exploradas, las acciones tomadas, la evidencia recuperada, el coste de la búsqueda y la calidad final del resultado. Estas experiencias permitirían crear un entorno de entrenamiento *offline* en el que nuevas políticas de recuperación pudieran evaluarse sin tener que repetir constantemente todas las consultas contra bases de datos y sistemas externos. El objetivo no sería sustituir la consulta de las fuentes originales, que continuaría siendo necesaria para garantizar que la información está actualizada y es trazable, sino aprender qué estrategia de búsqueda resulta más eficiente para cada tipo de problema.

Caso de uso:

«Encuentra todas las condenas asociadas a este individuo.»

El agente podría aprender que una búsqueda directa sobre determinadas bases de datos resulta suficiente. Sin embargo, ante una consulta como:

«Encuentra las condenas más similares a este caso, teniendo en cuenta los hechos, la fecha, el tipo penal, los agravantes y las circunstancias del acusado.»

el sistema podría activar automáticamente una estrategia de recuperación mucho más compleja, combinando búsqueda semántica, exploración del grafo, recuperación multi-hop, comparación temporal y consulta de múltiples fuentes.

En nuestro escenario de 2030, estas políticas habrían sido entrenadas sobre un conjunto extremadamente heterogéneo de tareas jurídicas, desde consultas directas hasta problemas que requieran múltiples pasos de razonamiento y recuperación. Un LLM actuaría además como componente encargado de evaluar y mejorar progresivamente la política de búsqueda, aprendiendo qué factores son relevantes para decidir la siguiente acción y qué estrategia ofrece mejores resultados en cada contexto. De esta manera, el sistema aprenderá no solamente qué documentos recuperar, sino también cómo buscarlos, qué fuentes consultar, qué relaciones explorar, cuándo profundizar en una línea de investigación, cuándo cambiar de estrategia y cuándo existe evidencia suficiente para finalizar la recuperación. La finalidad sería disponer de una capa de recuperación capaz de proporcionar al sistema judicial de IA la información más completa, relevante y trazable posible antes de comenzar cualquier razonamiento jurídico.

Works Cited

“[2112.01488] ColBERTv2: Effective and Efficient Retrieval via Lightweight Late Interaction.”

arXiv, <https://arxiv.org/abs/2112.01488>. Accessed 26 September 2026.

“[2405.14831] HippoRAG: Neurobiologically Inspired Long-Term Memory for Large

Language Models.” *arXiv*, [https://arxiv.org/abs/2405.14831?](https://arxiv.org/abs/2405.14831) Accessed 27 September 2026.

“[2502.14802] From RAG to Memory: Non-Parametric Continual Learning for Large

Language Models.” *arXiv*, <https://arxiv.org/abs/2502.14802>. Accessed 27 September 2026.

“[2507.21892] Graph-R1: Towards Agentic GraphRAG Framework via End-to-end

Reinforcement Learning.” *arXiv*, <https://arxiv.org/abs/2507.21892>. Accessed 26 September 2026.

“conversación algoritmo RSI de Google.”

“Conversación estado del arte.”

<https://chatgpt.com/c/6ab7f0c6-71d4-83eb-bc99-e0dd3d92091d>.

“Dream-RSI: Recursive Self-Improvement through Evolving Worlds.” *arXiv*,

<https://arxiv.org/html/2609.14858v1>. Accessed 26 September 2026.

Microsoft. *Welcome - GraphRAG*, <https://microsoft.github.io/graphrag/>. Accessed 27

September 2026.

Robertson, Stephen, and Hugo Zaragoza. “The Probabilistic Relevance Framework: BM25

and Beyond Contents.” *City, University of London*,

https://www.staff.city.ac.uk/~sbrp622/papers/foundations_bm25_review.pdf.

Accessed 26 September 2026.