

Uso de IA

De acuerdo a desarrollar el sistema más preciso y completo posible, estudiamos la implementación de distintas arquitecturas.

Recuperación de la información correspondiente mediante RAGs multi-hop Agénticos.

Para poder aprovechar la mayor cantidad posible de documentación e incorporar de forma continua nuevos procedimientos, resoluciones y fuentes jurídicas, los modelos LLM de *ReJust* estarán acompañados por una arquitectura RAG agéntica y *multi-hop*. Su función será recuperar dinámicamente la información necesaria para cada caso antes de elaborar cualquier razonamiento o propuesta de resolución.

Como referencia de las capacidades que esperamos alcanzar (*“Conversación estado del arte de algoritmos RAGs”*) pueden considerarse arquitecturas actuales como Graph-R1 ([2507.21892] *Graph-R1: Towards Agentic GraphRAG Framework via End-to-end Reinforcement Learning*), en las que la recuperación deja de consistir en una única consulta estática. El agente puede analizar en qué estado se encuentra, teniendo en cuenta la pregunta inicial, la información recuperada hasta ese momento y los pasos realizados previamente, y decidir de forma iterativa cuál debe ser su siguiente acción: realizar una nueva consulta, profundizar sobre determinada información, explorar una relación concreta, consultar otra fuente o finalizar la búsqueda cuando considere que dispone de evidencia suficiente.

La recuperación combinaría distintas técnicas complementarias. Por una parte, se utilizarían métodos de recuperación léxica, como *BM25* (Robertson and Zaragoza), especialmente útiles para localizar términos jurídicos exactos, nombres, identificadores, artículos concretos o expresiones específicas. Estos métodos se complementarían con sistemas de recuperación densa y semántica, como *ColBERTv2* ([2112.01488] *ColBERTv2: Effective and Efficient Retrieval via Lightweight Late Interaction*), capaces de localizar documentos conceptualmente relacionados incluso cuando no emplean exactamente las mismas palabras.

Sobre estas técnicas se incorporarían arquitecturas de recuperación basadas en grafos, inspiradas en aproximaciones actuales como Microsoft GraphRAG (Microsoft) , HippoRAG ([2405.14831] *HippoRAG: Neurobiologically Inspired Long-Term Memory for Large Language Models*) o HippoRAG 2 ([2502.14802] *From RAG to Memory: Non-Parametric Continual Learning for Large Language Models*), así como en futuros algoritmos de construcción y exploración de grafos. La finalidad sería representar explícitamente las relaciones existentes entre procedimientos, personas, delitos, artículos legales, jurisprudencia, pruebas, informes periciales y resoluciones judiciales. De este modo, la recuperación no se limitaría a encontrar documentos individualmente similares, sino que permitiría realizar búsquedas multi-hop recorriendo relaciones entre distintas fuentes. Por ejemplo, el sistema podría localizar inicialmente un determinado tipo penal, recuperar las

resoluciones relacionadas con él, identificar qué sentencias son citadas por esas resoluciones y explorar posteriormente casos con hechos o circunstancias similares.

Destacar que los algoritmos mencionados representan únicamente ejemplos del estado actual de la tecnología. Al situar *ReJust* en el año 2030, asumimos la existencia de técnicas de recuperación considerablemente más avanzadas, capaces de alcanzar niveles muy elevados de cobertura de la información relevante para una consulta. El objetivo no sería garantizar matemáticamente la recuperación absoluta de toda la información existente, sino minimizar al máximo la posibilidad de omitir evidencia jurídicamente relevante.

Sobre esta capa de recuperación se situaría una arquitectura agéntica, potencialmente compuesta por distintos agentes o herramientas especializadas. Algunos componentes podrían encargarse de planificar la búsqueda, otros de consultar jurisprudencia, legislación o expedientes, otros de recorrer el grafo de conocimiento y otros de comprobar si la evidencia obtenida resulta suficiente o si es necesario continuar investigando, es decir, actuando como una “mezcla de expertos”. Una de las principales innovaciones de nuestra propuesta para 2030 sería que la propia estrategia de recuperación podría aprender y evolucionar con la experiencia. Para ello planteamos un mecanismo inspirado en Dream-RSI (“Dream-RSI: Recursive Self-Improvement through Evolving Worlds”). La idea sería aprovechar las trayectorias de búsqueda ejecutadas previamente para construir una memoria de experiencias de recuperación (“Conversación algoritmo RSI de Google”). Cada trayectoria almacenaría información sobre el estado inicial, las consultas realizadas, las fuentes exploradas, las acciones tomadas, la evidencia recuperada, el coste de la búsqueda y la calidad final del resultado. Estas experiencias permitirían crear un entorno de entrenamiento *offline* en el que nuevas políticas de recuperación pudieran evaluarse sin tener que repetir constantemente todas las consultas contra bases de datos y sistemas externos. El objetivo no sería sustituir la consulta de las fuentes originales, que continuaría siendo necesaria para garantizar que la información está actualizada y es trazable, sino aprender qué estrategia de búsqueda resulta más eficiente para cada tipo de problema.

Caso de uso:

«Encuentra todas las condenas asociadas a este individuo.»

El agente podría aprender que una búsqueda directa sobre determinadas bases de datos resulta suficiente. Sin embargo, ante una consulta como:

«Encuentra las condenas más similares a este caso, teniendo en cuenta los hechos, la fecha, el tipo penal, los agravantes y las circunstancias del acusado.»

el sistema podría activar automáticamente una estrategia de recuperación mucho más compleja, combinando búsqueda semántica, exploración del grafo, recuperación multi-hop, comparación temporal y consulta de múltiples fuentes.

En nuestro escenario de 2030, estas políticas habrían sido entrenadas sobre un conjunto extremadamente heterogéneo de tareas jurídicas, desde consultas directas hasta problemas que requieran múltiples pasos de razonamiento y recuperación. Un LLM actuaría además como componente encargado de evaluar y mejorar progresivamente la política de búsqueda, aprendiendo qué factores son relevantes para decidir la siguiente acción y qué estrategia ofrece mejores resultados en cada contexto. De esta manera, el sistema aprenderá no solamente qué documentos recuperar, sino también cómo buscarlos, qué fuentes consultar, qué relaciones explorar, cuándo profundizar en una línea de investigación, cuándo cambiar de estrategia y cuándo existe evidencia suficiente para finalizar la recuperación. La finalidad sería disponer de una capa de recuperación capaz de proporcionar al sistema judicial de IA la información más completa, relevante y trazable posible antes de comenzar cualquier razonamiento jurídico.

Visión por computador

Para analizar las pruebas audiovisuales de un procedimiento penal y detectar comportamientos potencialmente relevantes en entornos penitenciarios, ReJust incorporará un módulo de visión por computador aplicado principalmente a cámaras de videovigilancia (CCTV). Este módulo se apoyará en modelos Vision Transformer y Vision-Language Models, arquitecturas que actualmente constituyen una de las principales líneas de investigación para la comprensión semántica de imágenes y vídeo. En el escenario planteado para 2030, suponemos además que estos modelos habrán sido entrenados o adaptados con grandes cantidades de ejemplos representativos de comportamientos, interacciones y situaciones potencialmente violentas o sancionables.

Una arquitectura actual que puede servir como referencia consistiría en combinar estos modelos de visión con técnicas avanzadas de *Video Anomaly Detection* y sistemas RAG. El procesamiento podría dividirse en varias fases.

En primer lugar, se realizaría una segmentación temporal del vídeo, dividiéndolo en fotogramas o pequeños fragmentos temporales. Sobre ellos podrían aplicarse aproximaciones similares a LAVAD (“[2404.01014] Harnessing Large Language Models for Training-free Video Anomaly Detection”), donde un modelo visión-lenguaje genera descripciones textuales de lo que sucede en las imágenes y posteriormente un LLM analiza temporalmente estas descripciones, las refina y estima si los acontecimientos observados pueden considerarse anómalos. LAVAD resulta especialmente interesante porque demuestra que es posible realizar detección de anomalías aprovechando modelos pre entrenados sin tener que entrenar específicamente un nuevo detector para cada escenario.

Sin embargo, en sistemas de videovigilancia continua aparece un problema evidente: no es viable introducir horas de grabación completas dentro del contexto de un modelo. Para solucionarlo, el sistema incorporaría una memoria estructurada de eventos. En lugar de conservar todos los fotogramas, transformaría progresivamente el vídeo en representaciones compactas de los acontecimientos relevantes: qué personas aparecen,

qué objetos intervienen, qué acciones se realizan, dónde ocurren y durante qué intervalo temporal. Sobre esta memoria podría actuar un sistema RAG especializado en vídeo, encargado de recuperar únicamente aquellos fragmentos o eventos necesarios para resolver una consulta. En lugar de realizar una única recuperación, el sistema podría razonar sobre la información obtenida, detectar que falta contexto y ejecutar nuevas recuperaciones de forma iterativa. Una arquitectura actual que muestra esta dirección es Memory-enhanced Retrieval Augmentation for Long Video Understanding, que propone memorizar información global del vídeo, razonar sobre qué información necesita la consulta, recuperar los momentos relevantes y finalmente concentrar el análisis sobre ellos (“[2503.09149] Memory-enhanced Retrieval Augmentation for Long Video Understanding”). Esta separación entre memoria global y recuperación de momentos concretos permitiría trabajar con grabaciones de muchas horas sin tener que procesarlas íntegramente cada vez que se formula una consulta. Por ejemplo, ante una investigación sobre una agresión, el sistema podría recuperar primero el instante de la agresión, posteriormente buscar qué interacciones habían ocurrido entre las mismas personas minutos antes y, si fuera necesario, ampliar de nuevo la búsqueda hacia acontecimientos anteriores.

Para el funcionamiento online, donde las imágenes llegan continuamente desde las cámaras, sería necesario mantener además una memoria temporal del contexto reciente. Una referencia especialmente interesante es MoniTor, que procesa vídeo en streaming y utiliza estados anteriores y predicciones recientes para interpretar el fotograma actual. Su mecanismo está inspirado en las redes LSTM, conservando información relevante del pasado y utilizando una memoria dinámica para determinar si la secuencia reciente de acontecimientos puede representar una anomalía (“[2510.21449] MoniTor: Exploiting Large Language Models with Instruction for Online Video Anomaly Detection”). Por tanto, una acción no tendría que considerarse anómala únicamente por lo observado en un fotograma aislado. El sistema podría considerar la secuencia completa de acontecimientos. Por ejemplo, observar a una persona corriendo puede no contener información suficiente por sí solo; sin embargo, si previamente el sistema ha registrado una confrontación y segundos después detecta que una de las personas involucradas huye, el contexto temporal permite construir una interpretación mucho más rica de la situación.

Finalmente, esta memoria podría representarse mediante un grafo dinámico de eventos, conectando entidades y acontecimientos mediante nodos y relaciones. Podrían existir nodos como Persona_X, Persona_Y, Objeto_Z, Evento_1, Lugar_A o Instante_T, unidos mediante relaciones como participa_en, interactúa_con, porta, ocurre_en, precede_a o es_consecuencia_de. De esta manera, la información procedente de miles de fotogramas dejaría de representarse únicamente como una secuencia de imágenes y pasaría a convertirse en una estructura semántica consultable.




Figura 1: Ejemplo de representación de un evento con un grafo. Imagen generada por ChatGPT.

El RAG podría entonces recuperar no solo fragmentos audiovisuales aislados, sino también subgrafos completos de acontecimientos relacionados, permitiendo reconstruir temporalmente una situación, identificar relaciones entre personas y objetos y proporcionar al modelo de razonamiento un contexto mucho más compacto, interpretable y rico que el vídeo original.

Modelos Juez

Una vez recuperada toda la información pertinente, esta será proporcionada a un sistema de agentes LLM especializados en razonamiento jurídico, encargado de analizar conjuntamente los hechos del procedimiento, las pruebas disponibles, la legislación aplicable y la jurisprudencia recuperada. En lugar de depender exclusivamente del conocimiento almacenado en los parámetros del modelo, el razonamiento estará condicionado por la evidencia recuperada, de manera que las conclusiones alcanzadas deberán estar sustentadas por información concreta y verificable del expediente y de las fuentes jurídicas consultadas.

En nuestro escenario de 2030, suponemos modelos específicamente entrenados para el dominio jurídico mediante conjuntos de datos amplios y heterogéneos, sometidos además a procesos destinados a reducir sesgos, inconsistencias y diferencias injustificadas entre casos equivalentes. No asumimos una objetividad absoluta, sino un sistema diseñado para aplicar de forma consistente unos mismos criterios jurídicos ante circunstancias equivalentes.

La arquitectura podría estar formada por diferentes agentes especializados. Por ejemplo, un agente podría analizar los hechos y pruebas, otro estudiar la legislación aplicable, otro contrastar la jurisprudencia y precedentes similares, y otro actuar como agente crítico, buscando contradicciones, información omitida o argumentos que cuestionen la conclusión provisional. Finalmente, un agente de síntesis integraría estas perspectivas para elaborar una resolución estructurada y motivada. Esta incluiría no solamente la decisión propuesta y, cuando proceda, la pena correspondiente, sino también los hechos considerados probados, las normas aplicadas, los precedentes utilizados, los elementos que han influido en la decisión y el grado de incertidumbre existente.



Figura 2: Ejemplo de funcionamiento del sistema multi agente. Imagen generada por ChatGPT.

Módulo de explicabilidad y trazabilidad

Dado que las decisiones tomadas por *ReJust* podrían tener consecuencias extremadamente importantes sobre las personas afectadas, la explicabilidad y trazabilidad constituirían una parte central de la arquitectura y no únicamente una explicación generada posteriormente por el propio LLM. Cada afirmación relevante de la resolución deberá estar vinculada con la evidencia concreta que la sustenta. Gracias a la arquitectura RAG, el sistema podrá indicar qué fragmentos del expediente, artículos legales, informes periciales o resoluciones jurisprudenciales han sido utilizados para alcanzar cada conclusión. Las citas incluirían además información sobre su procedencia, fecha y versión, permitiendo reconstruir posteriormente el proceso seguido por el sistema.

Junto a esta trazabilidad documental podrían utilizarse técnicas de XAI , como SHAP o LIME, cuando existan componentes predictivos o clasificadores en los que resulte útil determinar qué variables han tenido mayor influencia sobre una determinada predicción. Sin embargo, estas técnicas no serían suficientes para explicar por sí solas el razonamiento completo de un sistema basado en LLM.

Por ello, *ReJust* incorporaría diferentes niveles de explicación:

- **Explicabilidad documental:** mostrar exactamente qué documentos y fragmentos sustentan cada afirmación.
- **Explicabilidad jurídica:** indicar qué normas, artículos y precedentes justifican la interpretación realizada.
- **Explicabilidad del modelo:** analizar, cuando sea técnicamente posible, qué variables o elementos de entrada han influido especialmente en determinadas predicciones.
- **Explicabilidad contrafactual:** permitir analizar cómo cambiaría la decisión si determinados hechos fueran diferentes. Por ejemplo, comprobar si la ausencia de un agravante concreto modificaría la pena propuesta.
- **Trazabilidad del proceso:** registrar qué agentes participaron, qué información recuperaron, qué hipótesis consideraron y qué comprobaciones realizaron antes de alcanzar la conclusión final.

Además, el sistema debería ser capaz de mostrar evidencia favorable y desfavorable a su propia conclusión. Si existe jurisprudencia contradictoria, pruebas con interpretaciones alternativas o incertidumbre sobre algún hecho relevante, dicha información deberá aparecer explícitamente en la explicación en lugar de ser ocultada por la respuesta final. El objetivo es que una resolución de *ReJust* no se limite a proporcionar una decisión, sino que permita reconstruir de manera auditable

- qué información conocía
- qué evidencia utilizó
- qué normas aplicó
- qué alternativas consideró
- por qué descartó otras interpretaciones
- cómo llegó finalmente a la resolución propuesta.

De esta manera, la explicabilidad no dependería únicamente de que el modelo sea capaz de generar una justificación aparentemente convincente, sino de que dicha justificación pueda ser contrastada con evidencias externas, verificables y trazables.

Trabajos Citados

“[2112.01488] ColBERTv2: Effective and Efficient Retrieval via Lightweight Late Interaction.”

arXiv, <https://arxiv.org/abs/2112.01488>. Accessed 26 September 2026.

“[2404.01014] Harnessing Large Language Models for Training-free Video Anomaly

Detection.” *arXiv*, <https://arxiv.org/abs/2404.01014>. Accessed 27 September 2026.

“[2405.14831] HippoRAG: Neurobiologically Inspired Long-Term Memory for Large

Language Models.” *arXiv*, <https://arxiv.org/abs/2405.14831>? Accessed 27 September 2026.

“[2502.14802] From RAG to Memory: Non-Parametric Continual Learning for Large

Language Models.” *arXiv*, <https://arxiv.org/abs/2502.14802>. Accessed 27 September 2026.

“[2503.09149] Memory-enhanced Retrieval Augmentation for Long Video Understanding.”

arXiv, <https://arxiv.org/abs/2503.09149>. Accessed 27 September 2026.

“[2503.09149] Memory-enhanced Retrieval Augmentation for Long Video Understanding.”

arXiv, <https://arxiv.org/abs/2503.09149>. Accessed 27 September 2026.

“[2507.21892] Graph-R1: Towards Agentic GraphRAG Framework via End-to-end

Reinforcement Learning.” *arXiv*, <https://arxiv.org/abs/2507.21892>. Accessed 26 September 2026.

“[2510.21449] MoniTor: Exploiting Large Language Models with Instruction for Online Video

Anomaly Detection.” *arXiv*, <https://arxiv.org/abs/2510.21449>. Accessed 27 September 2026.

ChatGPT. *Conversación sobre el estado del arte de ViT*,

<https://chatgpt.com/c/6ab902e7-6dfc-83ed-9239-a25a2c08ca43>.

“conversación algoritmo RSI de Google.”

“Conversación estado del arte.”

<https://chatgpt.com/c/6ab7f0c6-71d4-83eb-bc99-e0dd3d92091d>.

“Dream-RSI: Recursive Self-Improvement through Evolving Worlds.” *arXiv*,

<https://arxiv.org/html/2609.14858v1>. Accessed 26 September 2026.

Microsoft. *Welcome - GraphRAG*, <https://microsoft.github.io/graphrag/>. Accessed 27 September 2026.

Robertson, Stephen, and Hugo Zaragoza. "The Probabilistic Relevance Framework: BM25 and Beyond Contents." *City, University of London*, https://www.staff.city.ac.uk/~sbrp622/papers/foundations_bm25_review.pdf. Accessed 26 September 2026.