

Sprint 1: Especificación del proyecto



Rodrigo Mendoza García
Andrea Nicolás Romero
Pablo Medina Salmón
Jesús María Rodríguez García
Alberto Diez Álvarez
Lucas León Sigüero

Ética de Datos y de IA
Facultad de Informática
Universidad Complutense de Madrid

ReJust - Apoyo a decisiones penales y penitenciarias en España para 2030

ReJust es un sistema de IA que analiza información de procedimientos penales y de ejecución de penas para elaborar propuestas no vinculantes. Está diseñado como una herramienta cuya finalidad abarca facilitar la consulta de pruebas y fuentes jurídicas, señalar contradicciones y documentar la incertidumbre, pero manteniendo la decisión final en manos de la autoridad competente.

Propuesta y alcance

El proyecto se sitúa en España en 2030, en el contexto de DigitalJustice@2030 [4]. Conforme al art. 117.3 de la Constitución y a la Instrucción 2/2026 del CGPJ [1, 2], tanto la valoración de los hechos, la interpretación del Derecho y la resolución corresponderían siempre a jueces y tribunales. Se plantea como un sistema de alto riesgo, sujeto a supervisión humana, registro, evaluación de impacto y auditoría [3], dividido en dos grandes módulos:

- El análisis integral del expediente autorizado (con sus respectivas pruebas audiovisuales), la legislación y la jurisprudencia recaería sobre el módulo ReJust-Sentencia. Distinguiría hechos respaldados, controvertidos e información ausente, y presentaría alternativas y argumentos contrarios. Se limitaría al enjuiciamiento, excluyendo la instrucción, la jurisdicción de menores y los procedimientos ante el Tribunal del Jurado.
- ReJust-Seguimiento apoyaría la toma de decisiones durante la ejecución de penas (permisos, libertad condicional, beneficios penitenciarios, progresión de grado, régimen cerrado y sanciones), dentro de las competencias del art. 76 de la LOGP [5]. Su uso se dirigiría únicamente a personas condenadas por sentencia firme, sin perfilar a presos preventivos ni realizar seguimientos tras la excarcelación.

El despliegue respetaría las competencias penitenciarias de Cataluña y País Vasco. Ambos módulos compartirían infraestructura, pero separarían finalidades, permisos, datos y evaluación para impedir que la información penitenciaria condicionase indebidamente el juicio sobre la culpabilidad.

Actores y perspectiva elegida

En el ecosistema del proyecto intervienen múltiples actores: colectivos afectados (personas encausadas, internas y víctimas), operadores jurídicos y penitenciarios (jueces, órganos de vigilancia penitenciaria, Fiscalía, defensa, Juntas de Tratamiento y personal penitenciario), así como administraciones y reguladores (Ministerio de Justicia, CGPJ/CENDOJ, proveedor tecnológico, AESIA y AEPD). La perspectiva elegida para el desarrollo del proyecto es la de la persona interna. Se asume este rol por ser el sujeto que soporta las consecuencias directas del sistema y quien tiene menos control sobre sus datos. Su aceptación dependería de garantizar sus derechos fundamentales: conocer el uso del sistema, acceder a la información que le concierne, obtener explicaciones y poder rectificar e impugnar. La defensa debe poder discutir los datos y argumentos de la IA en igualdad de armas.

Funcionamiento y originalidad

El sistema combinaría recuperación léxica y semántica, grafos de conocimiento y búsquedas *multi-hop* sobre expedientes, normas y jurisprudencia, tomando arquitecturas agénticas como *Graph-R1* como referencia [13]. El razonamiento recaería en un sistema multiagente estructurado para analizar pruebas, comprobar normas, comparar precedentes, buscar contradicciones y sintetizar resultados, asumiendo siempre que la mera coincidencia entre agentes no sustituye a la evidencia verificable. En vídeo, se describirían acontecimientos observables y se enlazarían con el fragmento original [14]. Las mejoras de las estrategias de recuperación se estudiarían offline, tomando Dream-RSI como inspiración, con validación y versiones controladas antes del despliegue [15].

Los antecedentes incluyen COMPAS y RisCanvi en evaluación de riesgo [11, 12], PROMETEA en apoyo jurídico [9], los proyectos de la Cour de cassation e INRIA [8] y la

investigación sobre patrones de resoluciones [10]. La aportación de ReJust sería integrar estas funciones con búsqueda de contraargumentos, separación entre sentencia y seguimiento, trazabilidad y posibilidad de abstenerse. La viabilidad para 2030 seguiría condicionada a comprobar su rendimiento y sus garantías en el contexto judicial español.

Riesgos éticos y regulatorios

La protección de las personas afectadas condiciona todo el proyecto. Los siguientes riesgos deben abordarse desde el diseño y someterse a revisión continua durante su despliegue:

Privacidad y videovigilancia. Dado que ReJust-Seguimiento analizaría automáticamente cámaras de centros penitenciarios, lo que podría ampliar la vigilancia y sacar de contexto conductas cotidianas. Por ello, se delimitará estrictamente qué se analiza, con qué finalidad, los plazos de conservación y los controles de acceso. Se excluirían espacios íntimos o protegidos y cualquier inferencia algorítmica sobre emociones, intenciones o estados psicológicos. Los datos médicos, psicológicos o biométricos requerirían base jurídica, necesidad estricta y acceso restringido; la telemetría continua no se incorporaría por defecto [6]. Los datos reales de cada caso no alimentarían automáticamente el entrenamiento.

Sesgos y discriminación. Las decisiones anteriores, los informes penitenciarios y los modelos de riesgo pueden reproducir desigualdades históricas. Una buena precisión general no basta: se deberá auditar qué personas, grupos y contextos concentran los fallos del sistema. Origen, barrio, renta, estructura familiar, educación o empleo no actuarán como factores de culpabilidad, peligrosidad, reincidencia o pena. Asimismo se revisarán variables que actuaran como sustitutos de esos atributos. Todo ello requerirá auditorías independientes y la suspensión del sistema ante diferencias injustificadas [11, 12].

Transparencia y explicabilidad. Cada recomendación mostrará la información exacta utilizada, los factores ponderados, las evidencias favorables y contrarias, las fuentes originarias y su grado de incertidumbre. El objetivo es que el juez y las partes puedan reconstruir y debatir el razonamiento jurídico [7]. En el análisis audiovisual, se separarán las observaciones objetivas de las hipótesis y la valoración jurídica, con la premisa de que una mera correlación temporal no demuestra, por sí sola, causalidad, intención ni culpabilidad.

Errores del sistema: ReJust podría omitir resoluciones relevantes, utilizar información desactualizada o malinterpretar el expediente. Para evitarlo, el sistema deberá consultar fuentes jurídicas autorizadas, comprobar la vigencia temporal de las normas, verificar las citas y enlazar cada afirmación con su fuente original. Ante información insuficiente o contradictoria, la IA tendrá la directriz estricta de señalarlo, solicitar aclaraciones al operador o abstenerse de emitir una recomendación.

Supervisión humana. Una propuesta extensa y bien redactada puede parecer más fiable de lo que realmente es y propiciar su aceptación automática. Para evitarlo la autoridad competente necesitaría formación, tiempo para revisar y capacidad de poder modificar o rechazar la recomendación. La resolución exigiría motivación humana propia; una firma no bastaría como supervisión. No habría decisiones automáticas sobre la libertad y la persona afectada conservará el derecho a impugnar los datos y argumentos utilizados [1, 2, 3].

Evaluación y condiciones de uso

El rendimiento de ReJust no se justificará por el simple ahorro de tiempo o por su coincidencia con resoluciones históricas. Su validez se medirá por la recuperación exhaustiva de pruebas (incluyendo las contrarias), la corrección de las citas, la reducción de falsas alarmas u omisiones, la calidad de las explicaciones generadas y la distribución equitativa de los errores entre distintos grupos. Además, se auditarán periódicamente las reclamaciones e impugnaciones derivadas de su uso.

ReJust solo sería aceptable si mejora la revisión de la información sin reducir ninguna garantía procesal. La reutilización de datos requeriría una base jurídica propia y las recomendaciones deberían ser siempre comprensibles y rebatibles en sala. Si no se pudiera garantizar la privacidad, la ausencia de discriminación injustificada, la explicabilidad o la supervisión humana efectiva, se suspendería el módulo afectado.

Referencias

- [1] Cortes Generales (1978). Constitución Española, arts. 24, 25 y 117. BOE.
- [2] Consejo General del Poder Judicial (2026). Instrucción 2/2026, sobre la utilización de sistemas de inteligencia artificial en el ejercicio de la actividad jurisdiccional. BOE-A-2026-2205.
- [3] Parlamento Europeo y Consejo de la Unión Europea (2024). Reglamento (UE) 2024/1689 por el que se establecen normas armonizadas en materia de inteligencia artificial. EUR-Lex.
- [4] Comisión Europea (2025). Communication on DigitalJustice@2030. Comisión Europea.
- [5] Jefatura del Estado (1979). Ley Orgánica 1/1979, de 26 de septiembre, General Penitenciaria, art. 76. BOE.
- [6] Jefatura del Estado (2021). Ley Orgánica 7/2021, de protección de datos personales tratados para fines penales y de ejecución de sanciones penales. BOE.
- [7] Comisión Europea para la Eficacia de la Justicia (CEPEJ) (2018). European Ethical Charter on the Use of Artificial Intelligence in Judicial Systems and their Environment. Consejo de Europa.
- [8] Cour de cassation (2023). Les projets d'intelligence artificielle: colaboración con INRIA para similitud y divergencias jurisprudenciales. Cour de cassation.
- [9] Estevez, E., Fillottrani, P. y Linares Lejarraaga, S. (2020). PROMETEA: Transformando la administración de justicia con herramientas de inteligencia artificial. Banco Interamericano de Desarrollo. doi:10.18235/0002378.
- [10] Medvedeva, M., Vols, M. y Wieling, M. (2020). "Using machine learning to predict decisions of the European Court of Human Rights". Artificial Intelligence and Law, 28, 237–266. doi:10.1007/s10506-019-09255-y.
- [11] Angwin, J., Larson, J., Mattu, S. y Kirchner, L. (2016). "Machine Bias". ProPublica. Artículo.
- [12] Generalitat de Catalunya / Dribia Data Research (2024). Informe Tiresias. Auditoria de l'algorisme RisCanvi — Resum executiu. Informe.
- [13] Luo, D. et al. (2025). "Graph-R1: Towards Agentic GraphRAG Framework via End-to-end Reinforcement Learning". arXiv:2507.21892. arXiv.
- [14] Zanella, L. et al. (2024). "Harnessing Large Language Models for Training-free Video Anomaly Detection (LAVAD)". arXiv:2404.01014. arXiv.
- [15] Dream-RSI: Recursive Self-Improvement through Evolving Worlds (2026). arXiv:2609.14858. arXiv.