Sprint 2: Desafíos Éticos de la IA



Rodrigo Mendoza García
Andrea Nicolás Romero
Pablo Medina Salmón
Jesús María Rodríguez García
Alberto Diez Álvarez
Lucas León Siguero

Ética de Datos y de IA
Facultad de Informática
Universidad Complutense de Madrid

ReJust - Apoyo a decisiones penales y penitenciarias en España para 2030

Personalización

La personalización de ReJust se limitará a la interacción con el sistema (idioma, accesibilidad, presentación de resultados y filtros reversibles), sin modificar los criterios jurídicos según las preferencias o historial del usuario. La legislación aplicable, jurisprudencia y estimaciones de riesgo no podrán adaptarse al perfil del operador, garantizando un análisis idéntico ante el mismo expediente. Se prohíbe la creación de perfiles basados en ideologías o decisiones previas, así como el cruce de historiales entre ReJust-Sentencia y ReJust-Seguimiento.

Para evitar cámaras de eco jurídicas, el sistema mostrará precedentes y argumentos contrarios relevantes, aunque no coincidan con las preferencias habituales del usuario. Asimismo, para reducir el *automation bias* y la dependencia excesiva, se priorizará la presentación de evidencias, fuentes, contraargumentos e incertidumbre antes de mostrar una síntesis, exigiendo siempre supervisión humana efectiva. Cualquier adaptación algorítmica requerirá auditoría previa, rigiéndose por el principio inquebrantable de: «personalizar la interacción, no el criterio jurídico».

Riesgos Éticos:

- **Impacto a gran escala y amplificación de errores**

Si ReJust llegara a implantarse de forma generalizada en numerosos juzgados o se extendiera internacionalmente, sus efectos podrían alcanzar a millones de personas. Por ello, la escala debe considerarse un riesgo ético propio y no una simple cuestión técnica; una tasa de error reducida no implica necesariamente un impacto pequeño. Un defecto en la recuperación de pruebas o en la interpretación normativa podría repetirse y perjudicar de forma sistemática a determinados colectivos. Para limitarlo, ReJust se implantaría progresivamente, con auditorías de equidad, supervisión humana efectiva, mecanismos de suspensión técnica y trazabilidad absoluta para revisar los procedimientos potencialmente afectados (Anexo II).

Mejoras respecto al debate

- Identidad y Marco Legal: ReJust es un proyecto impulsado por el Gobierno, lo que justifica las reformas legales necesarias para su implantación en 2030. Su propósito es centralizar la información para asistir al juez, garantizando que el sistema informa, pero no influencia la decisión final, respetando así la independencia judicial (Instrucción 2/2026 del CGPJ; Carta Ética Europea de la CEPEJ, 2018).

-Gestión de Vídeo y Privacidad: Se aplica un enfoque de "Privacidad desde el Diseño" (Anexo I). Se entrena con datos sintéticos y actores para no exponer a internos reales. Aplica *Pose Estimation* para analizar movimientos ignorando rasgos faciales y garantizando el anonimato absoluto, con difuminado irreversible en metraje real. Se cumple la ley borrando el vídeo bruto a los 30 días, conservando únicamente metadatos textuales para el historial longitudinal. El sistema adopta un enfoque positivo, detectando también buenas conductas para apoyar beneficios penitenciarios.

-Exclusión del Jurado Popular: El uso se limita a jueces por su formación técnica y

jurídica, necesaria para evitar el sesgo de automatización (*overreliance*) y la influencia indebida, riesgos inaceptables en un jurado popular (Buçinca, Malaya y Gajos, 2021).

-Recuperación Exhaustiva de Pruebas: Se exige como requisito indispensable recuperar y mostrar siempre evidencias a favor y en contra, garantizando un borrador neutral que reduzca el "ruido" y los sesgos en la evaluación final (Kahneman, Sibony y Sunstein, 2021; NIST AI RMF, 2023).

-Principio de Neutralidad Probatoria: La arquitectura tiene bloqueada la capacidad de sugerir penas o fallos (Reglamento UE 2024/1689 de IA). Opera estrictamente como asistente documental, presentando pruebas contradictorias con idéntica jerarquía visual para asegurar que la resolución emane exclusivamente del juez.

Reflexiones sobre posturas macro

La intervención de la IA en la justicia penal enfrenta cuatro visiones: la postura *tecnooptimista* defiende que reduce el "ruido" y la disparidad judicial (Kahneman et al., 2021; Kleinberg et al., 2018); la *regulacionista* (Unión Europea) la admite como sistema de alto riesgo bajo supervisión (Reglamento UE 2024/1689; CEPEJ, 2018); la *crítica* advierte que automatiza desigualdades históricas sobre colectivos vulnerables (O'Neil, 2016; Eubanks, 2018); y la *humanista* sostiene que predecir el riesgo de un humano atenta contra su dignidad (Kant, 1785/2012; AI Act art. 5.1.d).

Nuestro grupo adopta una postura **regulacionista exigente** que incorpora las objeciones críticas y humanistas. Cumplir la normativa no basta: ReJust debe demostrar que mejora las decisiones sin trasladar costes a quienes menos pueden defenderse. Por ello, proponemos desplegar primero ReJust-Sentencia y condicionar ReJust-Seguimiento a un piloto con evaluación independiente (participando la sociedad civil y el Mecanismo Nacional de Prevención de la Tortura). El éxito no se medirá por rapidez, sino comparando sus garantías con la inversión equivalente en personal judicial. Si no supera esa comparación, se retirará.

Robustez.

Planteamos diez casos límite sobre jailbreak, sesgos, desactualización y ambigüedad. Para mitigar instrucciones ocultas [Greshake, arXiv:2302.12173], el diseño separa los módulos de Sentencia y Seguimiento, restringe accesos y verifica citas normativas en BOE y CENDOJ. Evita perfiles discriminatorios y mantiene pruebas de descargo y contraargumentos. Ante información ambigua, el sistema distinguirá hechos de hipótesis, explicará la incertidumbre o se abstendrá. Antes de cada actualización, se exigen pruebas adversarias, contrafactuales y evaluación externa de robustez [arXiv:2307.02483], bloqueando el despliegue ante cualquier regresión. Estas salvaguardas reducen riesgos, pero no eliminan el sesgo de automatización: la supervisión humana sigue siendo imprescindible.

Mockup y Explicabilidad por capas

- Mockup: Prototipos visuales actualizados incluidos en el Anexo IV.
- Explicabilidad: Modelos de transparencia estructural en el Anexo V

Referencias

- Unión Europea (2024). Reglamento (UE) 2024/1689 — AI Act.
- CGPJ (2026). Instrucción 2/2026 sobre utilización de IA en la actividad jurisdiccional.
- CCJE (2023). Opinion No. 26: Moving forward: the use of assistive technology in the judiciary.
- Buçinca, Z., Malaya, M. B. y Gajos, K. Z. (2021). To Trust or to Think: Cognitive Forcing Functions Can Reduce Overreliance on AI.
- Areeb, Q. M. et al. (2023). Filter bubbles in recommender systems: Fact or fallacy—A systematic review.
- OpenAI (2026). Conversación con ChatGPT utilizada como apoyo para desarrollar la personalización de ReJust.
- Greshake, K. et al. (2023). Not what you've signed up for: Compromising Real-World LLM-Integrated Applications with Indirect Prompt Injection.
- arXiv:2302.12173. Wei, A., Haghtalab, N. y Steinhardt, J. (2023). Jailbroken: How Does LLM Safety Training Fail? NeurIPS 2023.
- arXiv:2307.02483. Parlamento Europeo y Consejo de la Unión Europea (2024). Reglamento (UE) 2024/1689 de Inteligencia Artificial, art. 15.
- **[1] Cortes Generales (1978). Constitución Española.** Artículos 18 y 24.
- https://www.boe.es/buscar/act.php?id=BOE-A-1978-31229
- **Relación con ReJust.** Fundamenta la protección de la intimidad y las garantías relacionadas con el derecho de defensa.
- **[2] Secretaría General de Instituciones Penitenciarias (2022). Instrucción 4/2022, de 28 de julio, sobre tratamiento de datos obtenidos mediante videovigilancia penitenciaria.**
- https://derechopenitenciario.com/wp-content/uploads/2022/08/i-4-2022_videovigilancia11.pdf
- **Relación con ReJust.** Principal referencia para los plazos de conservación, las excepciones, el acceso a grabaciones y la cadena de custodia.
- **[3] Jefatura del Estado (2018). Ley Orgánica 3/2018, de Protección de Datos Personales y garantía de los derechos digitales.** Artículo 22.
- https://www.boe.es/buscar/act.php?id=BOE-A-2018-16673
- **Relación con ReJust.** Establece el régimen general de videovigilancia, que debe distinguirse del tratamiento penitenciario sujeto a normativa específica.
- **[4] Jefatura del Estado (2021). Ley Orgánica 7/2021, de protección de datos personales tratados para fines penales y de ejecución de sanciones penales.**
- https://www.boe.es/buscar/act.php?id=BOE-A-2021-8806
- **Relación con ReJust.** Permite justificar los requisitos de licitud, finalidad, seguridad y evaluación de impacto del tratamiento.
- **[5] Parlamento Europeo y Consejo de la Unión Europea (2024). Reglamento (UE) 2024/1689 de Inteligencia Artificial.**
- https://eur-lex.europa.eu/eli/reg/2024/1689/oj?locale=es
- **Relación con ReJust.** Aporta el marco para evaluar los requisitos aplicables a los sistemas de IA de alto riesgo.
- **[6] Defensor del Pueblo (2021). *Derechos de los internos en los centros penitenciarios*. Recomendación de 19 de agosto de 2021.**
- https://www.defensordelpueblo.es/resoluciones/derechos-de-los-internos-en-centros-penitenciarios-4/
- **Relación con ReJust.** Respalda la importancia de utilizar las grabaciones como medio de prueba para proteger los derechos de las personas internas.

- **[7] Agencia Española de Protección de Datos (2026). *La AEPD señala las garantías para incorporar inteligencia artificial a los sistemas de videovigilancia*. 6 de octubre de 2026.**
- https://www.aepd.es/prensa-y-comunicacion/notas-de-prensa/aepd-sennala-garantias-para-incorporar-ia-a-sistemas-videovigilancia
- **Relación con ReJust.** Aporta una referencia actual sobre la necesidad de incorporar garantías al añadir IA a sistemas de videovigilancia. Se refiere a proyectos municipales, por lo que se utiliza como orientación y no como regulación penitenciaria específica.
- National Institute of Standards and Technology (2023). *Artificial Intelligence Risk Management Framework AI RMF 1.0*.
- https://www.nist.gov/itl/ai-risk-management-framework
- Comisión Europea para la Eficiencia de la Justicia (2018). *Carta ética europea sobre el uso de la inteligencia artificial en los sistemas judiciales*.
- https://rm.coe.int/ethical-charter-en-for-publication-4-december-2018/16808f699c
- Parlamento Europeo y Consejo de la Unión Europea (2024). *Reglamento UE 2024/1689 de Inteligencia Artificial*.
- https://eur-lex.europa.eu/eli/reg/2024/1689/oj?locale=es
-
- ProPublica (2016). *Machine Bias*. Ejemplo utilizado para ilustrar por qué la exactitud global no basta para evaluar la distribución de los errores.
- https://www.propublica.org/article/machine-bias-risk-assessments-in-criminal-sentencing
- **CONVERSACIÓN CON IA QUE NOS HA AYUDADO EN ESTE DOCUMENTO:**

  https://chatgpt.com/share/6ac8f881-ae98-83eb-b40b-85a6bec18a67?no_universal_links=1

- CEPEJ (2018). Carta Ética Europea sobre el uso de la inteligencia artificial en los sistemas judiciales y su entorno.
- Eubanks, V. (2018). Automating Inequality: How High-Tech Tools Profile, Police, and Punish the Poor. St. Martin's Press.
- Kahneman, D., Sibony, O. y Sunstein, C. R. (2021). Ruido: Un fallo en el juicio humano. Debate.
- Kant, I. (1785/2012). Fundamentación para una metafísica de las costumbres. Alianza Editorial.
- Kleinberg, J., Lakkaraju, H., Leskovec, J., Ludwig, J. y Mullainathan, S. (2018). Human Decisions and Machine Predictions. The Quarterly Journal of Economics, 133(1), 237–293.
- O'Neil, C. (2016). Weapons of Math Destruction. Crown.