

Anexo II

Riesgos generales e impacto ético a gran escala de ReJust

1 Alcance del análisis

ReJust se plantea como una herramienta pública de apoyo para dos ámbitos especialmente sensibles. ReJust-Sentencia facilitaría la consulta de pruebas, normativa y jurisprudencia, mientras que ReJust-Seguimiento ayudaría a organizar y revisar información penitenciaria. En ambos módulos, los resultados podrían influir en actuaciones relacionadas con la libertad y los derechos de las personas.

El escenario de cientos de millones de personas debe entenderse como una prueba de impacto a gran escala, no como una previsión inmediata de uso en España. La cuestión ética es qué ocurriría si el sistema se extendiera a numerosas instituciones o países y un mismo problema comenzara a repetirse.

2 Amplificación y repetición de errores

Un porcentaje de error aparentemente pequeño puede afectar a muchas personas cuando el volumen de procedimientos es elevado. Además, no todos los fallos tienen la misma gravedad. Una referencia incorrecta detectada antes de decidir no tiene las mismas consecuencias que omitir una prueba favorable o presentar información incompleta que influya en una decisión.

El riesgo más importante es que el error no sea aleatorio, sino estructural. Si ReJust utilizara una versión desactualizada de una norma, recuperase peor determinados documentos o concediera demasiado peso a ciertos informes, el mismo defecto podría reproducirse en numerosos juzgados o centros penitenciarios. La apariencia de coherencia del sistema podría dificultar su detección.

También debe evitarse un ciclo de retroalimentación en el que decisiones influenciadas por ReJust se reutilicen posteriormente como datos de entrenamiento sin validación independiente. Ese proceso podría convertir un error inicial en un patrón cada vez más consolidado.

- Controlar las versiones del modelo, las fuentes jurídicas y las actualizaciones.
- Evaluar la frecuencia y la gravedad de los errores, no solo la precisión media.
- Impedir el aprendizaje automático a partir de decisiones anteriores sin una revisión independiente.
- Suspender temporalmente una función cuando aparezca un patrón de fallos sistemáticos.

3 Impacto desigual y discriminación sistemática

Una precisión global elevada no garantiza que ReJust funcione igual para todas las personas. El sistema podría cometer más errores con documentación traducida, expedientes poco habituales, información incompleta o situaciones escasamente representadas durante su desarrollo. Las desigualdades históricas presentes en los datos también podrían reproducirse mediante variables aparentemente neutrales.

Los efectos podrían ser especialmente graves para personas con barreras lingüísticas, pocos recursos económicos, discapacidad, problemas de salud mental o pertenecientes a colectivos históricamente discriminados. Estos grupos no solo podrían sufrir más errores, sino disponer de menos medios para detectarlos e impugnarlos.

- Analizar la distribución de errores por colectivos, centros y tipos de procedimiento cuando exista base jurídica para hacerlo.
- Utilizar datos de evaluación variados y revisar variables que puedan actuar como indicadores indirectos de características protegidas.
- Incorporar auditorías independientes y limitar el sistema si aparecen diferencias injustificadas que no puedan corregirse.

4 Confianza excesiva y desigualdad entre instituciones

Cuando una herramienta funciona habitualmente bien, los profesionales pueden acostumbrarse a aceptar sus resultados sin comprobarlos de forma suficiente. Esta confianza excesiva, conocida como sesgo de automatización, permitiría que una omisión o recomendación incorrecta se repitiese en muchos procedimientos aunque formalmente existiera supervisión humana.

La supervisión deberá ser efectiva. ReJust mostrará las fuentes utilizadas, permitirá corregir o ampliar los resultados y no servirá como única base de una decisión que afecte a derechos. También deberá registrarse el grado de aceptación de sus recomendaciones para comprobar si, en la práctica, el criterio profesional está siendo sustituido por el sistema.

La calidad del funcionamiento también puede variar entre instituciones. Un juzgado con expedientes completamente digitalizados no ofrece las mismas condiciones que otro con documentación incompleta, y lo mismo ocurre entre centros penitenciarios con distintos recursos y sistemas de información. ReJust deberá poder abstenerse cuando los datos no alcancen una calidad mínima, evitando que la protección de una persona dependa del centro en el que se encuentre.

5 Fallos compartidos seguridad y concentración del daño

El uso del mismo sistema en numerosas instituciones concentra el riesgo. Una actualización defectuosa, una fuente jurídica desactualizada o una vulnerabilidad de seguridad podrían afectar simultáneamente a toda la red. Cuanto mayor sea el despliegue, mayor será el número potencial de personas perjudicadas por un único fallo técnico.

- Probar las actualizaciones en entornos limitados antes de extenderlas.
- Mantener separados los datos, permisos y finalidades de ReJust-Sentencia y ReJust-Seguimiento.
- Realizar auditorías de seguridad y conservar registros de accesos y operaciones.
- Permitir detener una funcionalidad concreta sin paralizar todo el sistema.
- Convertir un fallo detectado en una institución en una alerta para revisar el resto de despliegues.

6 Identificación reparación y revisión de casos

Corregir el algoritmo no resuelve por sí solo el daño ya causado. Si se descubre que una versión de ReJust omitía sistemáticamente una clase de pruebas o generaba recomendaciones inadecuadas, deberá analizarse qué procedimientos pudieron verse afectados.

La trazabilidad permitirá saber qué versión del sistema se utilizó, qué fuentes consultó y qué información presentó en cada caso. El protocolo de incidentes deberá contemplar la suspensión de la función, la investigación del error, la identificación de personas potencialmente afectadas y la activación de los mecanismos de revisión o reparación que correspondan. No implica anular automáticamente las decisiones, sino permitir que sus efectos puedan investigarse.

7 Videovigilancia

La selección incorrecta de imágenes podría contribuir a la amplificación de errores si ReJust omitiera evidencias relevantes o destacara fragmentos sin suficiente contexto. No obstante, los riesgos de privacidad, conservación, integridad y acceso a las grabaciones ya se desarrollan en el **Anexo I Videovigilancia penitenciaria en ReJust-Seguimiento**. Para evitar repeticiones, este anexo se limita a recordar que el componente audiovisual no atribuye responsabilidades y siempre exige la revisión del material original.

8 Medidas para una implantación responsable

ReJust no se desplegaría simultáneamente en todas las instituciones. Comenzaría con proyectos piloto y solo se ampliaría después de comprobar su funcionamiento en contextos diferentes. Las medidas principales serían:

- Implantación progresiva para detectar problemas antes de ampliar el sistema.
- Auditorías periódicas de rendimiento, equidad, seguridad y calidad de los datos.
- Supervisión humana efectiva y formación específica para los profesionales.
- Monitorización continua y mecanismos de suspensión ante fallos sistemáticos.
- Trazabilidad suficiente para identificar y revisar los procedimientos potencialmente afectados.

Conclusión

El principal riesgo de la implantación masiva de ReJust no es únicamente que cometa errores, sino que pueda repetirlos de forma coherente y extenderlos por numerosas instituciones. Una tasa de fallo pequeña puede tener un impacto considerable cuando afecta a miles de procedimientos, especialmente si los errores se concentran en personas vulnerables o difíciles de representar adecuadamente en los datos.

Por ello, la expansión del sistema deberá depender de su capacidad para detectar, limitar y corregir daños. La precisión y el ahorro de tiempo no serán suficientes si ReJust no mantiene una supervisión humana real, permite investigar los fallos y ofrece mecanismos para revisar los casos potencialmente perjudicados.

Referencias de apoyo

National Institute of Standards and Technology (2023). *Artificial Intelligence Risk Management Framework AI RMF 1.0*.
<https://www.nist.gov/itl/ai-risk-management-framework>

Comisión Europea para la Eficiencia de la Justicia (2018). *Carta ética europea sobre el uso de la inteligencia artificial en los sistemas judiciales*.

<https://rm.coe.int/ethical-charter-en-for-publication-4-december-2018/16808f699c>

Parlamento Europeo y Consejo de la Unión Europea (2024). *Reglamento UE 2024/1689 de Inteligencia Artificial*.
<https://eur-lex.europa.eu/eli/reg/2024/1689/oj?locale=es>

ProPublica (2016). *Machine Bias*. Ejemplo utilizado para ilustrar por qué la exactitud global no basta para evaluar la distribución de los errores.

<https://www.propublica.org/article/machine-bias-risk-assessments-in-criminal-sentencing>