ReJust — Sprint 3: Implicaciones Sociales de la IA



Rodrigo Mendoza García
Andrea Nicolás Romero
Pablo Medina Salmón
Jesús María Rodríguez García
Alberto Diez Álvarez
Lucas León Siguero

Ética de Datos y de IA
Facultad de Informática
Universidad Complutense de Madrid

1. Mejoras respecto al Sprint 2

En este sprint hemos revisado ReJust a partir de las críticas recibidas en el debate del 22 de octubre, con el objetivo de corregir los puntos más débiles del proyecto y reforzar sus garantías.

El principal cambio afecta a **ReJust-Seguimiento**. En el Sprint 2 proponíamos analizar continuamente las cámaras de las zonas comunes. Ahora hemos eliminado ese análisis continuo y limitado el uso de *Pose Estimation* a búsquedas autorizadas de acontecimientos observables en grabaciones relacionadas con incidentes, denuncias o procedimientos. La información sobre talleres y actividades se obtendrá de los registros administrativos.

También hemos corregido otras cuestiones: *Pose Estimation* se considera una técnica de minimización, no de anonimización absoluta; los registros tendrán plazos de conservación limitados y las detecciones deberán ser verificadas por profesionales. Además, el uso judicial y sus registros quedarán bajo el control del CGPJ para proteger la independencia judicial.

Estas mejoras se desarrollan en el **Anexo I - Mejoras y correcciones tras el debate**.

2. Riesgos y plausibilidad

Hemos identificado **diez riesgos principales**, como la omisión de pruebas favorables, las citas jurídicas incorrectas, los sesgos discriminatorios, los errores audiovisuales y la dependencia excesiva de la IA. Para cada uno hemos establecido su gravedad, probabilidad estimada, prevención y contingencia.

Proponemos controles durante el desarrollo, auditorías independientes y revisiones tras las actualizaciones. Si aparece un fallo grave, también se comprobarán los procedimientos anteriores que puedan haberse visto afectados. Todo ello se recoge en el **Anexo III - Gestión de riesgos y medidas de control**.

Respecto a la viabilidad para 2030, ReJust-Sentencia es la parte más plausible porque utiliza tecnologías existentes, aunque todavía pueden producirse errores y omisiones. ReJust-Seguimiento depende también de la calidad de los registros penitenciarios. Su función audiovisual sigue siendo la más incierta y solo se activará con habilitación jurídica suficiente, evaluación de impacto y validación real. Estas limitaciones se analizan en el **Anexo II - Análisis de plausibilidad**.

3. Límites, emergencias y rendición de cuentas

Hemos establecido **cinco líneas rojas**: ReJust no propondrá decisiones judiciales o penitenciarias, no calculará puntuaciones individuales de peligrosidad, no usará reconocimiento facial ni inferencia de emociones, no valorará la credibilidad de las personas y no adaptará el criterio jurídico al juez ni aprenderá de sus decisiones.

Ante un fallo grave, cualquier juez podrá dejar de utilizar ReJust en su caso y la institución responsable podrá suspender el módulo entero. Se pasará a modo manual, se avisará a las personas afectadas y se revisarán las ejecuciones anteriores. Solo se reanudará con una versión corregida y validada; si no es posible, se retirará el componente.

Quien toma y firma la decisión sigue siendo responsable, nunca la IA. La persona afectada podrá saber si se usó ReJust, acceder al registro y a las fuentes, recibir una explicación, recurrir y reclamar ante el CGPJ, la AEPD o el Defensor del Pueblo, según el caso. Si se confirma un error, se corregirán los registros y se revisarán los casos afectados.

Todo esto se desarrolla en el **Anexo IV - Límites, emergencias y rendición de cuentas**.

4. Usuarios, colectivos vulnerables y auditoría de sesgos

Los principales usuarios serán jueces, Juntas de Tratamiento y personal autorizado. Sin embargo, las consecuencias afectarán especialmente a las personas encausadas e internas, que tienen menos control sobre la información utilizada.

Hemos analizado la situación de personas extranjeras, personas con trastornos mentales, mujeres y personas sin recursos o arraigo, incluyendo casos de interseccionalidad, donde varias circunstancias pueden aumentar las desigualdades. Este análisis se desarrolla en el **Anexo V - Usuarios y colectivos vulnerables**.

También proponemos auditorías para detectar sesgos en los datos, modelos, interfaces y decisiones de diseño. En ReJust-Sentencia comprobaremos la recuperación equilibrada de pruebas y realizaremos pruebas contrafactuales cuando la característica modificada no sea jurídicamente relevante. En ReJust-Seguimiento revisaremos las desigualdades entre centros y los errores de *Pose Estimation* según las condiciones de grabación y movilidad.

Si se detectan sesgos graves, investigaremos su origen, corregiremos los problemas y revisaremos los casos afectados. El procedimiento aparece en el **Anexo VI - Auditoría de sesgos**.

5. Equidad y evaluación final

La equidad no se medirá únicamente por la precisión general, sino también por cómo se distribuyen los errores entre colectivos. Mantendremos la presentación equilibrada de pruebas, la accesibilidad y la prohibición de interpretar la ausencia de registros favorables como algo negativo. Esto se desarrolla en el **Anexo VII - Métricas de equidad y mínimos autoimpuestos**. Sus porcentajes se plantean como objetivos iniciales para el piloto y deberán revisarse con muestras suficientes, intervalos de confianza y comparación con el procedimiento sin IA.

Finalmente, proponemos implantar ReJust de forma progresiva, empezando por las funciones documentales. Su utilidad deberá compararse con alternativas sin IA, incluida la inversión equivalente en personal judicial.

Nuestra conclusión es que ReJust debe poder corregirse, limitarse o retirarse si no cumple las garantías previstas. La prioridad será proteger los derechos de las personas, no implantar tecnología por el simple hecho de disponer de ella.

Referencias

[1] CGPJ (2026). *Instrucción 2/2026 sobre el uso de IA en la actividad jurisdiccional.* https://www.boe.es/buscar/doc.php?id=BOE-A-2026-2205

[2] Unión Europea (2024). *Reglamento (UE) 2024/1689 de Inteligencia Artificial*, y modificaciones posteriores. https://eur-lex.europa.eu/eli/reg/2024/1689/oj

[3] Jefatura del Estado (2021). *Ley Orgánica 7/2021 de protección de datos para fines penales.* https://www.boe.es/buscar/act.php?id=BOE-A-2021-8806

[4] Jefatura del Estado (2022). *Ley 15/2022, integral para la igualdad de trato y la no discriminación.* https://www.boe.es/buscar/act.php?id=BOE-A-2022-11589

[5] NIST (2023). *Artificial Intelligence Risk Management Framework 1.0.* https://doi.org/10.6028/NIST.AI.100-1

[6] Dahl, M. et al. (2024). *Large Legal Fictions: Profiling Legal Hallucinations in Large Language Models.* https://doi.org/10.1093/jla/laae003

Documentación complementaria: Anexos I–VII del Sprint 3 y documentación de los Sprints 1 y 2.

Uso de IA: enlaces públicos a las conversaciones utilizadas durante el proyecto.