Anexo — Auditoría de sesgos en ReJust

1. Objetivo

Aunque ReJust no tome decisiones automáticamente, puede introducir sesgos en la información que recupera, analiza o presenta. Esto podría provocar que determinados colectivos recibieran información menos completa o que sus circunstancias se interpretaran de manera desfavorable.

Por ello, proponemos realizar auditorías antes de implantar el sistema, después de actualizaciones importantes y periódicamente durante su uso. **El objetivo es detectar si ReJust comete más errores con determinados grupos y evitar que esos fallos acaben afectando a decisiones judiciales o penitenciarias.**

2. ¿De dónde pueden aparecer los sesgos?

Identificamos cuatro fuentes principales:

- **Datos:** los expedientes pueden contener desigualdades históricas, información incompleta o valoraciones subjetivas. Por ejemplo, no participar en talleres puede deberse a que el centro no ofrece plazas, y no a una falta de interés del interno.
- **Modelos:** ReJust podría recuperar peor documentos traducidos, expedientes poco habituales o determinados tipos de pruebas. Los modelos audiovisuales también podrían fallar más ante personas con distintas características físicas o de movilidad.
- **Interfaz:** el orden en que aparecen las pruebas y los resúmenes podría dar más importancia a determinada información y condicionar la interpretación del profesional.
- **Diseño:** las decisiones sobre qué información recuperar o qué acontecimientos detectar pueden dejar fuera situaciones relevantes si no se tienen en cuenta diferentes perfiles y necesidades.

3. ¿Cómo auditaríamos cada módulo?

ReJust-Sentencia

Comprobaríamos principalmente tres aspectos:

- **Recuperación de pruebas:** utilizar expedientes de prueba revisados por especialistas para comprobar si ReJust recupera tanto las evidencias favorables como las desfavorables.
- **Pruebas contrafactuales:** comparar dos expedientes equivalentes cambiando características como la nacionalidad, cuando no sean jurídicamente relevantes. Si el análisis cambia injustificadamente, se investigará el posible sesgo.

- **Presentación de resultados:** comprobar que los argumentos contrarios relevantes, las contradicciones y las fuentes originales sean accesibles, sin que los filtros o resúmenes oculten información importante.

También realizaríamos pruebas con documentos traducidos y casos poco frecuentes para comprobar si el sistema funciona igual de bien.

ReJust-Seguimiento

Aquí distinguiríamos entre los registros penitenciarios y las grabaciones.

Registros administrativos: revisaríamos si las diferencias de información se deben realmente a la conducta del interno o a sus oportunidades. Por ejemplo, ReJust deberá distinguir entre una persona que no participa en un taller porque no quiere y otra que no puede participar porque no existen plazas.

Análisis audiovisual: siguiendo las modificaciones del Sprint 3, *Pose Estimation* se utilizará sobre grabaciones autorizadas para identificar acontecimientos observables previamente definidos, sin deducir intenciones ni valorar la rehabilitación de una persona.

Realizaríamos pruebas con distintas condiciones de iluminación, ángulos, calidad de imagen y formas de movilidad, incluyendo personas que utilizan ayudas técnicas.

Como el entrenamiento inicial utilizará datos sintéticos y actores, será necesario comprobar que los resultados también son fiables en condiciones reales antes de utilizar el sistema. Estas pruebas con imágenes reales requerirán la correspondiente autorización legal.

Además, los puntos corporales extraídos se tratarán con especial precaución por su posible carácter biométrico y no se conservarán después del procesamiento, conforme a las mejoras establecidas en el Sprint 3.

4. Procedimiento de auditoría

Proponemos realizar la auditoría en cuatro fases:

1. **Revisión de los datos:** comprobar su procedencia, calidad, representatividad y posibles ausencias.
2. **Pruebas controladas:** comparar los resultados de ReJust con casos previamente revisados por especialistas, prestando especial atención a omisiones y clasificaciones incorrectas.
3. **Análisis de desigualdades:** comprobar si los errores son mayores en determinados colectivos o combinaciones de ellos. Cuando haya pocos casos, complementar los resultados con revisiones cualitativas independientes.
4. **Documentación y seguimiento:** registrar los problemas encontrados, las correcciones aplicadas y repetir las pruebas antes de aprobar nuevas versiones.

Las métricas y los límites de aceptación se establecerán en coordinación con el Anexo VI de Equidad y Métricas.

5. ¿Qué hacemos si encontramos un sesgo?

Primero investigaremos si procede de los datos, el modelo o la forma de presentar la información. Según su origen, podrán corregirse los conjuntos de evaluación, las reglas de recuperación o la interfaz.

Después se repetirán las pruebas para comprobar si el problema se ha solucionado.

Si se detecta un sesgo grave que no pueda corregirse, la funcionalidad afectada se suspenderá. Además, se identificarán los expedientes potencialmente perjudicados para que los profesionales competentes valoren las medidas de revisión o reparación necesarias.

Las auditorías deberán contar con revisión independiente y, cuando corresponda, con especialistas y representantes de colectivos afectados.

6. Conclusión

La finalidad de estas auditorías no es demostrar que ReJust nunca tendrá sesgos, sino comprobar **dónde aparecen, a quién perjudican y cómo podemos corregirlos**.

Por eso, no bastará con evaluar la precisión general del sistema. También tendremos que comprobar que su funcionamiento sea suficientemente equitativo y que los errores detectados no se repitan ni terminen perjudicando a determinadas personas.

Referencias

- Ley 15/2022, integral para la igualdad de trato y la no discriminación, art. 23. https://www.boe.es/buscar/act.php?id=BOE-A-2022-11589
- Reglamento (UE) 2024/1689 de Inteligencia Artificial, art. 10. https://eur-lex.europa.eu/eli/reg/2024/1689/oj?locale=es
- NIST (2023). *AI Risk Management Framework 1.0*. https://doi.org/10.6028/NIST.AI.100-1
- Buolamwini, J. y Gebru, T. (2018). *Gender Shades*. https://proceedings.mlr.press/v81/buolamwini18a.html

Documentación interna: Sprint 2 de ReJust; Sprint 3, Correcciones y Plausibilidad; Usuarios y Colectivos Vulnerables; Gestión de Riesgos y Anexo VI de Equidad y Métricas.

Enlace IA:
https://chatgpt.com/share/6ade6b64-383c-83eb-8927-71a331c791d8