Sprint 3: Gestión de Riesgos y Control Absoluto

1. Objeto y alcance

ReJust adoptará un modelo de gestión continua de riesgos, destinado a identificar, prevenir, detectar y mitigar posibles fallos durante todo su ciclo de vida. Aunque el apartado se denomine «Gestión de Riesgos y Control Absoluto», no se considerará técnicamente posible garantizar la ausencia completa de errores, sesgos o consecuencias perjudiciales. La finalidad será establecer un control efectivo, verificable y auditable, reconociendo la existencia de riesgos residuales incluso después de aplicar las medidas de seguridad.

El control se abordará desde tres perspectivas complementarias: técnica, mediante mecanismos de verificación, restricciones funcionales y monitorización; humana, permitiendo a los profesionales comprobar las fuentes y prescindir de los resultados; e institucional, mediante auditorías, responsabilidades definidas y protocolos de suspensión. Este planteamiento se fundamenta en los artículos 9, 14 y 15 del Reglamento (UE) 2024/1689, así como en el marco de gestión de riesgos del NIST y la norma ISO/IEC 23894:2023 [1, 3, 4].

Las decisiones de diseño establecidas en los sprints anteriores constituirán el punto de partida de esta evaluación. Entre ellas se encuentran la separación entre ReJust-Sentencia y ReJust-Seguimiento, la prohibición de proponer penas o fallos, la ausencia de puntuaciones individuales de riesgo, la recuperación de pruebas favorables y contrarias, la supervisión humana y la abstención ante información insuficiente.

Estas salvaguardas no se considerarán garantías demostradas por el simple hecho de estar especificadas. Su eficacia deberá comprobarse mediante pruebas independientes y procedimientos de evaluación adaptados a cada funcionalidad.

2. Identificación y clasificación de riesgos

ReJust dispondrá de un registro de riesgos diferenciado por módulo y funcionalidad. Cada entrada incluirá la causa del posible fallo, sus consecuencias, gravedad, probabilidad estimada, capacidad de detección, reversibilidad del daño, medidas preventivas, responsable del control y riesgo residual.

Al tratarse de un sistema prospectivo sin resultados experimentales propios, no se asignarán porcentajes de fallo arbitrarios. Inicialmente se empleará una clasificación cualitativa de probabilidad baja, media, alta o desconocida, combinada con niveles de gravedad moderada, alta y crítica.

Se considerarán especialmente críticos los errores que puedan afectar a la libertad personal, el derecho de defensa, la igualdad o la confidencialidad de información sensible. La baja frecuencia estimada de un incidente no bastará para justificar su aceptación cuando sus consecuencias puedan ser graves o difíciles de reparar.

2.1. Riesgos propios de ReJust-Sentencia

Los principales riesgos del módulo judicial estarán relacionados con la omisión de pruebas relevantes, especialmente de descargo; la recuperación de jurisprudencia inaplicable; la utilización de normativa desactualizada; las citas jurídicas inexistentes y las interpretaciones incorrectas de documentos.

La omisión silenciosa de información constituye uno de los riesgos más difíciles de detectar. A diferencia de una cita inventada, cuya existencia puede comprobarse, una prueba que no aparece en el análisis puede pasar inadvertida y producir una síntesis aparentemente coherente, pero incompleta.

Para reducir este problema, ReJust deberá elaborar un inventario de las fuentes autorizadas del expediente, identificar documentos ilegibles o incompletos y comprobar la cobertura de la recuperación documental. El sistema también verificará las referencias jurídicas mediante fuentes oficiales y garantizará la presencia del núcleo mínimo de información establecido en el apéndice de Correcciones y plausibilidad, incluyendo hechos relevantes, pruebas de cargo y descargo, normativa, precedentes contrarios e incertidumbre.

Los estudios de Dahl et al. (2024) y Magesh et al. (2025) muestran que tanto los modelos de lenguaje generales como determinadas herramientas especializadas de investigación jurídica pueden generar información incorrecta. Por ello, la utilización de recuperación documental no se considerará suficiente para garantizar la fiabilidad de ReJust [5, 6].

2.2. Riesgos propios de ReJust-Seguimiento

En el módulo penitenciario, los riesgos principales estarán asociados a la presentación incompleta de información, el tratamiento de datos personales y los errores en la recuperación o clasificación de acontecimientos audiovisuales.

De acuerdo con las correcciones incorporadas al Sprint 3, el análisis audiovisual se limitará a búsquedas autorizadas y a un catálogo cerrado de acontecimientos observables. No se utilizará para identificar personas mediante sus movimientos, inferir emociones o intenciones, elaborar perfiles de peligrosidad ni generar puntuaciones de conducta.

Se evaluarán especialmente los falsos positivos y negativos, los errores relacionados con la iluminación, los ángulos de cámara, las oclusiones y las diferencias físicas o de movilidad. Ninguna clasificación automática constituirá por sí sola un hecho acreditado. Los registros deberán ser verificados por personal competente antes de poder utilizarse en informes.

La evaluación tendrá en cuenta que los datos sintéticos utilizados inicialmente pueden no representar adecuadamente las condiciones reales de los centros penitenciarios. En consecuencia, una funcionalidad entrenada exclusivamente con datos sintéticos no podrá autorizarse para uso operativo sin la validación independiente y la habilitación jurídica correspondientes.

La conservación de grabaciones y registros seguirá la política específica fijada en el apéndice de Correcciones y plausibilidad, evitando establecer plazos diferentes o conservar datos indefinidamente.

2.3. Riesgos comunes

Ambos módulos estarán expuestos a riesgos de ciberseguridad, accesos no autorizados, manipulación documental, errores de actualización, dependencia excesiva de la IA y propagación de fallos a gran escala.

Se prestará especial atención a los ataques de prompt injection, en los que un documento procesado contiene instrucciones destinadas a modificar el comportamiento del modelo. Para impedirlo, ReJust separará las instrucciones del sistema del contenido documental y limitará técnicamente las acciones que puedan realizarse a partir de información no confiable [7].

Asimismo, se comprobará que los datos y resultados de ReJust-Seguimiento no puedan influir en el análisis sustantivo de ReJust-Sentencia, manteniendo separados sus finalidades, permisos y mecanismos de evaluación.

2.4. Tabla sintética de riesgos

La matriz siguiente relaciona riesgos, gravedad, probabilidad cualitativa preliminar y medidas de prevención y contingencia. No recoge frecuencias observadas: cada valoración deberá actualizarse con resultados de pruebas.

Líneas rojas de ReJust. Con carácter previo a cualquier despliegue se establecen cinco prohibiciones estrictas que no podrán desactivarse mediante preferencias de usuario:

- ReJust no propondrá fallos, penas, progresiones de grado ni concesiones o denegaciones de permisos o libertad condicional; la decisión corresponderá a la autoridad competente.
- ReJust no generará puntuaciones individuales de peligrosidad, reincidencia o conducta futura.
- El análisis audiovisual no empleará reconocimiento facial ni inferirá emociones, intenciones o culpabilidad; se limitará a eventos observables en búsquedas autorizadas.
- No se mezclarán datos ni finalidades de ReJust-Sentencia y ReJust-Seguimiento, ni se adaptará el criterio jurídico al historial individual de los operadores.
- No se emitirá un análisis sustantivo cuando falten fuentes determinantes, existan problemas graves de integridad o no puedan comprobarse las referencias esenciales.

Tabla 1. Riesgos relevantes y medidas de control

Escalas: gravedad alta o crítica; probabilidad baja, media o desconocida. Todas las estimaciones son hipótesis de diseño sujetas a evaluación y no constituyen tasas experimentales.

Riesgo	Descripción	Gravedad	Probabilidad[1]	Prevención	Contingencia
R1. Omisión de prueba relevante	No se recupera una prueba o documento determinante, especialmente de descargo.	Crítica	Desconocida	Inventario íntegro del expediente, pruebas de cobertura y contraste de pruebas de cargo y descargo.	Bloquear el informe; revisión manual del expediente; identificar consultas afectadas y suspender el recuperador si el fallo es sistemático.
R2. Cita jurídica inexistente o incorrecta	Se genera o atribuye una norma o resolución inexistente, errónea o no comprobable.	Alta	Media	Verificación independiente de citas en BOE/CENDOJ; separación de recuperación y generación; contraste de fuente original.	Invalidar la afirmación o salida; revisar consultas de la misma versión; corregir el verificador y repetir las pruebas.
R3. Fuente jurídica desactualizada	Una norma derogada o una línea jurisprudencial superada se presenta como aplicable.	Alta	Media	Verificación de vigencia y aplicación temporal; control de fechas y cambios normativos; pruebas de actualización.	Abstención o bloqueo; actualizar las fuentes, localizar análisis afectados y validar antes de reactivar.
R4. Sesgo discriminatorio	La recuperación o presentación de información perjudica de modo desigual a determinados colectivos.	Crítica	Desconocida	Pruebas contrafactuales, auditorías de equidad por subgrupos y revisión de variables discriminatorias indirectas.	Suspender la función; auditoría independiente; corregir datos o reglas; repetir pruebas por grupos antes de reanudar.
R5. Error de clasificación audiovisual	Una grabación incompleta o adversa produce falsos positivos o negativos de eventos observables.	Alta	Media	Catálogo cerrado de eventos y búsquedas autorizadas; pruebas con oclusiones, movilidad diversa y mala iluminación; verificación humana.	No validar el registro; revisar vídeo original y contexto; corregir registros e informes que hayan reutilizado el error.
R6. Acceso indebido o filtración de datos	Exposición de expedientes o grabaciones por vulnerabilidad, permiso incorrecto o intrusión.	Crítica	Baja	Permisos por función y finalidad, cifrado, separación de módulos, registros de acceso y pruebas de seguridad.	Aislar sistemas y revocar accesos; preservar pruebas; investigar alcance y comunicar a las autoridades cuando corresponda.

Riesgo	Descripción	Gravedad	Probabilidad[1]	Prevención	Contingencia
R7. Inyección de instrucciones	Un documento del expediente intenta alterar las instrucciones o las herramientas del modelo.	Alta	Media	Tratar documentos como datos no confiables; separar instrucciones privilegiadas; limitar herramientas y ensayar ataques.	Bloquear el procesamiento afectado; investigar la entrada y revisar salidas; corregir los controles antes de reanudar.
R8. Dependencia humana de la IA	El profesional acepta una síntesis convincente sin contrastar fuentes o contradicciones.	Alta	Media	Mostrar fuentes, descargos e incertidumbre antes de la síntesis; formación y pruebas de interacción humano-IA.	Revisión humana independiente de casos sensibles; rediseñar interfaz; repetir ensayos de sobredependencia.
R9. Contaminación entre módulos	Datos penitenciarios se reutilizan indebidamente en Sentencia o se cruzan finalidades.	Crítica	Baja	Separar historiales, bases, permisos y evaluaciones; pruebas automáticas de aislamiento y acceso.	Bloquear el flujo indebido; auditar accesos y consultas; corregir y revisar posibles procedimientos afectados.
R10. Regresión tras actualización	Una nueva versión introduce errores sistemáticos de búsqueda, citación o presentación.	Crítica	Media	Manifiesto y control de versiones; pruebas adversarias y comparativas; aprobación independiente y despliegue escalonado.	Suspender la nueva versión; revertir a la validada; localizar consultas afectadas; corregir y repetir validación.

[1] Probabilidad preliminar y no medida empíricamente. Su categoría podrá cambiar tras las pruebas.

3. Prevención y monitorización

La gestión operativa seguirá cuatro etapas: prevención, detección, respuesta y recuperación. Los resultados de cada evaluación o incidente deberán utilizarse para mejorar los controles, sin permitir que el sistema aprenda automáticamente del criterio jurídico individual de sus usuarios.

3.1. Controles preventivos

Antes de generar una salida, ReJust deberá verificar la integridad de los documentos incorporados, la disponibilidad de las fuentes y el cumplimiento de los permisos de acceso. Las afirmaciones jurídicas deberán vincularse con referencias comprobables, evitando presentar como acreditada información que no pueda sustentarse documentalmente.

Se mantendrá un control de versiones que incluya el modelo utilizado, los índices jurídicos, las reglas de recuperación, los verificadores y las configuraciones relevantes. Esto permitirá identificar cambios sustantivos incluso cuando no se haya modificado el modelo generativo principal.

Toda actualización deberá superar una batería de pruebas previamente definida. Se comprobarán las omisiones documentales, las referencias jurídicas, los posibles sesgos y la resistencia frente a entradas maliciosas. La detección de regresiones críticas conocidas impedirá autorizar la nueva versión hasta su corrección.

3.2. Detección y seguimiento

La detección combinará comprobaciones automáticas por consulta, evaluaciones periódicas sobre conjuntos de referencia y auditorías independientes.

Las pruebas utilizarán expedientes y documentos autorizados, revisados por especialistas, para determinar qué información debería recuperar el sistema. Esto permitirá medir tanto los errores presentes en las respuestas como la información relevante que ReJust haya omitido.

La monitorización buscará anomalías en la recuperación documental, las citas jurídicas, las abstenciones, los accesos, el funcionamiento de los verificadores y las diferencias entre versiones.

Los registros de ReJust-Sentencia se organizarán por expediente y permanecerán bajo la custodia del CGPJ, conforme al modelo de gobernanza definido en el Sprint 3. Su finalidad será investigar incidentes y reconstruir el funcionamiento técnico, no elaborar perfiles de los jueces ni comparar sus criterios decisorios.

La evaluación de la dependencia humana se realizará mediante estudios controlados y datos agregados y seudonimizados, evitando utilizar los registros de producción para supervisar individualmente la actuación jurisdiccional.

4. Gestión del riesgo residual y criterios de intervención

Cada riesgo deberá evaluarse antes y después de aplicar los controles correspondientes. El riesgo residual será aquel que permanezca después de aplicar las medidas preventivas y correctivas. Su evaluación permitirá determinar si la funcionalidad puede mantenerse, necesita controles adicionales o debe suspenderse.

No todos los riesgos residuales serán aceptables. Una funcionalidad podrá mantenerse cuando exista evidencia suficiente de que opera dentro de las condiciones autorizadas. Si se detectan deficiencias relevantes, deberá restringirse, someterse a nuevas pruebas o suspenderse.

Se establecerán tres niveles internos de incidencia:

Moderado: errores de funcionamiento o presentación sin consecuencias sustantivas conocidas. Se registrarán, corregirán y revisarán para detectar posibles patrones.

Alto: fallos relevantes de recuperación, verificación o integridad que afecten a una consulta. Se bloqueará el resultado comprometido y se comprobará si existen otros casos afectados.

Crítico: errores sistemáticos, discriminación grave, accesos indebidos o situaciones capaces de comprometer derechos fundamentales. Se activarán los mecanismos de suspensión y respuesta institucional definidos en el anexo de Límites, emergencias y rendición de cuentas.

Estos niveles constituyen una clasificación interna propuesta para ReJust y no sustituyen las definiciones legales de incidente grave establecidas por el Reglamento Europeo de Inteligencia Artificial.

La abstención será una medida preventiva obligatoria cuando falten documentos determinantes, no puedan verificarse fuentes esenciales o existan problemas graves de integridad. El sistema indicará qué comprobación ha fallado y qué información puede revisarse de manera independiente.

La autoridad judicial podrá prescindir de ReJust y continuar el procedimiento por los medios ordinarios, pero no podrá desactivar los controles institucionales de seguridad o convertir una salida no verificada en información validada por el sistema.

5. Evaluación de la eficacia de los controles

La seguridad de ReJust no se medirá exclusivamente mediante su precisión global. Se evaluarán también los errores omitidos, su distribución entre colectivos, la capacidad de detección y las consecuencias que podrían tener sobre los procedimientos.

Los indicadores principales para la gestión de riesgos serán:

- **Cobertura documental:** proporción de evidencias relevantes recuperadas respecto de las identificadas en conjuntos de referencia.
- **Errores de citación:** proporción de referencias jurídicas inexistentes, incorrectas o no verificables.
- **Fiabilidad normativa:** capacidad de identificar correctamente la vigencia y aplicabilidad temporal de las disposiciones.
- **Efectividad de los bloqueos:** comprobación de que el sistema se abstiene cuando faltan garantías esenciales.
- **Resistencia adversaria:** porcentaje de ataques de prueba capaces de vulnerar restricciones de seguridad.
- **Tiempo de detección y contención:** intervalo entre la aparición de un incidente, su identificación y el bloqueo de la funcionalidad afectada.

- **Cobertura retrospectiva:** capacidad para localizar consultas y expedientes potencialmente afectados por una versión defectuosa.
- **Efectividad de la recuperación:** superación de las pruebas necesarias antes de autorizar la reanudación del servicio.

Estas métricas se complementarán con las evaluaciones de equidad del Anexo VI y el análisis de colectivos vulnerables desarrollado en este sprint. Se comprobarán las diferencias de rendimiento por grupos y condiciones de uso, incluyendo situaciones interseccionales cuando existan datos suficientes.

Los criterios de aceptación deberán definirse antes de conocer los resultados de las pruebas. No se establecerán porcentajes arbitrarios de precisión, sino objetivos justificados en función de la gravedad de los errores, la incertidumbre estadística y la comparación con procedimientos equivalentes sin IA.

Un resultado agregado favorable no justificará el despliegue si existen errores críticos concentrados en determinados colectivos. Del mismo modo, no observar un fallo durante las pruebas no demostrará que dicho fallo sea imposible.

6. Evaluación de escenarios críticos

Las pruebas de ReJust deberán incorporar situaciones adversarias que permitan comprobar la actuación conjunta de los controles técnicos y humanos.

6.1. Omisión de jurisprudencia favorable

Se simulará una actualización que provoque la desaparición de una línea jurisprudencial relevante en determinados expedientes.

Las pruebas deberán comprobar si el defecto es detectado, si puede identificarse la versión responsable y si los registros permiten localizar las consultas potencialmente afectadas.

La suspensión y eventual revisión de procedimientos seguirán los mecanismos establecidos en el anexo de Límites, emergencias y rendición de cuentas. Se distinguirá siempre entre reparar el funcionamiento técnico de ReJust y determinar las consecuencias jurídicas de su utilización.

6.2. Clasificación audiovisual incorrecta

Se utilizarán grabaciones de prueba con acontecimientos ambiguos, contextos incompletos y condiciones de visibilidad adversas.

La evaluación comprobará si ReJust presenta adecuadamente sus limitaciones, evita atribuciones automáticas de responsabilidad y permite la revisión del material original por personal autorizado.

También se verificará que los datos no confirmados no puedan convertirse en registros válidos para fundamentar informes penitenciarios y que las correcciones posteriores puedan rastrearse.

6.3. Dependencia excesiva del sistema

Se realizarán pruebas controladas con profesionales que deban revisar documentación con y sin asistencia de ReJust, incluyendo algunas salidas deliberadamente incorrectas en entornos experimentales.

Se analizará si detectan errores, consultan las fuentes originales y mantienen la capacidad de cuestionar resultados aparentemente convincentes.

Estas pruebas permitirán evaluar el automation bias sin construir perfiles individuales de jueces a partir de su actividad jurisdiccional [8, 9].

6.4. Fallo institucional de los controles

Se contemplará el supuesto de que una auditoría detecte un riesgo crítico, pero existan presiones para mantener el sistema por motivos de productividad o ahorro.

La evaluación deberá verificar que se activan los mecanismos institucionales de suspensión establecidos, sin que la continuidad del servicio dependa exclusivamente de la conveniencia económica.

Este escenario permitirá comprobar que el control de ReJust no se limita a sus componentes tecnológicos, sino que alcanza también a las decisiones de las instituciones responsables.

7. Condiciones de autorización y continuidad

La implantación de ReJust estará condicionada a una evaluación progresiva de seguridad, utilidad y proporcionalidad.

En una primera fase se utilizarán casos sintéticos y conjuntos documentales autorizados, sin intervenir en procedimientos reales. Posteriormente podrán desarrollarse pilotos paralelos al funcionamiento ordinario para comprobar el rendimiento y la interacción humano-IA sin que sus resultados fundamenten decisiones.

Solo después de superar las evaluaciones independientes correspondientes se considerará el uso institucional limitado de las funciones autorizadas.

Se mantendrá la prioridad de despliegue de ReJust-Sentencia establecida en el Sprint 2. ReJust-Seguimiento requerirá una validación adicional, especialmente de las funcionalidades audiovisuales y de los tratamientos que puedan afectar a las personas internas.

La autorización deberá acreditar que existen mecanismos eficaces de abstención, trazabilidad, revisión humana, suspensión y recuperación. Asimismo, deberá comprobarse el cumplimiento de los requisitos jurídicos y de protección de datos aplicables a cada módulo.

La continuidad de ReJust se evaluará comparando sus resultados con los procedimientos ordinarios y con alternativas no algorítmicas, incluida la inversión equivalente en personal judicial. La mejora de productividad no será suficiente si no se demuestra una relación favorable entre utilidad y riesgos.

Cuando una funcionalidad no pueda mantener las garantías exigidas, deberá restringirse o retirarse, aunque su implementación resulte técnicamente viable.

8. Conclusión

La gestión de riesgos de ReJust no se fundamentará en la promesa de un sistema incapaz de fallar, sino en la demostración continua de que sus errores pueden prevenirse, detectarse y gestionarse dentro de límites jurídicos y técnicos definidos.

El control efectivo requerirá combinar verificaciones automáticas, evaluación humana, auditorías independientes y procedimientos institucionales de intervención. Ninguna de estas medidas será suficiente por separado, y su existencia formal no permitirá considerar eliminado el riesgo residual.

En consecuencia, ReJust adoptará como principio rector:

«Control efectivo y auditable, no control absoluto».

Este principio se complementará con dos exigencias: abstenerse ante incertidumbre crítica y permitir investigar cualquier fallo grave antes de reanudar una funcionalidad comprometida.

La posibilidad de limitar o retirar componentes no se considerará una debilidad del proyecto, sino una garantía fundamental para impedir que su funcionamiento prevalezca sobre los derechos de las personas afectadas.

Referencias

[1] Unión Europea (2024). Reglamento (UE) 2024/1689 por el que se establecen normas armonizadas en materia de inteligencia artificial. https://eur-lex.europa.eu/eli/reg/2024/1689

[2] Consejo General del Poder Judicial (2026). Instrucción 2/2026 sobre la utilización de sistemas de inteligencia artificial en el ejercicio de la actividad jurisdiccional. https://www.boe.es/buscar/doc.php?id=BOE-A-2026-2205

[3] Tabassi, E. (2023). Artificial Intelligence Risk Management Framework (AI RMF 1.0). National Institute of Standards and Technology. https://doi.org/10.6028/NIST.AI.100-1

[4] ISO/IEC (2023). ISO/IEC 23894:2023 — Information technology — Artificial intelligence — Guidance on risk management. https://www.iso.org/standard/77304.html

[5] Dahl, M., Magesh, V., Suzgun, M. y Ho, D. E. (2024). Large Legal Fictions: Profiling Legal Hallucinations in Large Language Models. Journal of Legal Analysis. https://doi.org/10.1093/jla/laae003

[6] Magesh, V. et al. (2025). Hallucination-Free? Assessing the Reliability of Leading AI Legal Research Tools. Journal of Empirical Legal Studies. https://doi.org/10.1111/jels.12413

[7] Greshake, K. et al. (2023). Not What You've Signed Up For: Compromising Real-World LLM-Integrated Applications with Indirect Prompt Injection. https://doi.org/10.48550/arXiv.2302.12173

[8] Buçinca, Z., Malaya, M. B. y Gajos, K. Z. (2021). To Trust or to Think: Cognitive Forcing Functions Can Reduce Overreliance on AI in AI-Assisted Decision-Making. https://doi.org/10.1145/3449287

[9] Green, B. y Chen, Y. (2019). Disparate Interactions: An Algorithm-in-the-Loop Analysis of Fairness in Risk Assessments. https://doi.org/10.1145/3287560.3287563

[10] OpenAI (2026). Conversación con ChatGPT utilizada como apoyo para la investigación y elaboración del apartado «Gestión de Riesgos y Control Absoluto» del proyecto ReJust. ChatGPT. https://chatgpt.com/c/6ab810b5-5f20-83ed-8771-1543e4b702ca