Análisis de plausibilidad de ReJust

ReJust · Apoyo a decisiones penales y penitenciarias en España para 2030

Ética de Datos y de IA · Facultad de Informática · Universidad Complutense de Madrid · Sprint 3 · Octubre de 2026

1. Objeto, alcance y criterio de análisis

El presente documento examina la plausibilidad de ReJust, entendida como la probabilidad razonable de que el sistema pueda construirse, contar con base jurídica suficiente y ser adoptado por las instituciones en la forma prevista y en el horizonte de 2030. No se trata de una nueva evaluación de la conveniencia ética del proyecto, ya abordada en los sprints anteriores, sino de una identificación de las partes del diseño que resultan frágiles o dudosas y de las razones que lo explican.

Las fragilidades se agrupan según su origen en cuatro tipos de dependencia: la tecnológica, que afecta a capacidades no demostradas o todavía en fase de investigación; la de datos, relativa a la disponibilidad, la calidad y la representatividad de la información; la jurídica, que comprende las condiciones normativas de las que depende cada función; y la de adopción institucional, que depende de la aceptación, los medios y la coordinación de los organismos implicados. Se señalan, además, los elementos cuya plausibilidad resulta sólida y las medidas que permitirían reforzarla.

2. Diseño de referencia tras las correcciones

ReJust es un asistente documental que no propone fallos, penas, clasificaciones de grado ni concesiones o denegaciones de permisos, y que no genera puntuaciones de riesgo. ReJust-Sentencia organiza el expediente, recupera normas y precedentes, verifica las citas en fuentes oficiales y presenta los argumentos a favor y en contra con idéntica jerarquía visual. ReJust-Seguimiento ordena la información de la ejecución penitenciaria para la Junta de Tratamiento y el Juez de Vigilancia Penitenciaria. El Ministerio de Justicia actúa como proveedor, sin acceso al contenido de las consultas, y el gobierno del uso jurisdiccional corresponde al Consejo General del Poder Judicial, que custodia unos registros organizados por expediente y no por usuario.

El componente audiovisual de ReJust-Seguimiento, que fue el más cuestionado en el debate, ha quedado redefinido para ajustarse al marco jurídico vigente. Sus rasgos esenciales son los siguientes.

En cuanto a su finalidad, el sistema no realiza un análisis continuo del comportamiento ni elabora perfiles de conducta. Se limita a localizar, dentro de las grabaciones que el centro ya obtiene y conserva legalmente, los fragmentos vinculados a un incidente documentado, a una denuncia, a un procedimiento o a una solicitud autorizada, incluida la de la defensa del interno. Solo clasifica eventos observables de un catálogo cerrado y definido de antemano, como una caída, un contacto físico o la permanencia en una zona determinada, y no infiere emociones, intenciones ni estados psicológicos. Las conductas favorables se obtienen de los registros administrativos del centro, como la asistencia a talleres o el desempeño de destinos, y no del análisis de vídeo.

En cuanto al tratamiento de los datos, la estimación de pose se considera una técnica de minimización y no de anonimización, y los puntos corporales se tratan como datos potencialmente biométricos sujetos al régimen de categorías especiales del artículo 13 de la Ley Orgánica 7/2021. Esos puntos se suprimen inmediatamente después de clasificar el evento y no pueden utilizarse para identificar a nadie por su forma de moverse; la identificación corresponde siempre a un profesional sobre la grabación original. No se emplea reconocimiento facial. El difuminado se aplica solo a las copias de visualización y de entrenamiento, mientras que el original se conserva sin alteración bajo custodia de la Administración, con cadena de custodia y verificación de integridad, lo que preserva el derecho de defensa del artículo 24 de la Constitución.

En cuanto a la conservación, la grabación original se suprime a los treinta días conforme a la Instrucción 4/2022 de la Secretaría General de Instituciones Penitenciarias, salvo los fragmentos vinculados a un incidente, una denuncia, un procedimiento o una impugnación. Ningún registro se conserva de forma indefinida: los registros no verificados se suprimen con la grabación y no pueden usarse en ninguna decisión, y los verificados siguen plazos por categoría alineados con los artículos 105 y 260 del Reglamento Penitenciario. Todo registro cuyo original haya sido suprimido se marca como no contrastable y no puede fundar por sí solo una decisión desfavorable.

En cuanto a la base jurídica, el consentimiento de los internos se ha suprimido como fundamento del tratamiento, porque en una relación de sujeción especial no puede considerarse libre. La observación de los internos tiene respaldo en el artículo 66 del Reglamento Penitenciario y la captación y conservación de imágenes en la Instrucción 4/2022, pero el análisis automatizado requiere además una habilitación normativa específica y una evaluación de impacto conforme al artículo 35 de la Ley Orgánica 7/2021. El diseño corregido incorpora esta exigencia como condición de activación: mientras no exista esa habilitación, la función audiovisual permanece desactivada y ReJust-Seguimiento opera exclusivamente con registros administrativos e informes, y el entrenamiento se realiza solo con datos sintéticos, sin utilizar imágenes de internos reales. Además, ReJust-Seguimiento se reconoce como sistema de alto riesgo conforme a los puntos 6 y 8 del Anexo III del Reglamento (UE) 2024/1689, sin acogerse a la excepción del artículo 6.3.

Con esta configuración, el componente audiovisual es conforme a Derecho en cada fase del proyecto: no amplía la captación de imágenes que ya existe, respeta los plazos y excepciones vigentes, aplica las garantías más exigentes al dato potencialmente biométrico y no se activa sin la habilitación y la evaluación de impacto que la ley exige. La cuestión que subsiste no es su legalidad, sino su plausibilidad, es decir, la probabilidad de que esa habilitación se obtenga y de que la tecnología alcance la fiabilidad necesaria.

3. Valoración general

La plausibilidad de ReJust no es uniforme. El núcleo documental de ReJust-Sentencia es la parte más plausible: se apoya en técnicas existentes y encaja en el marco que fija la Instrucción 2/2026 del Consejo General del Poder Judicial. La vertiente documental de ReJust-Seguimiento tiene una plausibilidad intermedia, condicionada sobre todo por la calidad de los datos penitenciarios y por la coordinación entre tres administraciones. El componente audiovisual, tras las correcciones, es jurídicamente viable y técnicamente mucho más abordable que en su formulación original, puesto que se limita a búsquedas bajo demanda y a un catálogo cerrado de eventos. Sigue siendo, no obstante, la función con más dependencias, porque su activación requiere una habilitación

normativa que todavía no existe y una validación en condiciones reales que solo puede realizarse una vez obtenida.

Varias de las garantías incorporadas en el Sprint 3, como la reproducción de ejecuciones anteriores, la abstención ante la incertidumbre o la medición desagregada de errores por colectivos, son correctas desde el punto de vista ético, pero dependen a su vez de capacidades técnicas o estadísticas que no están resueltas. Su viabilidad debe acreditarse y no puede darse por supuesta.

4. Dependencias tecnológicas

4.1. Fiabilidad de los modelos de lenguaje en el ámbito jurídico

El diseño confía en grandes modelos de lenguaje con recuperación aumentada para resumir expedientes, identificar normas aplicables y localizar precedentes. La evidencia disponible muestra que esta tecnología sigue produciendo errores relevantes en el dominio jurídico. Un estudio sobre modelos generalistas registró tasas de alucinación de entre el 58 % y el 88 % en preguntas verificables sobre jurisprudencia federal estadounidense (Dahl et al., 2024). Incluso las herramientas comerciales especializadas, basadas en recuperación aumentada, presentaron respuestas incorrectas o mal fundamentadas en una proporción situada aproximadamente entre el 17 % y el 33 % de las consultas evaluadas (Magesh et al., 2025). Aunque cabe esperar mejoras hasta 2030, el proyecto no puede presuponer que el problema estará resuelto.

La verificación automática de citas contra el BOE mediante el identificador ELI y contra el CENDOJ mediante el identificador ECLI es una salvaguarda valiosa pero parcial. Comprueba que la norma o la resolución citada existe y está vigente, pero no que su contenido respalde la afirmación concreta a la que se asocia. El error más difícil de detectar no es la cita inventada, sino la cita real atribuida a una tesis que no sostiene. Además, la salvaguarda depende de que el CENDOJ ofrezca un acceso automatizado estable y con cobertura suficiente, lo cual no se ha comprobado.

El requisito de recuperación exhaustiva de pruebas, incluidas las contrarias, presenta un problema adicional de verificabilidad. La exhaustividad solo puede medirse frente a un conjunto de referencia que indique qué elementos debían recuperarse en cada caso, y ese conjunto no existe para el procedimiento penal español. Sin él, la exhaustividad es un objetivo de diseño, no una propiedad demostrable.

4.2. Arquitecturas de referencia en fase de investigación

La arquitectura se inspira en propuestas recientes, como Graph-R1 para la recuperación agéntica sobre grafos de conocimiento y Dream-RSI para la mejora de las estrategias de búsqueda. Ambas son prepublicaciones evaluadas sobre conjuntos de prueba académicos y sin validación conocida en entornos judiciales; Dream-RSI, en particular, data de 2026. Tomarlas como inspiración es legítimo, pero no constituyen tecnología madura. Además, aunque el aprendizaje se realice fuera de línea y con versiones controladas, cada nueva política de recuperación puede constituir una modificación sustancial a efectos del Reglamento (UE) 2024/1689, con la consiguiente repetición de la evaluación de conformidad, de modo que el ritmo de mejora quedará limitado por el ritmo de certificación. Por último, cuando todos los agentes de la arquitectura multiagente comparten el

mismo modelo base, sus errores tienden a estar correlacionados, y la revisión por un agente crítico aporta menos independencia de la que sugiere su denominación.

4.3. Reproducibilidad de las ejecuciones

El protocolo de emergencias del Sprint 3 prevé reproducir las ejecuciones anteriores con su versión registrada para determinar a quién afectó un fallo. Esta garantía solo es plausible con modelos congelados bajo control del proveedor, índices de búsqueda versionados, parámetros de generación deterministas y conservación de todos los documentos de entrada. Los modelos de lenguaje no son plenamente deterministas en la práctica, y los índices cambian a medida que se incorporan nuevas resoluciones. Si algún componente procede de un proveedor externo que retira versiones antiguas, la reproducción deja de ser posible. Resulta más robusto conservar la salida íntegra de cada ejecución junto con sus fuentes que confiar en poder regenerarla.

4.4. Análisis audiovisual en su versión corregida

La redefinición del componente audiovisual mejora de forma notable su plausibilidad técnica. Clasificar conductas como «colaborar» a partir de puntos corporales, como preveía la formulación original, no era técnicamente creíble, porque se trata de interpretaciones sociales y no de patrones cinemáticos. En cambio, detectar caídas, contactos físicos o permanencias en una zona son tareas para las que la estimación de pose ofrece resultados razonables, y la búsqueda bajo demanda sobre fragmentos acotados reduce el volumen de vídeo y el número de falsas alarmas.

Persisten, sin embargo, tres fragilidades. La primera es la calidad de las imágenes: la estimación de pose funciona bien con buena iluminación y personas poco ocluidas, condiciones que no son las habituales en un circuito cerrado penitenciario. La segunda es el cambio de dominio entre los datos sintéticos y las grabaciones reales, que el apéndice reconoce y que solo puede medirse en el piloto. La tercera es la madurez de las técnicas de referencia: los sistemas de detección de anomalías como LAVAD obtienen en conjuntos públicos un área bajo la curva en torno al 80 %, un resultado notable en investigación pero alejado de la fiabilidad exigible a un registro que puede influir en decisiones sobre la libertad. Estas fragilidades no afectan a la legalidad del componente, porque ningún registro se utiliza sin verificación humana, pero sí a su utilidad, y conviene comprobar en el piloto que el valor añadido compensa su coste.

4.5. Abstención, incertidumbre y umbrales

Buena parte de las garantías descansa en que el sistema reconozca cuándo debe abstenerse: expediente incompleto, contradicciones no resueltas o casos comparables insuficientes. Esta capacidad presupone que el sistema estima su propia incertidumbre de forma calibrada, una propiedad que los modelos de lenguaje no garantizan, ya que tienden a expresar seguridad también cuando se equivocan. Además, ningún documento fija todavía los umbrales concretos que activan la abstención, la suspensión de un módulo o la alerta por sesgo; el documento de Robustez reconoce que el umbral de alerta tendrá que ajustarse con los propios usuarios. Mientras no se cuantifiquen, estas garantías dependen de decisiones futuras.

5. Dependencias de datos

5.1. Disponibilidad y calidad de los expedientes

ReJust presupone un expediente judicial íntegramente electrónico, estructurado e interoperable. La realidad española es la de varios sistemas de gestión procesal distintos según el territorio, con

competencias en medios materiales transferidas a numerosas comunidades autónomas, y con una parte relevante de la documentación incorporada todavía como imagen escaneada o texto libre. La orientación al dato impulsada por la normativa de eficiencia digital de la justicia avanza en la dirección correcta, pero no puede darse por supuesta su culminación en 2030. En el ámbito penitenciario la dificultad es mayor, porque los registros dependen de tres administraciones: la Secretaría General de Instituciones Penitenciarias, la Generalitat de Cataluña y el Gobierno Vasco. Este punto cobra más importancia tras las correcciones, puesto que las conductas favorables pasan a obtenerse de los registros administrativos de los centros, cuya calidad y homogeneidad determinan ahora la información disponible.

5.2. Evaluación sin verdad de referencia

Las métricas de validez del proyecto, como la recuperación de pruebas contrarias, la corrección de citas o la reducción de omisiones, requieren conjuntos de evaluación anotados por profesionales del Derecho. Su elaboración es costosa, exige acceso a expedientes reales con base jurídica suficiente y está sujeta a desacuerdo entre anotadores, porque la relevancia de una prueba es en parte una cuestión de criterio. El proyecto todavía no prevé quién elaborará esos conjuntos, con qué recursos ni cómo se resolverán las discrepancias.

5.3. Datos sintéticos y validación real

Conforme a las correcciones, ningún modelo entrenado solo con datos sintéticos puede utilizarse en producción, y la validación en condiciones reales es obligatoria en la fase piloto, previa habilitación y evaluación de impacto. La medida asegura la legalidad del entrenamiento, pero crea una dependencia secuencial: la evidencia sobre el rendimiento real solo puede obtenerse después de la habilitación, mientras que la habilitación exige justificar la necesidad y la proporcionalidad del tratamiento. Esta tensión puede resolverse si la justificación ante el legislador se basa en la evidencia de las fases documentales del proyecto, que no requieren vídeo, y en un piloto de alcance limitado con evaluación independiente.

5.4. Métricas de equidad con poblaciones reducidas y variables no registradas

El apéndice de colectivos vulnerables y el Anexo VI proponen medir los errores de forma desagregada, incluidas las intersecciones entre colectivos. El compromiso es éticamente sólido, pero choca con límites estadísticos. Las mujeres representan en torno al 7 % de la población penitenciaria, de modo que las intersecciones reúnen muy pocos casos y cualquier tasa de error calculada sobre ellas carece de fiabilidad; el propio apéndice lo reconoce y propone una revisión cualitativa externa por debajo de un umbral que aún no se ha fijado. El Anexo VI exige además que la tasa de recuperación de fragmentos sea idéntica para todos los colectivos, requisito que no es alcanzable en sentido estricto y que debe sustituirse por una diferencia máxima tolerada con su intervalo de confianza. Por último, la Administración no registra la etnia, lo que impide auditar el posible sesgo sobre la población gitana; el estudio específico propuesto al amparo del artículo 10.5 del Reglamento de IA depende de la colaboración de organizaciones externas y de garantías que aún no están definidas.

6. Dependencias jurídicas

6.1. Habilitación del análisis audiovisual

Como se ha expuesto, el diseño corregido es conforme a Derecho porque condiciona la activación del análisis automatizado a una habilitación normativa específica y a una evaluación de impacto. La fragilidad, por tanto, no reside en la legalidad, sino en la incertidumbre de que esa habilitación llegue a aprobarse. Una norma de esta naturaleza requeriría probablemente rango de ley orgánica, con la mayoría parlamentaria que ello comporta, y un debate público sobre la videovigilancia algorítmica en prisión cuyo resultado no puede anticiparse. A su favor juegan el alcance reducido del diseño corregido, su orientación también a la protección de los internos, puesto que la defensa puede solicitar la localización de fragmentos, y la participación del Mecanismo Nacional de Prevención de la Tortura en el piloto. En cualquier caso, si la habilitación no se obtiene, el proyecto sigue siendo viable sin el componente audiovisual.

6.2. Calendario y desarrollo del Reglamento de IA

El diseño se apoya en las obligaciones del Reglamento (UE) 2024/1689 para los sistemas de alto riesgo. Su calendario ha sido modificado por el Reglamento (UE) 2026/1744, conocido como *Digital Omnibus on AI*, publicado en el Diario Oficial de la Unión Europea el 24 de julio de 2026 y en vigor desde el 27 de julio de 2026. Esta norma aplaza la aplicación de las obligaciones de los sistemas de alto riesgo del Anexo III, categoría en la que se encuentran los dos módulos de ReJust, del 2 de agosto de 2026 al 2 de diciembre de 2027. El aplazamiento se justifica por el retraso en la disponibilidad de normas armonizadas, especificaciones comunes y directrices, que a la fecha de este documento aún no se han publicado.

La modificación no altera la clasificación de ReJust ni el contenido de sus obligaciones, sino únicamente la fecha a partir de la cual son exigibles, que sigue siendo anterior al horizonte de 2030. Tampoco cambia la competencia de supervisión: los sistemas utilizados por autoridades judiciales y en la aplicación de la ley siguen correspondiendo a las autoridades nacionales. La fragilidad que subsiste es otra: mientras no se publiquen las normas armonizadas y las directrices sobre alto riesgo, el contenido técnico concreto de requisitos como la precisión, la robustez o la gestión de riesgos sigue sin definirse, por lo que las referencias del proyecto a esos requisitos deberán revisarse cuando se publiquen.

6.3. Autoridades competentes

El protocolo de emergencias atribuye la notificación de incidentes graves a la Agencia Española de Supervisión de la Inteligencia Artificial y la de brechas de seguridad a la Agencia Española de Protección de Datos. Esta asignación conviene precisarla. El Reglamento de IA permite que, para los sistemas de alto riesgo utilizados en la aplicación de la ley y en la administración de justicia, la vigilancia del mercado se atribuya a las autoridades de protección de datos. Por su parte, el control de los tratamientos con fines jurisdiccionales corresponde al Consejo General del Poder Judicial, y en Cataluña y en el País Vasco intervendrían sus respectivas autoridades autonómicas de protección de datos. El reparto real de competencias es más complejo que el descrito.

6.4. Eficacia del régimen sancionador frente a un proveedor público

El documento de rendición de cuentas menciona sanciones de hasta quince millones de euros o el 3 % del volumen de negocio para el proveedor. Si, conforme a las correcciones, el proveedor es el Ministerio de Justicia, esa referencia pierde buena parte de su sentido: el Reglamento deja a cada Estado miembro decidir si se imponen multas a autoridades y organismos públicos, y una sanción económica entre administraciones tiene un efecto disuasorio limitado. La responsabilidad efectiva del proveedor público descansa en el control parlamentario, la responsabilidad patrimonial y la supervisión independiente, y así debería exponerse.

6.5. Plazos de conservación y reparto competencial

La política de conservación por categorías vincula la vida de los registros a los plazos de cancelación del artículo 260 y a la periodicidad de revisión del artículo 105 del Reglamento Penitenciario. Es una analogía razonable y coherente con el principio de limitación del plazo de conservación de la Ley Orgánica 7/2021, pero se trata de una decisión de diseño que debe incorporarse a la norma de habilitación o, al menos, a una instrucción de la administración penitenciaria para adquirir fuerza jurídica. Del mismo modo, un despliegue estatal en un ámbito en el que varias comunidades autónomas gestionan sus propios medios materiales de la justicia, y en el que Cataluña y el País Vasco tienen competencias penitenciarias, requeriría acuerdos en los órganos de cooperación de la administración judicial electrónica, cuya negociación puede extenderse durante años.

7. Dependencias de adopción institucional

7.1. Utilidad percibida y carga de verificación

El proyecto rechaza, con razón, medir su éxito por la rapidez. Sin embargo, su adopción real depende de que los órganos judiciales perciban una utilidad. Si cada afirmación debe contrastarse con su fuente, como exige la supervisión efectiva, el ahorro de tiempo puede desaparecer y el sistema puede percibirse como una carga añadida. Si, por el contrario, se percibe como útil porque ahorra tiempo, aumenta el riesgo de sesgo de automatización en órganos con elevada carga de trabajo. El equilibrio entre ambos extremos solo puede comprobarse en el piloto.

7.2. Capacidad de los órganos de supervisión

Las garantías incorporadas atribuyen tareas nuevas a numerosos organismos: la custodia de los registros y la publicación de un informe anual por el Consejo General del Poder Judicial, la participación del Mecanismo Nacional de Prevención de la Tortura en el piloto, la verificación profesional de cada registro audiovisual, la revisión cualitativa de muestras por expertos externos y entidades del tercer sector, y el modo asistido de la pantalla P6 con intérpretes, lectura fácil y apoyo de los Servicios de Orientación Jurídica Penitenciaria. Ninguna de estas tareas cuenta todavía con una estimación de coste ni con una previsión de financiación. Si los medios no acompañan, las garantías pueden quedar en el plano formal.

7.3. Operatividad del criterio de retirada

El compromiso de retirar el sistema si sus garantías no superan las de una inversión equivalente en personal judicial es el más exigente del proyecto. Su plausibilidad depende de que pueda aplicarse, y aún no se ha definido qué se entiende por garantías, cómo se miden, frente a qué inversión concreta se comparan ni quién decide la retirada. Una vez realizada la inversión, existirá

además una presión institucional para mantener el sistema. Sin una metodología previa y un órgano decisor independiente, el criterio corre el riesgo de no activarse nunca.

7.4. Aceptación en los centros penitenciarios

Las correcciones reducen las objeciones previsibles, porque el sistema ya no observa de forma continua ni registra conductas de manera proactiva. Aun así, el personal penitenciario aparece en las grabaciones y su actividad puede quedar documentada en los fragmentos analizados, lo que obligará a negociar con sus representantes las condiciones de uso. Las personas internas, por su parte, carecen de acceso a internet y dependen de la defensa o de los servicios de orientación para ejercer los derechos que ofrece la pantalla P6. La evaluación prevista en el piloto sobre si la presencia del sistema altera la conducta en los espacios comunes será determinante para su aceptación social.

8. Coherencia documental tras las correcciones

Las correcciones han resuelto las contradicciones principales señaladas en el debate. Para que la memoria sea coherente con el diseño de referencia, deben entenderse superados también los siguientes pasajes, que no recoge la fe de erratas del apéndice.

En primer lugar, en cuanto al alcance del análisis audiovisual, prevalece la búsqueda bajo demanda descrita en el documento de Límites del Sprint 3, en el Anexo VI y en el apartado 7.3 del apéndice, y queda superado el análisis continuo y proactivo de los espacios comunes descrito en el Anexo I del Sprint 2. En segundo lugar, en cuanto al registro de uso, prevalece la organización por expediente bajo custodia del Consejo General del Poder Judicial; la mención del documento de Límites al registro del usuario debe entenderse referida a la trazabilidad de cada consulta, y la tasa de discrepancia de los jueces solo puede publicarse de forma agregada y seudonimizada, para no presionarles a seguir el análisis. En tercer lugar, quedan superadas las previsiones del documento de Datos del Sprint 1 sobre el tratamiento de datos biométricos, expedientes médicos y telemetría de posicionamiento, y sobre el uso de los informes de los funcionarios como señal de aprendizaje; también las denominaciones «Juez IA» y las explicaciones sobre cómo cambiaría la decisión, incompatibles con un asistente que no propone decisiones. Por último, el alcance del piloto, limitado a delitos de gravedad media, debe definirse con referencia a la clasificación de penas del Código Penal.

9. Elementos de plausibilidad sólida

El análisis anterior no implica que el proyecto sea inviable. La renuncia a proponer fallos, penas o puntuaciones de riesgo elimina el uso que concentra mayores objeciones jurídicas y técnicas y sitúa el sistema en una función de asistencia documental para la que ya existen herramientas comparables. La verificación de citas contra fuentes oficiales es técnicamente sencilla y reduce el riesgo más visible. La separación entre los módulos de Sentencia y Seguimiento, el registro de las ejecuciones, la posibilidad de detener el sistema y la continuidad del procedimiento en modo manual no dependen de avances futuros. La atribución del gobierno del uso jurisdiccional al Consejo General del Poder Judicial es coherente con la Instrucción 2/2026. El componente audiovisual corregido se apoya en grabaciones, plazos y excepciones que ya existen, y su condición de activación garantiza que nunca opere sin base jurídica. Por último, el principio de que la motivación de la resolución debe ser propia del juez es jurídicamente sólido y fácil de controlar mediante los recursos ordinarios.

10. Medidas para reforzar la plausibilidad

En primer lugar, se propone un despliegue en fases, cada una condicionada a la superación de la anterior. La primera fase comprendería el núcleo documental de ReJust-Sentencia en un número reducido de órganos. La segunda incorporaría la vertiente documental de ReJust-Seguimiento, basada en registros administrativos e informes. El componente audiovisual se activaría en una fase posterior, una vez aprobada la habilitación y realizada la evaluación de impacto, mediante un piloto limitado con participación del Mecanismo Nacional de Prevención de la Tortura. Este orden permite que cada fase aporte la evidencia que justifica la siguiente.

En segundo lugar, deben cuantificarse los umbrales que hoy quedan abiertos: la tasa de error que activa la suspensión de un módulo, la diferencia máxima tolerada entre colectivos con su intervalo de confianza, el número mínimo de casos para desagregar resultados y los criterios de abstención. También debe definirse la metodología de comparación con la inversión equivalente en personal judicial y el órgano independiente que decide la retirada.

En tercer lugar, se recomienda conservar la salida íntegra de cada ejecución junto con sus fuentes, exigir al proveedor el mantenimiento de las versiones de los modelos durante el periodo de conservación de los registros y ampliar la verificación de citas a la comprobación de que el pasaje citado respalda la afirmación.

En cuarto lugar, conviene elaborar un mapa de las autoridades competentes por módulo y por territorio, una estimación de costes de las garantías de supervisión y de acceso asistido, y un plan de elaboración de los conjuntos de evaluación anotados. Por último, la política de conservación por categorías debería incorporarse a la propia norma de habilitación, para que los plazos del diseño adquieran fuerza jurídica.

11. Conclusión

Tras las correcciones, ReJust es un asistente documental jurídicamente viable en todos sus módulos. El componente audiovisual, que fue el aspecto más discutido, se limita ahora a búsquedas bajo demanda sobre grabaciones ya existentes, trata los datos de pose con las garantías de las categorías especiales, respeta los plazos de conservación vigentes y no se activa sin habilitación normativa y evaluación de impacto. Su plausibilidad depende, por tanto, de la obtención de esa habilitación y de la validación técnica en el piloto, no de una tensión con la ley. Las fragilidades restantes se concentran en la fiabilidad de los modelos de lenguaje, en la calidad y la representatividad de los datos, en la concreción de umbrales y criterios de retirada y en los medios institucionales para sostener las garantías. Reconocerlas completa la postura regulacionista exigente del proyecto: si cada función debe acreditar que sus garantías superan sus costes, también debe acreditar que es realizable. Un despliegue por fases permite que ReJust avance solo hasta donde la evidencia y el marco jurídico lo justifiquen.

Referencias

Consejo General del Poder Judicial (2026). Instrucción 2/2026, sobre la utilización de sistemas de inteligencia artificial en el ejercicio de la actividad jurisdiccional. BOE-A-2026-2205.

Constitución Española (1978), artículos 18, 24, 106, 117, 121 y 122. https://www.boe.es/buscar/act.php?id=BOE-A-1978-31229

Dahl, M., Magesh, V., Suzgun, M. y Ho, D. E. (2024). Large Legal Fictions: Profiling Legal Hallucinations in Large Language Models. *Journal of Legal Analysis*, 16(1), 64-93.

Ley Orgánica 7/2021, de 26 de mayo, de protección de datos personales tratados para fines de prevención, detección, investigación y enjuiciamiento de infracciones penales y de ejecución de sanciones penales, artículos 8, 13 y 35. https://www.boe.es/buscar/act.php?id=BOE-A-2021-8806

Luo, D. et al. (2025). Graph-R1: Towards Agentic GraphRAG Framework via End-to-end Reinforcement Learning. arXiv:2507.21892.

Magesh, V., Surani, F., Dahl, M., Suzgun, M., Manning, C. D. y Ho, D. E. (2025). Hallucination-Free? Assessing the Reliability of Leading AI Legal Research Tools. *Journal of Empirical Legal Studies*.

Real Decreto 190/1996, de 9 de febrero, por el que se aprueba el Reglamento Penitenciario, artículos 66, 105 y 260. https://www.boe.es/buscar/act.php?id=BOE-A-1996-3307

Reglamento (UE) 2024/1689 del Parlamento Europeo y del Consejo, de 13 de junio de 2024, de Inteligencia Artificial, artículos 3.34, 6.3, 10, 43, 74 y 99, considerando 15 y Anexo III. https://eur-lex.europa.eu/eli/reg/2024/1689/oj?locale=es

Secretaría General de Instituciones Penitenciarias (2022). Instrucción 4/2022, de 28 de julio, sobre tratamiento de datos obtenidos mediante videovigilancia penitenciaria.

Zanella, L. et al. (2024). Harnessing Large Language Models for Training-free Video Anomaly Detection (LAVAD). arXiv:2404.01014.

ReJust (2026). Memoria del Sprint 1 (Especificación y Datos), memoria del Sprint 2 (documento principal, Anexos I a V, Robustez y Mejoras a raíz del debate) y documentación del Sprint 3 (Límites, emergencias y rendición de cuentas; Usuarios y colectivos vulnerables; Anexo VI; Apéndice de respuesta a las críticas del debate del Sprint 2). Universidad Complutense de Madrid.