Anexo VI: Métricas de Equidad y Mínimos Autoimpuestos

Métricas de Equidad (Fairness) en ReJust Para garantizar que los compromisos de diseño a favor de la equidad se cumplan en la práctica, establecemos las siguientes métricas con sus respectivos umbrales máximos de tolerancia:

- **Distribución equitativa de errores (Impacto dispar y Traducciones):** Evaluaremos la tasa de recuperación documental para asegurar que los fallos no se concentren en colectivos vulnerables ni en formatos menos estandarizados.
    - **Umbral de pruebas de descargo:** La diferencia en la tasa de omisión de pruebas favorables a la persona interna entre distintos grupos sociodemográficos no podrá superar un 3%.
    - **Umbral de barrera lingüística:** La tasa de acierto en la recuperación de información no podrá degradarse más de un 3% al procesar expedientes con documentos traducidos frente a los redactados originalmente en castellano.
    - **Requisito estadístico:** Para que estas mediciones por grupos no arrojen falsos positivos, fijamos un tamaño de muestra mínimo (N) de 500 procedimientos documentados por cada grupo demográfico analizado.
- **Paridad técnica en búsqueda audiovisual:** Al operar bajo demanda para localizar incidentes ya documentados, nuestro modelo de Pose Estimation debe garantizar la equidad al recuperar evidencias en vídeo. Mediremos el sesgo técnico asociado a la constitución física o las condiciones de movilidad.
    - **Umbral de recuperación:** Dado que una tasa de acierto matemáticamente idéntica es inviable en entornos reales, fijamos un diferencial máximo permitido del 5% en la precisión al localizar a personas con movilidad reducida (ej. usuarios en silla de ruedas) frente a internos sin problemas de movilidad. Si el margen es mayor, el uso del módulo audiovisual se suspende para revisión.
- **Pruebas Contrafactuales de Neutralidad:** Exigimos que las variables protegidas no alteren bajo ningún concepto el resultado algorítmico.
    - **Umbral de invariabilidad:** Realizaremos test de perturbación modificando únicamente un atributo sensible en expedientes de prueba (por ejemplo, cambiar la nacionalidad española a una extranjera manteniendo idénticos los hechos). La métrica exigida es un 0% de variación en la síntesis de pruebas y recuperación de jurisprudencia. Si la salida cambia, el caso detona una auditoría interna.

Mínimos autoimpuestos (Líneas rojas) de ReJust Estas son las reglas inquebrantables de nuestra arquitectura. Si el sistema no las cumple, no entra en producción o se desconecta:

- **Suspensión técnica frente a regresiones:** Antes de cada actualización del modelo, ejecutamos una batería de pruebas adversarias obligatoria. Nuestra regla de oro para el despliegue es estricta: si una versión candidata falla un

solo caso límite que la versión anterior lograba superar, la actualización no se despliega.

- **Bloqueo por falta de verificación normativa:** Toda cita de jurisprudencia o legislación recuperada por el sistema se comprueba automáticamente contra las fuentes oficiales (BOE/CENDOJ). Nos imponemos la regla de exigir un 100% de coincidencia. Lo que no se verifica en la fuente oficial queda bloqueado y no puede entrar en el razonamiento del borrador.
- **Abstención obligatoria ante ambigüedad:** Hemos impuesto por diseño que el modelo no pueda alucinar ni resolver contradicciones por su cuenta para forzar una respuesta útil. Si los informes de un caso chocan frontalmente y faltan pruebas objetivas (ej. un parte médico), y el índice de confianza algorítmica baja del 90%, el sistema tiene la obligación de abstenerse de emitir una síntesis, limitándose a trasladar la incertidumbre y la contradicción al juez.
- **El Kill Switch frente a la utilidad humana:** Este es nuestro compromiso ético fundamental. El éxito de ReJust no lo mediremos por la rapidez. Si las auditorías independientes y los proyectos piloto demuestran que el sistema no logra superar las garantías procesales y de equidad que ofrecería una inversión equivalente en personal judicial humano, el proyecto se retirará definitivamente.