ReJust — Sprint 4: Propiedad intelectual

Rodrigo Mendoza García · Andrea Nicolás Romero · Pablo Medina Salmón · Jesús María Rodríguez García · Alberto Diez Álvarez · Lucas León Siguero

Ética de Datos y de IA · Facultad de Informática · Universidad Complutense de Madrid · Noviembre de 2026

Este sprint cierra lo abierto en el Debate 3 y define la propiedad intelectual de ReJust; cada apartado resume un anexo (A1–A6).

1. Cambios tras el Debate 3

En el debate en clase [1] se señalaron siete aspectos poco definidos. Cinco se resolvieron por votación del equipo **[A1]**:

- **Registros desfavorables no sancionados:** solo se usan si están verificados y su relevancia está justificada; nunca se presentan como sanción ni bastan por sí solos para perjudicar a nadie, y se mantiene su plazo máximo de seis meses.
- **Auditoría:** supervisión interna y auditoría externa independiente, con selección transparente, declaración de conflictos de interés y resultados públicos agregados.
- **Equidad:** el 3 % de diferencia entre colectivos pasa a ser una hipótesis; tras el piloto se fijarán también límites absolutos de error, porque todos los colectivos podrían fallar mucho y por igual.
- **Muestras pequeñas:** si no hay casos suficientes para validar una función en un contexto, no se usa en él hasta validarla, y la restricción se revisa para que no acabe excluyendo a nadie de forma permanente.
- **Valoraciones subjetivas:** la IA solo presenta hechos verificados; una anotación como «poca motivación» no se convierte en un hecho.

Las otras dos (quién responde del tratamiento de datos y quién suspende el sistema) dependen de competencias institucionales y no las damos por resueltas: antes del despliegue habrá una matriz de responsables por módulo, y proponemos que la suspensión general la acuerde la autoridad de despliegue de cada módulo, no el proveedor técnico.

2. Licencia de cada componente

Cada licencia se ha comparado con criterios explícitos: para el código, encaje en el sector público, validez en castellano, alcance en red y auditabilidad **[A2]**; para modelos y documentación, herencia del modelo base, datos personales, transparencia ante la defensa, seguridad, encaje público y libertad de uso **[A3]**.

Componente	Licencia	Por qué, y qué descartamos
Código propio	**EUPL-1.2** (software libre)	Aprobada por la OSI y reconocida como libre por la FSF [2,3], su copyleft alcanza el acceso en red [4] y el art. 97.2 del RDL 6/2023 la prevé para las aplicaciones de Justicia de fuentes abiertas [5]. MIT y Apache 2.0 permitirían cerrar el desarrollo público; GPLv3 no cubre el uso como servicio; de la AGPLv3 solo es oficial la versión inglesa; una licencia propietaria impediría auditar el sistema.
Dependencias	Las suyas	PyTorch (BSD-3), Transformers (Apache 2.0), FastAPI y React (MIT), PostgreSQL y pgvector: permisivas y compatibles. Ultralytics YOLO obligaría a distribuir el módulo bajo AGPL-3.0 o a comprar su licencia comercial [6]; lo sustituye MMPose (Apache 2.0) [7].
Pesos de ReJust-Sentencia	**CC BY-SA 4.0** sobre base Apache o MIT	Se ajustan con casos sintéticos, documentación propia y textos legales, así que publicarlos no expone datos de las causas y la defensa puede probarlos. Apache no mantiene abiertas las mejoras, la EUPL no aclara qué es el «código fuente» de unos pesos y OpenRAIL-M restringe el uso judicial [8]. Cerrarlos solo frenaría ataques de caja blanca, que además se transfieren [9]; el riesgo real son documentos manipulados en el expediente.
Pesos de ReJust-Seguimiento	Sin licencia pública	Se ajustan con grabaciones de actores cedidas solo al Ministerio, y un detector no tiene otra vía de ataque: con sus pesos sería fácil buscar movimientos que no reconoce. Acceden auditores, autoridad de supervisión, MNPT, peritos de la defensa y, por convenio, otras administraciones penitenciarias.
Casos sintéticos	**ODbL 1.0** y DbCL 1.0	La ODbL regula el derecho *sui generis* de la colección y exige reciprocidad [10]; la DbCL cubre el texto de cada caso [11]. CC0 perdería esa reciprocidad.
Escenas sintéticas	CC BY-NC-SA 4.0	Reutilizables sin fin comercial; los vídeos brutos de actores no se publican.
Fuentes jurídicas	Sin licencia propia	Leyes y sentencias carecen de derechos de autor (art. 13 TRLPI) [12], pero el CENDOJ se reutiliza en las condiciones del CGPJ [13], mediante convenio; los expedientes siguen bajo reserva y la LO 7/2021 [14].
Documentación	**CC BY 4.0**	Licencia por defecto de la Comisión Europea [15]; obliga a indicar cambios, así que una versión alterada no pasa por oficial. BY-SA frenaría su reutilización y BY-ND su traducción. La documentación técnica no se publica por seguridad, y las autoridades que la reciben deben guardar su confidencialidad (art. 78 RIA) [16].

Las incompatibilidades han cambiado decisiones previas. LEGAL-BERT, referencia del Sprint 1, está en inglés y fijaría de antemano la licencia de cualquier derivado [17], así que el LLM jurídico partirá de una base generativa Apache 2.0 en español, como ALIA [18]; RoBERTalex queda como alternativa para la recuperación [19]. De LAVAD (Sprint 1) solo se conserva la idea, porque Llama 2 impone su política de uso e ImageBind es no comercial [20–22]. El motor carga los pesos

como archivos externos, así que el copyleft del código no se extiende a ellos. Quedan dos vías para ofrecer mejoras como servicio sin publicarlas: CC BY-SA no cubre ese uso, y la cláusula de compatibilidad de la EUPL permite redistribuir una obra combinada bajo GPLv3. Las cerramos por contrato: los pliegos exigen entregar todo peso modificado y mantener bajo la EUPL lo entregado. Vetar la videovigilancia masiva con las escenas no cabe en la licencia, porque una Creative Commons con condiciones añadidas deja de serlo [23]; irá en una política de uso, que no obliga a terceros. El archivo `LICENSE` de la raíz del repositorio contiene la EUPL-1.2 en inglés, la versión que reconoce GitHub y que vale lo mismo que la castellana (art. 13) [4].

3. Modelo de software libre

El titular sería el Ministerio de Justicia, que no busca ingresos, así que más que un modelo de negocio necesita uno de sostenibilidad. Tras comparar siete opciones, adoptamos uno híbrido **[A4]**: (1) titularidad y gobierno públicos, con un equipo propio que aprueba cada cambio y custodia los pesos restringidos; (2) desarrollo contratado con cesión de derechos (art. 308.1 LCSP) [24] y entrega continua del código y los pesos, no al final del contrato; y (3) cooperación con otras administraciones. La puesta a disposición es gratuita (art. 97.1 RDL 6/2023) [5]; las comunidades autónomas que reutilicen ReJust formalizan un convenio (art. 97.3), que sirve también para codesarrollar y repartir el mantenimiento.

Descartamos tres modelos. El *open core* cobraría aparte justo las garantías (verificador de citas, registros, controles de equidad), sin las que un sistema de alto riesgo no puede desplegarse. La licencia dual vendería excepciones al copyleft, que es lo que quisimos evitar al descartar MIT, y obligaría a concentrar los derechos con acuerdos de cesión (CLA). Un servicio gestionado por una empresa privada le daría acceso a expedientes bajo reserva y el control de la versión en uso.

Una licencia libre no elimina el *lock-in*, porque si solo la adjudicataria sabe desplegar el sistema la dependencia sigue. Por eso los pliegos exigen un plan de salida probado antes de acabar el contrato y prescripciones sin marcas concretas (art. 126 LCSP) [24], y un cambio de licencia del modelo base no llega a la versión validada sin revisión. Para no chocar con la comunidad, las contribuciones se aceptan con DCO y no con CLA [25]: cada autor conserva sus derechos y los licencia bajo la EUPL. Los *forks* son legítimos, pero no son «ReJust validado». Quien modifica sustancialmente un sistema de alto riesgo pasa a ser su proveedor (art. 25.1 RIA) [16], y en el directorio de aplicaciones judiciales (art. 98 RDL 6/2023) solo figurarán las versiones validadas.

4. Aspectos adicionales elegidos

Plan de entrenamiento sin violación de copyright [A5]. No entrenamos desde cero con millones de resoluciones. Usamos un modelo preentrenado con licencia adecuada, a cuyo proveedor exigimos la política de derechos de autor y el resumen de datos de entrenamiento del art. 53.1 c) y d) RIA [16], RAG para la legislación y la jurisprudencia, y un ajuste limitado con casos ficticios. El criterio es consultar los expedientes, no aprender de ellos. Entrenar, indexar y consultar se autorizan por separado, porque acceder a una fuente no permite entrenar con ella. Los comentarios editoriales (arts. 10 y 11 TRLPI) y las bases que recopilan sentencias (arts. 12 y 133) pueden estar protegidos, y la excepción de minería de textos decae si el titular se reserva ese uso (art. 67.3 RDL 24/2021; art. 4 Directiva 2019/790) [26,27]. Antes de cada versión se comprueba que el modelo no reproduce material protegido de terceros ni información confidencial [28]. Ante una reclamación de copyright se suspende el uso de la fuente; si es fundada, se regenera el índice o, si el material llegó a los pesos, se vuelve a una versión validada o se repite el ajuste, porque el *machine unlearning* no garantiza el borrado [29]. El plan se elaboró con apoyo de IA [30].

Inventario de activos y titularidades [A4]. Recoge 32 activos (código, dependencias, modelos, datos, índices, documentación, trazas, secretos y denominación) con su titular o custodio, título, licencia y acceso. El Ministerio es titular de lo que crea su personal (arts. 51 y 97.4 TRLPI) [12] y de lo que entregan las adjudicatarias (art. 308.1 LCSP), con pliegos que fijen modalidades, ámbito y plazo para que la cesión no quede limitada a cinco años (art. 43 TRLPI). De modelos base, dependencias y contribuciones externas solo tiene licencia, y expedientes y trazas siguen custodiados por juzgados, CGPJ o prisiones. Los *embeddings* del CENDOJ no dan derechos sobre esa colección. Como búsqueda exploratoria, hemos encontrado un portal judicial rumano llamado también ReJust [31]. Por ello, aunque mantenemos el nombre para nuestro proyecto académico, sería necesario comprobar su disponibilidad como marca antes de utilizarlo oficialmente.

GitHub Community Standards [A6]. Además del README, la descripción y los reportes de contenido, hemos definido seis elementos del perfil de comunidad [32]: `LICENSE`, código de conducta, `CONTRIBUTING`, `SECURITY` y plantillas de incidencia y de *pull request*. El código de conducta adapta el Contributor Covenant 3.0 [33], sucesor de la versión 2.0 que ofrece GitHub, con dos reglas propias porque el proyecto trata causas penales: no se publican datos de causas ni de personas aunque consten en otra fuente, y se puede criticar a las instituciones, pero no señalar a individuos. Los demás archivos son propios, porque recogen las líneas rojas y el protocolo de brechas del Sprint 3: `CONTRIBUTING` rechaza todo cambio que cruce una línea roja y exige revisión jurídica si afecta a fuentes o citas. Como GitHub es público, los afectados por una decisión reclaman en una ventanilla aparte, con acuse en 48 horas.

5. Qué queda abierto

Todo esto son compromisos de diseño, no resultados comprobados: una función que no alcance sus garantías seguirá desactivada o se retirará. Quedan pendientes la matriz de responsables, la designación del auditor, el acceso de la defensa a los pesos restringidos y el registro de la marca [34]. El software libre ahorra licencias, no el coste de revalidar y auditar.

Referencias

Anexos de este sprint (repositorio público)

[A1] Anexo — Mejoras y aclaraciones tras el Debate 3.

[A2] Anexo II — Licenciamiento de código fuente y conjuntos de datos.

[A3] Anexo — Licencias de los modelos y de la documentación.

[A4] Anexo — Modelo de software libre e inventario de activos y titularidades.

[A5] Anexo — Plan de entrenamiento sin violación de copyright.

[A6] Anexo — GitHub Community Standards y respuesta a reclamaciones.

Fuentes citadas

[1] Debate 3 de la asignatura y votación posterior del equipo sobre cinco cuestiones pendientes, recogidos en [A1].

[2] Open Source Initiative. European Union Public Licence, version 1.2. https://opensource.org/license/eupl-1-2

[3] Free Software Foundation. Various Licenses and Comments about Them: EUPL-1.2. https://www.gnu.org/licenses/license-list.html#EUPL-1.2

[4] Comisión Europea (2017). Decisión de Ejecución (UE) 2017/863, por la que se actualiza la EUPL (v1.2), arts. 1, 5 y 13 y apéndice. https://eur-lex.europa.eu/eli/dec_impl/2017/863/oj

[5] España (2023). Real Decreto-ley 6/2023, de 19 de diciembre, arts. 97 y 98. https://www.boe.es/buscar/act.php?id=BOE-A-2023-25758

[6] Ultralytics. Repositorio y licencias (AGPL-3.0 o comercial). https://github.com/ultralytics/ultralytics

[7] OpenMMLab. MMPose (Apache 2.0). https://github.com/open-mmlab/mmpose

[8] BigScience (2022). BigScience Open RAIL-M License, anexo A, letra (m). https://licenses.ai/s/BigScience-Open-RAIL-M-License.pdf

[9] Zou, A. et al. (2023). Universal and Transferable Adversarial Attacks on Aligned Language Models. https://arxiv.org/abs/2307.15043

[10] Open Data Commons (2009). Open Database License (ODbL) v1.0. https://opendatacommons.org/licenses/odbl/1-0/

[11] Open Data Commons. Database Contents License (DbCL) v1.0. https://opendatacommons.org/licenses/dbcl/1-0/

[12] España (1996). Real Decreto Legislativo 1/1996, Texto Refundido de la Ley de Propiedad Intelectual, arts. 10–13, 43, 51, 97.4 y 133. https://www.boe.es/buscar/act.php?id=BOE-A-1996-8930

[13] CGPJ (2010). Reglamento 3/2010, sobre reutilización de sentencias y otras resoluciones judiciales. https://www.boe.es/buscar/doc.php?id=BOE-A-2010-17860

[14] España (2021). Ley Orgánica 7/2021, de protección de datos personales tratados con fines penales. https://www.boe.es/buscar/act.php?id=BOE-A-2021-8806

[15] Comisión Europea (2019). Decisión C(2019) 1655 sobre la reutilización de la información de la Comisión. https://digital-strategy.ec.europa.eu/en/news/rules-reuse-commission-information

[16] Unión Europea (2024). Reglamento (UE) 2024/1689 de inteligencia artificial (RIA), arts. 11, 25, 53, 78 y anexo III. https://eur-lex.europa.eu/eli/reg/2024/1689/oj/spa

[17] nlpaueb. LEGAL-BERT, ficha del modelo (CC BY-SA 4.0). https://huggingface.co/nlpaueb/legal-bert-base-uncased

[18] BSC-LT. ALIA-40b-instruct, ficha del modelo (Apache 2.0). https://huggingface.co/BSC-LT/ALIA-40b-instruct-2606

[19] PlanTL-GOB-ES. RoBERTalex, ficha del modelo (Apache 2.0). https://huggingface.co/PlanTL-GOB-ES/RoBERTalex

[20] Zanella, L. et al. (2024). Harnessing Large Language Models for Training-free Video Anomaly Detection (LAVAD). CVPR. https://arxiv.org/abs/2404.01014

[21] Meta (2023). Llama 2 Community License Agreement. https://ai.meta.com/llama/license/

[22] Meta AI. ImageBind, repositorio y licencia no comercial. https://github.com/facebookresearch/ImageBind

[23] Creative Commons. FAQ: Can I change the license terms or conditions? https://creativecommons.org/faq/#can-i-change-the-license-terms-or-conditions

[24] España (2017). Ley 9/2017, de Contratos del Sector Público (LCSP), arts. 126 y 308. https://www.boe.es/buscar/act.php?id=BOE-A-2017-12902

[25] Linux Foundation. Developer Certificate of Origin, v1.1. https://developercertificate.org/

[26] España (2021). Real Decreto-ley 24/2021, art. 67 (minería de textos y datos). https://www.boe.es/buscar/act.php?id=BOE-A-2021-17910

[27] Unión Europea (2019). Directiva (UE) 2019/790, sobre los derechos de autor en el mercado único digital, arts. 3 y 4. https://eur-lex.europa.eu/eli/dir/2019/790/oj

[28] Carlini, N. et al. (2021). Extracting Training Data from Large Language Models. USENIX Security. https://www.usenix.org/conference/usenixsecurity21/presentation/carlini-extracting

[29] Cooper, A. F. et al. (2024). Machine Unlearning Doesn't Do What You Think: Lessons for Generative AI Policy and Research. https://arxiv.org/abs/2412.06966

[30] Conversación con ChatGPT usada para el plan de entrenamiento [A5]. https://chatgpt.com/c/6ab810b5-5f20-83ed-8771-1543e4b702ca

[31] ReJust, portal judicial de Rumanía. https://www.rejust.ro/

[32] GitHub Docs. About community profiles for public repositories. https://docs.github.com/en/communities/setting-up-your-project-for-healthy-contributions/about-community-profiles-for-public-repositories

[33] Organization for Ethical Source (2025). Contributor Covenant 3.0. https://ethicalsource.dev/blog/contributor-covenant-3

[34] España (2001). Ley 17/2001, de 7 de diciembre, de Marcas. https://www.boe.es/buscar/act.php?id=BOE-A-2001-23093

Documentación previa: resúmenes y anexos de los Sprints 1–3 en https://github.com/EthicsAI-UCM/ReJust.