ANEXO — PLAN DE ENTRENAMIENTO SIN VIOLACIÓN DE COPYRIGHT

1. Objeto y alcance

ReJust adoptará una estrategia de entrenamiento y utilización de datos orientada a reducir los riesgos de vulneración de derechos de propiedad intelectual, manteniendo la trazabilidad de los materiales utilizados y respetando las restricciones legales y contractuales aplicables.

El sistema no necesitará entrenar un modelo fundacional desde cero con millones de expedientes judiciales o penitenciarios. Se priorizará la utilización de un modelo lingüístico previamente entrenado y autorizado, combinado con recuperación documental (RAG) y ajustes especializados limitados a conjuntos de datos cuya procedencia y utilización estén justificadas.

Esta decisión responde tanto a criterios jurídicos como técnicos. ReJust necesita recuperar información actualizada, contrastar fuentes y organizar documentación, no memorizar las resoluciones judiciales ni aprender a reproducir el criterio de cada juez. Además, incorporar grandes cantidades de documentos protegidos al entrenamiento dificultaría identificar su procedencia, controlar su reproducción y retirar posteriormente materiales utilizados de forma indebida.

Se distinguirán cuatro operaciones: entrenamiento, consulta documental, indexación y evaluación. Cada una podrá requerir permisos diferentes. El acceso legítimo a un documento no implicará automáticamente autorización para incorporarlo al entrenamiento, y su disponibilidad pública tampoco garantizará libertad de reutilización.

La estrategia seguirá la normativa española y europea de propiedad intelectual, especialmente el Texto Refundido de la Ley de Propiedad Intelectual, la Directiva (UE) 2019/790 y su transposición mediante el Real Decreto-ley 24/2021, así como las obligaciones aplicables del Reglamento Europeo de Inteligencia Artificial [1–4].

2. Arquitectura de entrenamiento propuesta

ReJust utilizará una arquitectura que permita separar la información aprendida por el modelo de los documentos consultados durante su funcionamiento.

2.1. Modelo lingüístico preentrenado

Se seleccionará un modelo previamente entrenado por un tercero, cuya licencia o contrato permita su utilización en el ámbito institucional, su integración con las funcionalidades previstas y, cuando resulte necesario, la realización de ajustes especializados.

Antes de incorporarlo, se comprobarán las condiciones de utilización, las restricciones de licencia, la documentación disponible sobre sus datos de entrenamiento, los riesgos conocidos de copyright y las garantías relacionadas con el tratamiento de información confidencial.

La elección definitiva del modelo se realizará atendiendo a las alternativas disponibles en el momento de implantación. No se considerará que la publicación de los pesos o del código garantiza por sí sola que los materiales utilizados en el entrenamiento original hayan sido obtenidos legítimamente.

Se priorizarán soluciones que permitan mantener versiones validadas, controlar las actualizaciones y evitar la utilización de expedientes de ReJust para entrenar sistemas externos sin una habilitación específica.

2.2. Ajustes especializados mediante fine-tuning

El fine-tuning se utilizará únicamente cuando aporte una mejora demostrable frente al modelo original y la recuperación documental.

Su finalidad será enseñar al sistema a realizar tareas concretas, como identificar las partes de un documento, organizar argumentos, distinguir hechos de alegaciones, presentar referencias verificables o reconocer situaciones en las que debe abstenerse.

Los ejemplos utilizados procederán preferentemente de situaciones jurídicas ficticias elaboradas específicamente para ReJust, documentación original o conjuntos de datos cuyo régimen jurídico autorice expresamente el ajuste previsto.

No se utilizarán automáticamente expedientes judiciales reales, consultas de los profesionales ni decisiones anteriores de los jueces para modificar el modelo. Esta restricción mantiene la política de personalización del Sprint 2 y evita que el sistema aprenda patrones decisorios individuales.

Asimismo, se realizarán pruebas para comprobar que los ajustes no provocan la memorización o reproducción indebida de materiales protegidos. La investigación de Carlini et al. (2021) demuestra que determinados modelos de lenguaje pueden reproducir fragmentos presentes en sus datos de entrenamiento, por lo que no se considerará suficiente eliminar los documentos originales después de entrenar [9].

2.3. Recuperación documental mediante RAG

La recuperación aumentada por generación, o RAG, constituirá el mecanismo principal de acceso a legislación, jurisprudencia y otras fuentes autorizadas.

ReJust-Sentencia podrá recuperar documentos relevantes, contrastar referencias y presentar argumentos vinculados a sus fuentes sin incorporar automáticamente dichos textos a los parámetros del modelo.

Este enfoque permitirá actualizar la legislación y jurisprudencia disponibles sin necesidad de volver a entrenar el modelo cada vez que se produzca una modificación normativa o se publique una nueva resolución.

Sin embargo, RAG no elimina las obligaciones de propiedad intelectual. Descargar una base jurídica, dividir sus documentos en fragmentos, generar embeddings, construir índices y reproducir contenido en una respuesta son operaciones que deberán ajustarse a los permisos y condiciones correspondientes.

Por ello, cada fuente incorporada a la biblioteca jurídica tendrá asociada información sobre su procedencia, condiciones de acceso, posibilidad de indexación, restricciones de reproducción y finalidad autorizada.

2.4. Separación de entornos

Se establecerán tres entornos diferenciados:

Entorno de entrenamiento: contendrá únicamente ejemplos y conjuntos de datos aprobados para entrenamiento o ajuste, con sus respectivas autorizaciones y registros de procedencia.

Biblioteca jurídica: incorporará legislación, jurisprudencia y otras fuentes que puedan adquirirse, indexarse y consultarse legítimamente. Los materiales se mantendrán actualizables y sometidos a sus condiciones de reutilización.

Entorno de expedientes: permitirá procesar documentación judicial y penitenciaria exclusivamente dentro de los procedimientos y finalidades autorizados. Su contenido permanecerá separado del entrenamiento general.

La información del tercer entorno no podrá transferirse automáticamente al primero. Cualquier posible utilización posterior para desarrollo o evaluación requerirá una justificación independiente y los permisos correspondientes.

3. Clasificación jurídica de las fuentes

No todas las fuentes utilizadas por ReJust tienen el mismo régimen de propiedad intelectual. Por ello, antes de incorporar cualquier conjunto de datos deberá determinarse qué operaciones están permitidas y cuáles requieren autorización adicional.

3.1. Legislación española y europea

El artículo 13 del Texto Refundido de la Ley de Propiedad Intelectual excluye de protección las disposiciones legales y reglamentarias, sus proyectos y determinadas resoluciones y documentos oficiales [1].

Por tanto, el texto oficial de una ley no tiene el mismo régimen que un manual jurídico privado que la comenta.

Para ReJust se priorizará la obtención de legislación española mediante los servicios oficiales del BOE y de normativa europea mediante EUR-Lex. Se conservarán identificadores, procedencia, versiones y fechas de vigencia para permitir la recuperación de la norma aplicable en cada momento.

No obstante, las condiciones generales de reutilización del BOE establecen límites y excepciones, especialmente para determinados materiales editoriales y actividades administrativas públicas. Su utilización institucional deberá articularse conforme al régimen jurídico correspondiente y no únicamente mediante la licencia general del portal [5].

Asimismo, EUR-Lex permite la reutilización de numerosos documentos legales, mientras que determinados contenidos editoriales, resúmenes y textos consolidados están sujetos a condiciones específicas, como CC BY 4.0 [6].

Los códigos comentados, manuales doctrinales, anotaciones editoriales y recopilaciones privadas se tratarán separadamente. Su incorporación al entrenamiento requerirá una licencia, autorización o excepción legal suficiente.

3.2. Jurisprudencia y resoluciones judiciales

Las resoluciones judiciales españolas están excluidas de protección por derechos de autor conforme al artículo 13 del Texto Refundido de la Ley de Propiedad Intelectual. Sin embargo, esta exclusión no supone que cualquier base de datos que las recopile pueda descargarse, indexarse o explotarse sin restricciones.

El Reglamento 3/2010 del CGPJ establece distintas modalidades de reutilización de sentencias y resoluciones judiciales, incluidas modalidades sin condiciones especiales, mediante licencias o previa autorización [7].

En consecuencia, ReJust deberá verificar el régimen aplicable a las resoluciones obtenidas del CENDOJ y las condiciones para su adquisición, almacenamiento, indexación y utilización institucional.

Se diferenciará el texto de la resolución de los posibles comentarios, resúmenes, clasificaciones u otros contenidos añadidos por terceros. La autorización para consultar una base jurídica privada no implicará necesariamente permiso para utilizarla en entrenamiento.

También se examinarán las condiciones particulares de fuentes como el Tribunal Constitucional, el Tribunal de Justicia de la Unión Europea y el Tribunal Europeo de Derechos Humanos, prestando especial atención a las traducciones no oficiales y a los elementos protegidos de terceros.

La reutilización de jurisprudencia deberá evaluarse teniendo en cuenta que determinados intercambios entre organismos públicos, realizados en el ejercicio de sus competencias, reciben un tratamiento distinto en el Reglamento 3/2010. Esta circunstancia no se interpretará como una autorización general para cualquier modalidad de entrenamiento.

3.3. Expedientes judiciales y pruebas

Los expedientes reales constituirán una categoría de acceso restringido y no formarán parte de los conjuntos generales de entrenamiento.

Aunque determinadas resoluciones estén excluidas de copyright, un expediente puede contener informes periciales originales, fotografías, grabaciones, publicaciones privadas, documentos empresariales y otros materiales protegidos.

El artículo 31 bis del Texto Refundido de la Ley de Propiedad Intelectual contempla determinados usos de obras necesarios para el correcto desarrollo de procedimientos judiciales [1]. Sin embargo, procesar una obra para un procedimiento concreto no equivale a poder utilizarla posteriormente para entrenar un modelo destinado a otros procedimientos.

Por ello, ReJust-Sentencia podrá analizar los materiales necesarios dentro del expediente autorizado, manteniendo las restricciones de acceso, finalidad y conservación correspondientes, pero no los reutilizará automáticamente para mejorar futuras versiones.

Esta separación también protegerá la confidencialidad, el secreto de las actuaciones y los datos personales, cuestiones que deberán cumplirse independientemente de la existencia o ausencia de copyright.

3.4. Documentación penitenciaria

ReJust-Seguimiento aplicará el mismo principio de separación de finalidades a los informes penitenciarios, registros administrativos y grabaciones audiovisuales.

Los materiales utilizados durante la ejecución penitenciaria podrán procesarse únicamente para las funciones autorizadas del módulo, sin incorporarse automáticamente a conjuntos generales de aprendizaje.

Las grabaciones reales de personas internas no se utilizarán para el entrenamiento inicial de los modelos audiovisuales. Además de los posibles derechos sobre las grabaciones o sus elementos, existen restricciones relacionadas con la protección de datos, la intimidad, la finalidad del tratamiento y la normativa penitenciaria.

Cualquier utilización posterior de material real para validación o desarrollo requerirá habilitación jurídica suficiente, evaluación de impacto y comprobación específica de los derechos y permisos aplicables.

Se mantendrá la decisión del Sprint 3 de eliminar los puntos corporales obtenidos mediante Pose Estimation después del procesamiento autorizado, impidiendo su incorporación a un repositorio persistente de entrenamiento.

3.5. Datos sintéticos para el componente audiovisual

El entrenamiento inicial de las funcionalidades audiovisuales de ReJust-Seguimiento se realizará mediante escenas sintéticas y materiales producidos específicamente para el proyecto.

Estas simulaciones representarán acontecimientos observables, como caídas, contactos físicos y movimientos parcialmente ocultos, incorporando variaciones de iluminación, perspectivas y condiciones de movilidad.

No obstante, el carácter sintético de un conjunto de datos no garantizará automáticamente que esté libre de derechos de autor. Los escenarios, personajes tridimensionales, texturas, animaciones, sonidos o modelos utilizados pueden pertenecer a terceros y estar sujetos a restricciones.

Se priorizarán recursos originales o con licencias compatibles con su utilización en entrenamiento de IA. Cuando participen actores o colaboradores, se documentarán las autorizaciones necesarias relativas a grabaciones, imagen y posibles reutilizaciones.

Las licencias del software de creación, como Blender, se distinguirán de los derechos sobre los recursos importados y los materiales generados. No se presumirá que utilizar una herramienta libre convierte automáticamente en libres todos los elementos incorporados al conjunto de datos.

La utilización de datos sintéticos permitirá desarrollar el sistema sin entrenarlo inicialmente con vídeos penitenciarios reales, pero no sustituirá la validación técnica y jurídica posterior exigida antes de activar la funcionalidad en condiciones reales.

4. Minería de textos y datos y límites legales

La Directiva (UE) 2019/790 y el artículo 67 del Real Decreto-ley 24/2021 contemplan excepciones y límites relacionados con la minería de textos y datos, entendida como el análisis automatizado de materiales digitales para identificar información, patrones o relaciones [2, 3].

La Directiva distingue la minería destinada a investigación científica, realizada por determinadas entidades, de la excepción general aplicable en otras circunstancias.

Esta última permite determinadas reproducciones y extracciones de materiales legítimamente accesibles, siempre que se cumplan las condiciones legales y no exista una reserva válida de derechos por parte del titular.

En ReJust no se supondrá que todos los materiales publicados en Internet pueden utilizarse libremente para entrenar modelos, ni que la finalidad académica inicial del proyecto autoriza automáticamente su explotación institucional posterior.

La utilización de conjuntos de datos para investigación universitaria y su incorporación a un sistema público desplegado en 2030 se evaluarán como situaciones diferentes.

Asimismo, se tendrán en cuenta los posibles derechos sobre bases de datos, incluidos los relacionados con su estructura y con la extracción o reutilización de contenidos. La ausencia de copyright sobre una resolución judicial no elimina necesariamente los derechos que puedan existir sobre la colección que la contiene.

Respecto al Reglamento Europeo de Inteligencia Artificial, el artículo 53 establece obligaciones relacionadas con copyright y transparencia de datos de entrenamiento para proveedores de modelos de propósito general [4].

ReJust deberá comprobar qué obligaciones corresponden al proveedor del modelo seleccionado y cuáles a la institución responsable de integrar y desplegar el sistema. La utilización de un modelo preentrenado no trasladará automáticamente todas las obligaciones del proveedor original a ReJust, pero tampoco eximirá al proyecto de comprobar las licencias y condiciones de utilización.

5. Plan de entrenamiento y autorización de datos

Se establecerá un procedimiento de seis fases para incorporar materiales al entrenamiento, la evaluación y la biblioteca documental.

Fase 1. Selección de fuentes

El equipo técnico y los especialistas jurídicos identificarán los conjuntos necesarios para cada funcionalidad, evitando adquirir datos que no aporten una utilidad justificada.

La selección diferenciará entre materiales destinados a entrenamiento, consulta, indexación y evaluación.

Fase 2. Comprobación de derechos

Cada conjunto deberá contar con una ficha que identifique su procedencia, titularidad cuando corresponda, licencia, autorización o excepción aplicable, reservas de derechos, restricciones y finalidades permitidas.

La revisión jurídica distinguirá cuatro situaciones:

- **Autorizado:** las operaciones previstas están suficientemente justificadas.
- **Restringido a consulta:** se permite acceder al contenido, pero no utilizarlo para entrenamiento.
- **Pendiente de revisión:** existen dudas que impiden su incorporación hasta que se resuelvan.
- **Excluido:** los permisos disponibles son incompatibles con la finalidad prevista.

Un conjunto no pasará a entrenamiento ni a indexación masiva de producción mientras no puedan acreditarse los derechos necesarios.

Fase 3. Preparación y separación

Los materiales aprobados se incorporarán a un entorno de preparación aislado, donde se revisarán duplicados, datos sensibles, restricciones de uso y posibles contenidos de terceros.

Se aplicarán permisos diferenciados para impedir que los expedientes judiciales, los registros penitenciarios o los documentos disponibles únicamente para consulta se incorporen por error al entrenamiento.

Fase 4. Entrenamiento o ajuste

Se utilizarán exclusivamente conjuntos previamente aprobados y versionados.

Cada ejecución conservará un registro de los modelos, ejemplos, datasets y configuraciones utilizados. La incorporación de nuevas fuentes exigirá repetir las comprobaciones jurídicas correspondientes.

No se permitirá aprendizaje automático continuo a partir de consultas reales de jueces o profesionales penitenciarios.

Fase 5. Evaluación

Antes de desplegar una nueva versión se realizarán pruebas técnicas, jurídicas y de seguridad.

Además de las evaluaciones de rendimiento establecidas en el Sprint 3, se comprobará la posible reproducción de material protegido, la memorización de ejemplos, la exposición de información confidencial y el cumplimiento de los permisos de recuperación documental.

Las pruebas incluirán consultas diseñadas para intentar obtener fragmentos extensos de material utilizado durante el ajuste. La ausencia de reproducciones detectadas no se considerará prueba absoluta de que no exista memorización.

La versión solo podrá desplegarse tras superar las evaluaciones correspondientes.

Fase 6. Mantenimiento y retirada

Las fuentes y licencias se revisarán durante todo el ciclo de vida del sistema.

Cuando se detecte una nueva restricción, una reserva de derechos aplicable o una reclamación fundada, se comprobarán las versiones y componentes afectados.

Si el problema afecta a un índice documental, se podrá bloquear el contenido y retirar o regenerar sus representaciones derivadas.

Cuando afecte a materiales utilizados para entrenar un modelo, la solución será más compleja, porque la información aprendida puede encontrarse distribuida entre sus parámetros.

En ese caso se valorará suspender la versión afectada, restaurar una anterior validada o repetir el ajuste utilizando únicamente materiales autorizados. No se considerará que las técnicas de machine unlearning garantizan por sí solas la eliminación completa de cualquier influencia previa.

6. Registro de procedencia y trazabilidad

ReJust incorporará un registro de procedencia para todos los conjuntos utilizados, que se coordinará con el inventario de activos y titularidades del Sprint 4.

Cada conjunto deberá documentar, como mínimo, su identificación, origen, titular de derechos cuando proceda, licencia o autorización, evidencia jurídica, fecha de adquisición, versión, finalidad permitida, restricciones, condiciones de conservación y componentes autorizados.

También se registrará qué versiones de los modelos o índices utilizan dicho conjunto. Esto permitirá identificar dependencias cuando una fuente deba corregirse, actualizarse o retirarse.

La procedencia se documentará para operaciones específicas, evitando clasificaciones demasiado generales como «datos públicos» o «licencia válida». Por ejemplo, una autorización para consultar una base de jurisprudencia no se interpretará automáticamente como autorización para generar embeddings persistentes, entrenar modelos o redistribuir sus contenidos.

Los registros deberán permitir reconstruir el origen de los datos sin conservar indefinidamente materiales personales o protegidos cuando no exista una justificación legal para ello.

7. Riesgos de copyright y medidas de control

Se identificarán especialmente los siguientes riesgos:

Incorporación de obras protegidas sin autorización. Se evitará mediante conjuntos cerrados y aprobados para entrenamiento, auditorías de procedencia y revisión de licencias. Si se detecta material incorporado indebidamente, se investigarán las versiones afectadas y se evaluará su retirada o sustitución.

Extracción masiva no autorizada de bases jurídicas. Se utilizarán canales institucionales y condiciones de reutilización verificadas, evitando descargar indiscriminadamente colecciones privadas. Ante un incumplimiento se suspenderá la adquisición y se revisarán los materiales obtenidos.

Reutilización indebida de expedientes. Los entornos de producción y entrenamiento permanecerán separados. Una consulta judicial o penitenciaria no podrá convertirse automáticamente en ejemplo de fine-tuning.

Reproducción excesiva de contenido protegido. ReJust comprobará los permisos de salida de las fuentes recuperadas. Cuando una licencia permita consulta, pero no reproducción íntegra, el sistema priorizará referencias, explicaciones ajustadas a los límites aplicables y enlaces autorizados.

Memorización de información protegida o confidencial. Se limitarán los ajustes, se utilizarán conjuntos controlados y se realizarán pruebas de reproducción. Si se detectan fugas relevantes, se suspenderá el componente afectado y se investigará su origen.

Datos sintéticos con recursos incompatibles. Se revisarán las licencias de escenarios, animaciones y otros activos. Si algún recurso no autoriza su uso, se sustituirá y se regenerarán los materiales derivados cuando sea necesario.

Incumplimiento de licencias de modelos externos. Antes de integrar una versión se comprobarán sus derechos de utilización, modificación, despliegue y distribución. Los cambios posteriores de licencia se revisarán sin presumir que alteran retroactivamente todos los permisos previamente adquiridos.

Estas medidas no garantizarán la inexistencia absoluta de conflictos, pero permitirán prevenir y detectar usos injustificados y actuar de manera documentada cuando se identifiquen.

8. Escenarios críticos y reclamaciones

8.1. Incorporación accidental de comentarios de una editorial

Si una editorial detectase que ReJust ha utilizado sus comentarios jurídicos para ajustar un modelo sin autorización suficiente, se identificarían el conjunto y las versiones afectadas.

Se suspendería el uso del material cuestionado mientras se revisa la reclamación y, si se confirma una utilización indebida, se determinarían las medidas de corrección pertinentes.

Cuando el contenido se hubiera incorporado a los parámetros del modelo, no bastaría con eliminar el archivo original. Podría resultar necesario recuperar una versión anterior o repetir el ajuste desde conjuntos autorizados.

8.2. Documento protegido incorporado a un expediente

Si una fotografía o informe privado se incorporase legítimamente a un procedimiento judicial, ReJust podría procesarlo dentro del uso autorizado correspondiente.

Sin embargo, ese mismo documento no podría pasar automáticamente al conjunto general de entrenamiento. Si se detectase dicha transferencia, se bloquearía su reutilización y se investigaría la exposición y los componentes afectados.

8.3. Solicitud de retirada de una fuente

Cuando se reciba una reclamación relacionada con una fuente documental, se verificará la titularidad alegada, el alcance de los derechos y la autorización vigente.

Si procede la retirada, ReJust localizará las copias, fragmentos, índices y versiones relacionadas para aplicar las medidas correspondientes.

Se distinguirá la eliminación de una fuente documental de la posible influencia de dicha fuente en un modelo entrenado, que puede requerir medidas adicionales.

8.4. Cambio de licencia de un modelo

Si el proveedor de un modelo introdujese restricciones incompatibles con el uso institucional previsto, ReJust comprobaría los derechos adquiridos sobre la versión existente y las condiciones aplicables a nuevas actualizaciones.

No se sustituirá automáticamente una versión validada por otra con condiciones diferentes. Si no pudiera mantenerse su utilización legítima, se evaluaría una alternativa técnica previamente validada.

9. Comparación de alternativas y decisión adoptada

Se han considerado tres estrategias principales.

La primera consistiría en entrenar un modelo jurídico desde cero. Aunque permitiría controlar parte del desarrollo, exigiría grandes corpus, recursos computacionales elevados y un proceso complejo de adquisición y verificación de derechos. Además, dificultaría retirar posteriormente materiales incorporados al entrenamiento.

La segunda utilizaría un modelo preentrenado con un fine-tuning jurídico extenso. Reduciría los costes iniciales respecto al entrenamiento completo, pero mantendría una dependencia considerable de grandes cantidades de documentación autorizada y los problemas asociados a su memorización.

La tercera combinaría un modelo preentrenado con RAG y ajustes especializados limitados. Esta opción permitiría concentrar el volumen documental en repositorios consultables y actualizables, manteniendo el entrenamiento adicional reducido a tareas concretas y conjuntos controlados.

ReJust adoptará inicialmente la tercera estrategia, por resultar más adecuada a sus funciones documentales y facilitar la separación entre datos operativos y datos de entrenamiento.

No obstante, esta arquitectura no se considerará automáticamente libre de riesgos jurídicos. La adquisición, indexación, conservación y reproducción de las fuentes deberán seguir justificándose individualmente.

10. Política de entrenamiento y utilización de datos

La política general de ReJust se organizará alrededor de tres categorías.

Materiales admitidos para entrenamiento o ajuste: ejemplos jurídicos originales, situaciones ficticias, conjuntos de datos con licencias compatibles, textos oficiales cuyo uso esté suficientemente justificado y materiales audiovisuales sintéticos con derechos acreditados.

Materiales limitados a consulta o procesamiento específico: expedientes judiciales reales, pruebas incorporadas a procedimientos, informes penitenciarios, grabaciones autorizadas y bases jurídicas que permitan acceso, pero no entrenamiento. Su utilización se limitará a las finalidades y operaciones legalmente habilitadas.

Materiales excluidos: documentos de procedencia desconocida, obras obtenidas sin autorización suficiente, materiales sujetos a restricciones incompatibles, grabaciones reales sin habilitación específica y conjuntos que incorporen recursos de terceros sin permisos adecuados.

Esta clasificación deberá comprobarse técnicamente mediante controles de acceso, separación de entornos, registros de procedencia y validación previa de cada nueva versión.

La política se regirá por seis principios: necesidad de los datos, procedencia verificable, finalidad autorizada, separación entre entrenamiento y operación, revisión continua de derechos y posibilidad de retirar materiales o versiones comprometidas.

11. Conclusión

El plan de entrenamiento de ReJust se basará en reducir la utilización innecesaria de materiales protegidos y comprobar los derechos correspondientes a cada operación realizada sobre ellos.

La combinación de un modelo preentrenado autorizado, RAG y ajustes especializados limitados permitirá desarrollar las funciones previstas sin entrenar indiscriminadamente con millones de documentos judiciales y penitenciarios.

La principal garantía será mantener los expedientes reales separados del aprendizaje del modelo, documentar la procedencia de las fuentes y disponer de mecanismos de revisión, retirada y sustitución cuando se detecten usos no autorizados.

El principio rector será:

«Entrenar con datos autorizados; consultar los expedientes, no aprender de ellos».

Este principio se complementará con una exigencia fundamental:

«El acceso a una fuente no implica autorización para entrenar con ella».

ReJust no prometerá la imposibilidad absoluta de infringir derechos de autor, sino un proceso verificable para minimizar ese riesgo, demostrar la legitimidad de los materiales utilizados y actuar cuando una fuente o componente no pueda mantenerse legalmente.

Referencias

[1] Jefatura del Estado (1996). *Real Decreto Legislativo 1/1996, por el que se aprueba el Texto Refundido de la Ley de Propiedad Intelectual.* Artículos 12, 13, 31 bis y 133 y siguientes. https://www.boe.es/buscar/act.php?id=BOE-A-1996-8930

[2] Parlamento Europeo y Consejo de la Unión Europea (2019). *Directiva (UE) 2019/790 sobre derechos de autor y derechos afines en el mercado único digital.* Artículos 3 y 4. https://eur-lex.europa.eu/eli/dir/2019/790/oj

[3] Jefatura del Estado (2021). *Real Decreto-ley 24/2021, de 2 de noviembre.* Artículo 67: minería de textos y datos. https://www.boe.es/buscar/act.php?id=BOE-A-2021-17910

[4] Parlamento Europeo y Consejo de la Unión Europea (2024). *Reglamento (UE) 2024/1689 por el que se establecen normas armonizadas en materia de inteligencia artificial.* Artículo 53. https://eur-lex.europa.eu/eli/reg/2024/1689/oj

[5] Agencia Estatal Boletín Oficial del Estado (2024). *Condiciones de reutilización de la información de la AEBOE.* https://www.boe.es/informacion/aviso_legal/index.php

[6] Oficina de Publicaciones de la Unión Europea (2026). *EUR-Lex: Legal notice.* https://eur-lex.europa.eu/content/legal-notice/legal-notice.html

[7] Consejo General del Poder Judicial (2010). *Reglamento 3/2010 sobre reutilización de sentencias y otras resoluciones judiciales.* https://www.boe.es/buscar/doc.php?id=BOE-A-2010-17860

[8] Jefatura del Estado (2007). *Ley 37/2007, de reutilización de la información del sector público.* https://www.boe.es/buscar/act.php?id=BOE-A-2007-19814

[9] Carlini, N., Tramèr, F., Wallace, E. et al. (2021). *Extracting Training Data from Large Language Models.* 30th USENIX Security Symposium. https://www.usenix.org/conference/usenixsecurity21/presentation/carlini-extracting

[10] Parlamento Europeo y Consejo (1996). *Directiva 96/9/CE sobre la protección jurídica de las bases de datos.* https://eur-lex.europa.eu/eli/dir/1996/9/oj

[11] Jefatura del Estado (2021). *Ley Orgánica 7/2021, de protección de datos personales tratados para fines penales y de ejecución de sanciones penales.* https://www.boe.es/buscar/act.php?id=BOE-A-2021-8806

[12] Comisión Europea (2025). *Guidelines on the obligations for general-purpose AI providers under the AI Act.* https://digital-strategy.ec.europa.eu/en/faqs/guidelines-obligations-general-purpose-ai-providers

[13] OpenAI (2026). *Conversación con ChatGPT utilizada como apoyo para la investigación y elaboración del apartado «Plan de entrenamiento sin violación de copyright» del proyecto ReJust.* ChatGPT. https://chatgpt.com/c/6ab810b5-5f20-83ed-8771-1543e4b702ca

Documentación interna consultada

ReJust (2026). *Documentación de los Sprints 1, 2 y 3.*

Especialmente las correcciones del Sprint 3 relativas a separación de módulos, tratamiento audiovisual, privacidad, gestión de riesgos y validación.

Repositorio del proyecto: https://github.com/EthicsAI-UCM/ReJust