Anexo: Licencias de los modelos y de la documentación

1. Objeto y alcance

Este anexo fija y justifica la licencia de dos componentes de ReJust: los modelos entrenados y la documentación. Completa el Anexo II, que regula el código fuente (EUPL-1.2) y los conjuntos de datos, y parte del anexo del plan de entrenamiento sin violación de copyright, que determina con qué datos se entrena cada modelo. El inventario de activos y el modelo de negocio toman como entrada la tabla de la sección 8.

Se mantiene lo acordado en sprints anteriores: el Ministerio de Justicia es el proveedor del sistema en el sentido del Reglamento (UE) 2024/1689 y titular de los derechos sobre lo que desarrolla. Las licencias se eligen, por tanto, desde la posición de un organismo público. Cada elección se compara con las alternativas descartadas y se evalúa con los mismos criterios (sección 4), para que la decisión sea trazable.

2. Componentes afectados

ReJust tiene cuatro grupos de modelos con orígenes y datos distintos. Conforme al plan de entrenamiento, ningún modelo se entrena con expedientes reales: la legislación y la jurisprudencia se consultan mediante recuperación documental (RAG) y no se incorporan a los pesos, y los ajustes se hacen con casos sintéticos y material producido para el proyecto. La documentación, por su parte, se divide en pública y restringida.

2.1. Modelos

Componente	**Módulo**	**Función**	**Origen**	**Datos de entrenamiento o ajuste**
LLM jurídico	Sentencia	Análisis del expediente y redacción de la propuesta motivada	Modelo preentrenado de terceros + ajuste limitado	Casos sintéticos textuales (ODbL 1.0) y documentación original
Modelos de recuperación	Sentencia	Indexación y recuperación semántica del tipo ColBERTv2	Terceros (MIT), con posible reajuste	Casos sintéticos y textos legales
Políticas de recuperación	Sentencia	Estrategias de búsqueda aprendidas (inspiradas en Dream-RSI)	Propio	Casos sintéticos en el entorno de entrenamiento; no aprenden de consultas reales
Estimación de pose y clasificación de eventos	Seguimiento	Detección de caídas, contactos físicos y otros acontecimientos en la búsqueda puntual de grabaciones	MMPose (Apache 2.0) + ajuste propio	Escenas sintéticas en Blender (CC BY-NC-SA 4.0) y grabaciones de actores bajo cesión restringida

2.2. Documentación

Documento	Destinatarios	Carácter	Origen de la obligación
Instrucciones de uso	Jueces, jueces de vigilancia, letrados	Pública	Art. 13 del Reglamento (UE) 2024/1689
Ficha de cada modelo y descripción de los datos	Defensa, investigadores, ciudadanía	Pública	Transparencia y derecho de defensa (CE, art. 24)
Informe anual de uso, incidentes y auditorías	Ciudadanía y Parlamento	Pública	Anexo IV del Sprint 3
Documentación técnica del sistema de alto riesgo	Autoridades de supervisión	Restringida	Art. 11 y Anexo IV del Reglamento (UE) 2024/1689
Informes de pruebas adversarias y vulnerabilidades	Equipo técnico y auditores externos	Restringida	Apartado de Robustez del Sprint 2

3. Licencias de terceros que condicionan la elección

Un modelo ajustado se construye sobre los pesos de otro, de modo que la licencia del modelo base limita la del resultado. Se discute si los pesos son obra protegida por derechos de autor; por prudencia, tratamos estas licencias como vinculantes. El plan de entrenamiento deja la elección concreta del modelo base para el momento de la implantación, así que la tabla muestra qué tipo de base es compatible con cada opción.

Modelo	Papel en ReJust	Licencia	Consecuencia
LEGAL-BERT	Referencia del LLM jurídico (Sprint 1)	CC BY-SA 4.0	Un derivado tendría que llevar CC BY-SA 4.0 o licencia compatible. Además, está entrenado en inglés
ColBERTv2	Recuperación densa	MIT	Permisiva: solo exige conservar el aviso de copyright y la licencia
RoBERTalex	Alternativa jurídica en español	Apache 2.0	Modelo jurídico del Plan de Tecnologías del Lenguaje del Gobierno, publicado con licencia permisiva
ALIA-40b	Posible base generativa en español	Apache 2.0	Deja libre la licencia del derivado, con aviso de atribución
MMPose	Estimación de pose en Seguimiento (Anexo II)	Apache 2.0	Permite ajustar el modelo y mantener el resultado sin publicar
Llama-2-13b-chat	Componente de LAVAD, referencia de Seguimiento en el Sprint 2	Llama 2 Community License	Política de uso aceptable, prohibición de usar sus salidas para mejorar otros LLM y tribunales de California. Excluido
ImageBind	Componente de LAVAD	No comercial (CC BY-NC 4.0 / CC BY-NC-SA 4.0)	Su propia ficha lo excluye de cualquier aplicación real. Excluido

De LAVAD (Zanella et al., 2024) solo se conserva la idea arquitectónica. El Anexo II aplica el mismo criterio cuando descarta Ultralytics YOLO por su licencia AGPL-3.0 y adopta MMPose. En Sentencia ocurre algo parecido: si el LLM jurídico se ajustara sobre LEGAL-BERT, la licencia de los pesos quedaría fijada en CC BY-SA 4.0 y el modelo partiría del inglés. Con una base Apache 2.0 en español, como ALIA o RoBERTalex, la licencia del modelo ajustado es una decisión propia.

4. Criterios de decisión

Todas las licencias candidatas se evalúan con los mismos seis criterios. Cada uno responde a una pregunta concreta y se apoya en una norma o en evidencia técnica.

Criterio	Pregunta	Base
C1. Herencia	¿Qué licencias permite la del modelo base?	Sección 3
C2. Datos personales	¿Publicar los pesos expone datos de las personas con cuyos datos se entrenó?	Carlini et al., 2021; LO 7/2021
C3. Transparencia y defensa	¿Puede la defensa, o un auditor independiente, examinar el modelo que influyó en el caso?	CE, art. 24; RDL 6/2023, art. 97
C4. Seguridad	¿Facilita la licencia ataques contra el sistema?	Zou et al., 2023; Robustez, Sprint 2
C5. Sector público y soberanía	¿Encaja con la reutilización de aplicaciones públicas y deja el control en manos del Estado?	Ley 40/2015, art. 157; RD 4/2010, art. 16; RDL 6/2023, arts. 97-98
C6. Libertad de uso	¿Se puede usar para cualquier fin, o impone restricciones de uso?	Definición de IA de código abierto de la OSI, v1.0; Reglamento (UE) 2024/1689, art. 2.12

C2. Carlini et al. extrajeron cientos de secuencias literales del entrenamiento de GPT-2 consultando el modelo, incluidos datos personales. Por eso importa con qué datos se ajusta cada modelo: los de Sentencia solo ven casos sintéticos, mientras que los de Seguimiento ven grabaciones de actores cuya imagen está protegida por un contrato de cesión.

C3 y C5. El art. 97 del RDL 6/2023 permite declarar de fuentes abiertas las aplicaciones de las Administraciones con competencias en Justicia cuando ello aumente la transparencia de su funcionamiento, y el art. 98 crea un directorio de aplicaciones judiciales reutilizables. La EUPL aparece en el art. 16 del RD 4/2010 como licencia de referencia para las aplicaciones públicas declaradas de fuentes abiertas.

C6. Licenciar en abierto no reduce las obligaciones de ReJust. El art. 2.12 del Reglamento excluye los sistemas con licencia libre, salvo que se comercialicen o pongan en servicio como sistemas de alto riesgo (Hogan Lovells, 2024), y la administración de justicia está en el Anexo III. Por el mismo motivo, los usos más graves que una licencia ética querría prohibir ya están prohibidos por ley, por ejemplo en el art. 5.1.d sobre predicción de delitos basada solo en perfiles.

5. Licencias candidatas para los modelos

Se comparan cinco opciones. Ninguna gana en todos los criterios: las abiertas favorecen la transparencia y la reutilización, y las restrictivas protegen mejor los datos y la seguridad.

Apache 2.0. Licencia permisiva con cesión expresa de patentes. Es la que han usado modelos de lenguaje públicos españoles como RoBERTalex y ALIA. Permite cualquier uso, incluido el comercial, sin obligación de publicar los cambios.

EUPL 1.2. Es la licencia del código de ReJust (Anexo II). Su copyleft alcanza el uso en red: quien ofrezca una versión modificada como servicio debe publicarla (Interoperable Europe). Para los pesos plantea un problema: apenas se ha usado con modelos y no está claro qué es el «código fuente» de

unos pesos, que es lo que su copyleft obliga a entregar.

CC BY-SA 4.0. Es la que impondría LEGAL-BERT a cualquier derivado, aunque también puede elegirse sobre una base Apache 2.0, que permite licenciar el modelo derivado con otras condiciones. Garantiza que las mejoras sigan abiertas, pero está pensada para obras culturales: no cede patentes y no cubre el uso como servicio.

OpenRAIL-M. Licencia abierta con restricciones de uso que pasan obligatoriamente a todos los derivados. No es de código abierto según la OSI (BigCode). La versión de BigScience tiene dos problemas para ReJust: su anexo A prohíbe usar el modelo en la administración de justicia, que es justo el uso para el que existe ReJust, y su cláusula 7 reserva al licenciante el derecho a restringir el uso en remoto (BigScience, 2022). Habría que redactar una licencia propia, y sus restricciones duplicarían prohibiciones que ya impone el art. 5 del Reglamento.

Acceso restringido. Los pesos no se publican. El Ministerio los custodia y da acceso controlado a auditores, a la autoridad de supervisión y, en un procedimiento concreto, a peritos de la defensa. Se publican la ficha del modelo y la descripción de los datos.

Licencia	**C1 Herencia**	**C3 Transparencia**	**C4 Seguridad**	**C5 Sector público**	**C6 Libertad de uso**
Apache 2.0	Solo con base permisiva	Alta	Baja	Alta (precedentes españoles)	Total
EUPL 1.2	Solo con base permisiva o compatible	Alta	Baja	Alta (referencia del RD 4/2010)	Total, con copyleft
CC BY-SA 4.0	Posible con base permisiva; obligatoria con LEGAL-BERT	Alta	Baja	Media	Total, con copyleft
OpenRAIL-M	Solo con base permisiva	Alta	Baja	Baja (restricción remota)	Limitada
Acceso restringido	Cualquier base	Media (acceso controlado)	Alta	Media	No aplica

C2 no aparece en la tabla porque no depende de la licencia, sino de los datos de cada módulo (sección 2). C4 también tiene matices: Zou et al. generaron ataques optimizándolos sobre modelos abiertos y luego los transfirieron a modelos cerrados. Cerrar los pesos dificulta los ataques de caja blanca, pero no hace el sistema inmune.

6. Licencias candidatas para la documentación

La documentación pública y la restringida no pueden llevar la misma licencia. Para la pública se comparan cinco opciones. La restringida no se licencia al público: se entrega a las autoridades de supervisión, que deben respetar su confidencialidad (art. 78 del Reglamento (UE) 2024/1689), y a los auditores mediante acuerdos de confidencialidad.

Licencia	**Reutilización**	**Atribución y trazabilidad**	**Traducción y adaptación**	**Cultura libre**
CC BY 4.0	Cualquier fin, incluido el comercial	Obligatoria, con indicación de los cambios	Sí	Sí

Licencia	Reutilización	Atribución y trazabilidad	Traducción y adaptación	Cultura libre
CC BY-SA 4.0	Cualquier fin; las adaptaciones llevan la misma licencia	Obligatoria, con indicación de los cambios	Sí	Sí
CC0 1.0	Total	No se exige	Sí	Sí
CC BY-ND 4.0	Solo copias literales	Obligatoria	No	No
Todos los derechos reservados	Solo con permiso	No aplica	No	No

CC BY 4.0 es la licencia por defecto de los documentos de la Comisión Europea desde la Decisión C(2019) 1655 (Comisión Europea), y la normativa europea sobre datos abiertos recomienda la serie CC 4.0 para la información del sector público (Reglamento de Ejecución (UE) 2023/138, cons. 12). Para un documento oficial tiene una ventaja concreta: quien lo modifique debe indicarlo, de modo que una versión alterada no puede circular como si fuera la oficial.

CC BY-SA 4.0 obligaría a publicar con la misma licencia las guías derivadas, por ejemplo las de un colegio de abogados. Protege lo común, pero puede frenar a editoriales jurídicas que integren la documentación en materiales propios. **CC0** maximiza la reutilización, pero en España los derechos morales de autor son irrenunciables (art. 14 de la Ley de Propiedad Intelectual), así que solo funciona como licencia amplia de respaldo, y además se pierde la atribución que permite saber qué versión es la válida. **CC BY-ND 4.0** impide traducir a las lenguas cooficiales o adaptar a formatos accesibles sin pedir permiso, y no es una licencia libre. **Todos los derechos reservados** contradice las obligaciones de transparencia asumidas en sprints anteriores y solo tiene sentido para la documentación restringida.

Creative Commons desaconseja sus licencias para software (Creative Commons, 2015), así que los fragmentos de código incluidos en la documentación siguen la licencia del código.

7. Compatibilidades e incompatibilidades

Con el Anexo II y el plan de entrenamiento cerrados, pueden comprobarse todas las relaciones entre licencias que afectan a los modelos y a la documentación.

Relación	Análisis	Resultado
Modelo base → modelo ajustado	Con LEGAL-BERT, solo CC BY-SA 4.0, Free Art License 1.3 o, en un solo sentido, GPLv3. Con una base Apache 2.0 o MIT, el derivado puede llevar otra licencia si se conservan los avisos originales	Se exige base Apache 2.0 o MIT al seleccionar el modelo (plan de entrenamiento, apdo. 2.1)
Componentes no comerciales o con política de uso	ImageBind es no comercial y Llama 2 impone una política de uso y tribunales de California	Excluidos
Casos sintéticos (ODbL 1.0) → modelos de Sentencia	La ODbL distingue la base de datos derivada, que debe compartirse con la misma licencia, de la obra producida a partir de ella, que solo exige un aviso cuando se usa públicamente (ODbL 1.0). Un modelo entrenado encaja mejor en la segunda categoría. Además, el Ministerio es titular de los casos y su propia licencia no le vincula	Compatible: los pesos llevan CC BY-SA 4.0 e incluyen el aviso de procedencia ODbL

Relación	Análisis	Resultado
Escenas sintéticas (CC BY-NC-SA 4.0) y grabaciones de actores → modelos de Seguimiento	Si los pesos se publicaran, podrían considerarse una adaptación de las escenas, heredando la cláusula no comercial, y exponer la imagen de los actores	Sin conflicto, porque los pesos no se publican (sección 8.2)
Pesos ↔ código (EUPL-1.2)	El Anexo II desacopla el motor de los pesos mediante API y carga externa de tensores, así que son obras separadas	Compatible. Ver la nota sobre el uso en red
Documentación (CC BY 4.0) ↔ código (EUPL-1.2)	Conviven en el mismo repositorio	El archivo LICENSE recoge la EUPL-1.2; el README indica a qué partes se aplican las demás licencias

Nota sobre el uso en red. El Anexo II descarta la GPLv3 para el código porque no cubre el uso como servicio. La CC BY-SA 4.0 tiene el mismo hueco para los pesos: una adjudicataria podría ofrecer por API un modelo mejorado sin publicarlo. Se cubre por contrato: los pliegos exigirán entregar al Ministerio cualquier peso modificado, que se publicará con la misma licencia.

8. Decisión y justificación

La tabla resume el resultado por componente. Cada decisión se justifica a continuación con los criterios de la sección 4.

Componente	Licencia
LLM jurídico (Sentencia)	CC BY-SA 4.0, sobre una base Apache 2.0 o MIT
Modelos de recuperación reajustados (Sentencia)	CC BY-SA 4.0, conservando el aviso MIT de ColBERTv2
Políticas de recuperación (Sentencia)	CC BY-SA 4.0; acceso restringido para cualquier versión ajustada con registros reales
Estimación de pose y clasificación de eventos (Seguimiento)	Acceso restringido
Documentación pública	CC BY 4.0
Documentación restringida	Sin licencia pública; confidencialidad del art. 78 del Reglamento (UE) 2024/1689
Referencia: código fuente	*EUPL-1.2 (Anexo II)*

8.1. Modelos de ReJust-Sentencia: CC BY-SA 4.0

El LLM jurídico se ajusta sobre un modelo preentrenado con licencia Apache 2.0 o MIT, por ejemplo ALIA, y se publica bajo CC BY-SA 4.0. Apache 2.0 permite licenciar el derivado con otras condiciones siempre que se conserven el aviso y la licencia originales. LEGAL-BERT deja de ser la referencia: está entrenado en inglés y fijaría la licencia de antemano. Los modelos de recuperación que se reajusten siguen la misma licencia.

El criterio decisivo es C3. Según el plan de entrenamiento, los pesos de Sentencia solo contienen lo aprendido de casos sintéticos y documentación original, así que C2 no justifica cerrarlos. Publicarlos permite a la defensa, a la universidad y al CGPJ examinar y probar el modelo, lo que encaja con el art. 97 del RDL 6/2023 y con la auditoría externa acordada tras el Debate 3. El requisito de compartir igual

mantiene abiertas las mejoras, que es el mismo objetivo que el Anexo II persigue con la EUPL para el código.

Frente al acceso restringido, el argumento de seguridad (C4) es débil. Los ataques diseñados sobre modelos abiertos se transfieren a modelos cerrados, y el vector realista en ReJust son documentos manipulados dentro del expediente, que no depende de que los pesos sean públicos. Apache 2.0 se descarta porque no obliga a mantener abiertas las mejoras. La EUPL 1.2, elegida para el código, se descarta para los pesos porque no está claro qué es su código fuente. OpenRAIL-M se descarta porque su anexo A prohíbe el uso en la administración de justicia. Se asumen dos límites de CC BY-SA 4.0: no cede patentes y no alcanza el uso como servicio, hueco que se cubre por contrato (sección 7).

Políticas de recuperación. Se entrenan solo con casos sintéticos, porque el plan de entrenamiento prohíbe aprender de consultas reales, y por eso siguen la misma licencia que el resto de Sentencia. Si en el futuro se habilitara ajustarlas con registros reales, esa versión quedaría en acceso restringido: aprendería de búsquedas en expedientes custodiados por el CGPJ y le aplicaría C2 igual que a Seguimiento.

8.2. Modelos de ReJust-Seguimiento: acceso restringido

Los pesos no se publican. Aunque el entrenamiento inicial usa escenas sintéticas, también usa grabaciones de actores cuya cesión de derechos está restringida al Ministerio (Anexo II). Unos pesos públicos podrían reproducir rasgos de esas grabaciones (C2) y, si se consideraran una adaptación de las escenas sintéticas, heredarían su cláusula no comercial. Además, cualquier validación posterior con material real exigirá habilitación jurídica y evaluación de impacto, y lo que se ajuste con él no podrá publicarse. Abrir ahora la primera versión crearía dos regímenes distintos para el mismo modelo.

También pesa C4, con más fuerza que en Sentencia. Con los pesos de un detector de caídas o agresiones, cualquiera puede buscar movimientos y posiciones que el detector no reconozca, y en un centro penitenciario ese incentivo existe.

La transparencia (C3) se garantiza por otras vías. Se publican la ficha del modelo y la descripción de los datos, y acceden de forma controlada los auditores externos acordados tras el Debate 3, la autoridad de supervisión, el Mecanismo Nacional de Prevención de la Tortura y, en cada procedimiento, los peritos de la defensa. Las licencias abiertas se descartan porque ninguna resuelve C2: el problema no es qué se permite hacer con los pesos, sino que existan copias públicas de ellos.

8.3. Documentación pública: CC BY 4.0

CC BY 4.0 permite traducir la documentación a las lenguas cooficiales y adaptarla a formatos accesibles sin pedir permiso, y que colegios de abogados, universidades o editoriales jurídicas la reutilicen. La obligación de citar e indicar los cambios mantiene la trazabilidad, y es la licencia por defecto de la Comisión Europea. Frente a CC BY-SA 4.0 se prioriza la reutilización sobre el copyleft, porque en documentación oficial importa más que circule que controlar las obras derivadas. CC0, CC BY-ND y todos los derechos reservados se descartan por los motivos de la sección 6. Los fragmentos de código de la documentación se rigen por la EUPL-1.2, y la documentación restringida no se licencia al público.

Referencias

Normativa

- Comisión Europea (2019). Decisión C(2019) 1655, por la que se adopta Creative Commons como licencia abierta. Enlace
- Comisión Europea (2023). Reglamento de Ejecución (UE) 2023/138, conjuntos de datos de alto valor. Enlace
- Constitución Española (1978). Art. 24.
- España (1996). Real Decreto Legislativo 1/1996, Texto Refundido de la Ley de Propiedad Intelectual. Arts. 13 y 14. Enlace
- España (2010). Real Decreto 4/2010, Esquema Nacional de Interoperabilidad. Art. 16. Enlace
- España (2015). Ley 40/2015, de Régimen Jurídico del Sector Público. Art. 157.
- España (2021). Ley Orgánica 7/2021, de protección de datos personales tratados con fines penales. Enlace
- España (2023). Real Decreto-ley 6/2023, de medidas de eficiencia digital del Servicio Público de Justicia. Arts. 97 y 98. Enlace
- Unión Europea (2024). Reglamento (UE) 2024/1689 de inteligencia artificial. Arts. 2.12, 5, 11, 13 y 78; Anexo III. Enlace

Licencias y fichas de modelos

- BigCode (2023). CodeML OpenRAIL-M 0.1, preguntas frecuentes. Enlace
- BigScience (2022). BigScience Open RAIL-M License. Enlace
- BSC-LT. ALIA-40b-instruct, ficha del modelo. Enlace
- colbert-ir. ColBERTv2.0, ficha del modelo. Enlace
- Creative Commons (2015). CC BY-SA 4.0 now one-way compatible with GPLv3. Enlace
- Interoperable Europe. European Union Public Licence v1.2. Enlace
- Interoperable Europe. ODC Open Database License (ODbL) v1.0. Enlace
- Meta (2023). Llama 2 Community License Agreement. Enlace
- Meta AI. ImageBind, ficha del modelo. Enlace
- nlpaueb. LEGAL-BERT, ficha del modelo. Enlace
- Open Source Initiative (2024). The Open Source AI Definition, v1.0. Enlace
- PlanTL-GOB-ES. RoBERTalex, ficha del modelo. Enlace

Estudios y análisis

- Carlini, N. et al. (2021). Extracting Training Data from Large Language Models. USENIX Security. Enlace
- Hogan Lovells (2024). Digital Transformation Notes, mayo de 2024. Enlace
- Zanella, L. et al. (2024). Harnessing Large Language Models for Training-free Video Anomaly Detection. CVPR. Enlace
- Zou, A. et al. (2023). Universal and Transferable Adversarial Attacks on Aligned Language Models. Enlace

Documentación del proyecto

- ReJust (2026). Sprint 4. Anexo II: Licenciamiento de código fuente y conjuntos de datos.
- ReJust (2026). Sprint 4. Anexo: Plan de entrenamiento sin violación de copyright.
- ReJust (2026). Sprint 4. Anexo: Mejoras y aclaraciones tras el Debate 3.
- ReJust (2026). Sprint 3. Anexo IV: Límites, emergencias y rendición de cuentas.
- ReJust (2026). Sprint 2. Robustez.
- Repositorio del proyecto. Enlace